BDAI 3팀 · 분석 흐름 정리

듀오링고 학습 지속 분석

목표 → 가설 → 세그먼트 → 코호트로 가설 검증 → 전략

0. 데이터 소개

듀오링고 학습자가 단어를 언제, 얼마 만에 다시 보고 맞혔는지 담은 2주치 기록

항목	내용
데이터	Duolingo 간격 반복(Spaced Repetition) 학습 기록 · learning_traces.13m.csv · 약 1,300만 행
기간	2013-02-28 ~ 03-12 (약 2주) → 하루가 온전한 3/1~3/11만 사용 (109,504명)
한 행	사용자 한 명이 한 세션에서 한 단어를 학습한 기록
주요 열	timestamp(학습 시각), delta(그 단어를 마지막으로 본 뒤 지난 시간), history_seen·correct(이전까지 본·맞힌 횟수), session_seen·correct(이번에 본·맞힌 횟수), 배우는 언어·사용 언어
없는 정보	가입일, 유입 경로, 알림, 결제, 세션 ID

복습 행동 데이터 → 가설을 복습 행동으로 세움

기간이 약 2주 → NSM을 주 단위로, 기준 주간 + 후속 4일

가입·알림·결제 없음 → 학습 기록만으로 분석

1. 목표와 NSM

목표는 이탈 방지, NSM은 ‘일주일에 4일 이상 학습한 사람 수’

NSM · 주 7일 중 4일 이상 학습한 사용자

9,834명

기준 주간 학습자 82,467명 중 11.9%

이 사람들은 다음 4일에 77.8%가 다시 옴 (나머지는 29.7%)

왜 하필 4일?

2일 이상 학습한 사람은 42.9%로 “한두 번 와 본 사람”과 구분되지 않음

6일 이상 학습한 사람은 2.9%로 너무 소수

4일 = 일주일의 절반 넘게 온 사람, 즉 습관이 생긴 사람

2. 가설과 Input Metrics

가설 3개, 그리고 가설마다 그걸 재는 지표 1개씩

가설	Input Metric	계산식
1 · 복습 규칙성 → 리텐션 일정한 간격으로 오는 사람이 더 오래 남는다	규칙적 학습자 비율	학습일 간격의 변동계수(표준편차 ÷ 평균)가 0.5 이하인 사람 ÷ 학습일 3일 이상인 사람
2 · 정답률 변화 → 리텐션 할수록 정답률이 오르는 사람이 더 오래 남는다	정답률 상승 사용자 비율	뒤 절반 세션 정답률 > 앞 절반 세션 정답률인 사람 ÷ 세션 3개 이상인 사람
3 · 복습 간격 → 학습 성과 너무 오래 두지 않고 복습하면 더 잘 맞힌다	7일 이내 복습 비율	delta(그 단어를 직전에 본 뒤 지난 시간)가 7일 이하인 학습 기록 ÷ 전체 학습 기록

왜 이 가설? 데이터가 복습 기록(복습 간격, 이전에 본 횟수, 정답 수)이라 “복습을 어떻게 하느냐”가 리텐션을 만든다는 방향으로 세움

기존 지표(다음날 재학습률 35.8%, 첫 학습일 학습량 47문항, 활동일당 세션 수 2.0)는 보조 지표로 둠 · 가설 3만 결과가 ‘정답률’이라 이탈 방지와는 한 다리 건너 연결

3. 데이터 분석 기준 (모든 분석 공통)

3/1~3/7 행동으로 사람을 나누고, 3/8~3/11에 다시 왔는지 봄

기준 주간 (나누는 기간)

3/1 ~ 3/7 · 82,467명

이 주에 한 번이라도 학습한 사람 전부

후속 관측 (결과 보는 기간)

3/8 ~ 3/11 · 4일

이 4일 동안 다시 학습했는지

재학습률 (결과 지표)

35.5% / 16.3%

4일 중 하루라도 옴 / 이틀 이상 옴

이탈 위험

53,227명 · 64.5%

4일 동안 한 번도 안 옴 (완전히 떠났다는 뜻은 아님)

4. 세그먼트 분석 (RFM)

사용자를 6개 유형으로 나눔

유형	어떤 사람?	사람 비중	학습량 비중	1인당 문항
꾸준형	4일 이상 + 최근에도 옴	10.8%	38.5%	611
습관 형성형	2~3일 + 최근에도 옴	17.7%	22.0%	212
최근 단발형	딱 1일 + 최근에 옴	18.7%	7.5%	69
멈춤-꾸준형	3일 이상 했는데 3/5 이후 안 옴	4.4%	8.3%	321
멈춤-몰입형	1~2일에 몰아서 많이 하고 멈춤	11.3%	14.9%	226
멈춤-저활동형	조금 하고 멈춤	37.2%	8.8%	40

꾸준형 · 습관 형성형 · 멈춤-몰입형 3개 유형(사람 40%)이 전체 학습량의 75%를 만듦

5. 세그먼트별 코호트

유형마다 다음 4일에 다시 오는 비율이 80%에서 18%까지 차이 남

유형	하루라도 다시 옴	이틀 이상 옴	안 옴 (이탈 위험)
꾸준형	80.3%	55.9%	19.7%
습관 형성형	52.2%	24.4%	47.8%
최근 단발형	32.5%	12.1%	67.5%
멈춤-꾸준형	45.7%	22.3%	54.3%
멈춤-몰입형	26.4%	9.0%	73.6%
멈춤-저활동형	17.5%	4.7%	82.5%

→ 그럼 같은 유형 안에서는 무엇이 다시 오는 사람과 안 오는 사람을 가를까? (= 가설 검증)

출처: 코호트 통합본 ③, 부록 B · 마지막 학습일을 맞춰도 유형 간 차이는 유지됨

6. 코호트로 가설 검증 · 방법

같은 유형끼리 묶고, 그 안에서 가설 요인으로 다시 나눠 비교

① 세그먼트

누구끼리?

예: 습관 형성형끼리

→

② 가설 요인

무엇으로 나눠?

예: 규칙적인 사람 vs 불규칙한 사람

→

③ 코호트

다시 왔나?

3/8~3/11 재학습률 비교

왜 같은 유형끼리? 전체로 비교하면 **원래 자주 오는 사람**이 섞여서 결과가 왜곡됨 (가설 1은 전체로 보면 결과가 반대로 나왔었음)

6개 유형 전부 검증함 · 가설 3만 '다시 왔나' 대신 '정답률'을 비교 · 300명 미만 칸은 해석 안 함

7. 가설 1 · 복습 규칙성 → 리텐션 판단 보류

7일 데이터로는 규칙적인 사람과 아닌 사람을 제대로 나눌 수 없었음

유형 (학습일 3~6일)	규칙적	불규칙
꾸준형	54.8%	45.5%
습관 형성형	30.6%	31.8%
멈춤-꾸준형	22.3%	없음 (전원 규칙적)

왜 보류?

7일 안에서는 학습 간격이 2~5개뿐이라, 대부분이 '규칙적'으로 분류됨 (84%)

습관 형성형은 차이 없음

꾸준형 차이도 학습일 수를 맞추면 +3~4%p로 줄어듦

수치 = 3/8~3/11 이틀 이상 재학습률 · 규칙적 = 학습일 간격의 변동계수 0.5 이하

8. 가설 2 · 정답률 변화 → 리텐션 기각

정답률이 올라도 더 돌아오지 않음 (모든 유형에서)

유형	정답률 오른 사람	정답률 떨어진 사람	차이
꾸준형	80.5%	80.3%	+0.2%p
습관 형성형	55.1%	53.6%	+1.5%p
최근 단발형	41.7%	45.1%	−3.4%p (오히려 반대)
멈춤-꾸준형	45.7%	45.5%	+0.2%p
멈춤-몰입형	27.0%	26.1%	+0.9%p
멈춤-저활동형	23.0%	23.2%	−0.2%p

→ 정답률 상승 사용자 비율은 지표에서 빼고, 정답률 관련 액션도 안 넣는 걸로

퍼널 분석에서도 첫날 정답률 차이는 학습량을 맞추면 사라짐 → 서로 다른 두 분석이 같은 결론

수치 = 3/8~3/11 하루라도 다시 온 비율 · 대상: 세션 3개 이상 44,495명 · 이틀 이상 기준으로 봐도 같음

9. 가설 3 · 복습 간격 → 학습 성과 지지 (차이는 작음)

7일 안에 다시 본 단어는 정답률이 조금 더 높음 (모든 유형에서)

유형	7일 이내 복습	7일 넘어서 복습	차이
꾸준형	90.8%	89.2%	+1.6%p
습관 형성형	90.9%	88.9%	+2.0%p
최근 단발형	91.1%	88.8%	+2.3%p
멈춤-꾸준형	90.9%	88.6%	+2.3%p
멈춤-몰입형	91.0%	89.0%	+2.0%p
멈춤-저활동형	90.1%	88.5%	+1.6%p

→ 결과가 '정답률'이라 이탈 방지와는 한 다리 건너 연결 → **학습 품질 지표**로만 사용

수치 = 정답률 · 7일 이내 복습 비율이 가장 낮은 유형: 멈춤-저활동형 61.7%, 최근 단발형 63.5% (꾸준형 85.2%)

9-1. 분석 중 추가로 발견한 것 (가설 아님, 퍼널 분석으로 알게 된 부분)

가설보다 '첫날'과 '그다음 날'이 훨씬 크게 갈랐음

첫날 많이 푼 사람이 주 4일까지 감

15.8% → 43.3%

첫날 20문제 미만 → 120문제 이상 (약 2.7배) · 어느 날 시작해도 같은 경향

첫날 다음날 다시 온 사람이 주 4일까지 감

61.9% vs 14.7%

다음날 다시 옴 vs 안 옴 (약 4.2배)

→ 보조 지표(첫 학습일 학습량, 다음날 재학습률)를 계속 봐야 하는 근거 · 딱 1일만 온 **최근 단발형**이 바로 여기서 멈춘 사람들

단, 원래 의욕이 큰 사람이 첫날도 많이 하고 다음날도 오는 것일 수 있음 → '늘려야 할 목표'보다 '계속 올지 알려 주는 신호'로 사용

출처: 퍼널 분석 (3/1 시작자 21,738명, 수치 = 주 4일 학습 달성률) · 코호트 통합본 ⑤도 첫 학습 다음 날에 가장 크게 줄어듦

10. 집중 유형 제안

전략은 습관 형성형부터 (검증은 6개 유형 전부 했음)

왜 습관 형성형?

NSM 바로 아래: 이미 2~3일 학습, 1~2일만 더 오면 NSM

사람이 많음: 14,583명 (17.7%)

올릴 여지: 절반(52.2%)은 다시 오는데 이틀 이상 이어 가는 건 24.4%

다른 유형은? 꾸준형은 이미 달성 / 단발형·저활동형은 NSM까지 멀고 복귀율 낮음 / 멈춤-꾸준형은 4.4%로 작음

이 유형에서 확인한 것

규칙성: 차이 없음 (30.6% vs 31.8%)

정답률 변화: 차이 없음 (55.1% vs 53.6%)

끊기는 곳: 다시 오는 건 52.2%, 이틀 이상은 24.4%

→ 가설 요인보다 “한 번 다시 온 사람을 한 번 더 오게” 하는 게 핵심

집중 유형은 더 추가될 수 있음 ex1. 최근 단발형: 첫날에서 멈춘 사람들, 9-1 퍼널 결과와 연결 ex2. 멈춤-꾸준형: 많이 했는데 멈춘 사람들

11. 유형별 전략

근거가 있는 것만 액션으로

누구에게	근거	무엇을	보는 지표
① 습관 형성형	다시 오지만 이어 가지 못함 (52.2% → 24.4%) · 코호트	다음 학습일 안내 + 주 4일 목표, 3일째엔 “4일까지 1일 남음” 알림	이틀 이상 재학습률, 4일 달성률
② 최근 단발형	다음날 온 사람 61.9% vs 안 온 사람 14.7% · 퍼널	다음날 “어제 배운 단어 복습” 알림, 첫날 적게 푼 사람부터	다음날 재학습률
③ 멈춤-저활동형	7일 안에 복습하는 비율 최저 61.7% · 가설 3	“잊기 전에 복습” 알림	7일 이내 복습 비율
④ 멈춤-꾸준형	많이 했는데 멈춤 (1인당 321문항) · 세그먼트	하던 학습 이어 하기 알림	하루라도 다시 온 비율
⑤ 꾸준형	이미 NSM 달성, 80.3%가 다시 옴	연속 학습 보상 (알림은 적게)	NSM 유지율

모두 실험으로 확인 · 무작위로 반 나눠 한쪽만 액션 · 첫날 학습량은 늘릴 목표가 아니라 알림 순서를 정하는 기준

12. 대시보드 (안)

매주 볼 지표 + 세그먼트 필터

[대시보드 화면 캡처 자리]

맨 위 숫자 카드

NSM 9,834명(11.9%) · 주간 학습자 82,467명 · 이탈 위험 64.5%

Input Metrics

7일 이내 복습 비율 79.7%

규칙적 학습자 비율 84.2% (참고만, 7일로는 판단 어려움)

보조 지표

다음날 재학습률 35.8% · 첫 학습일 학습량 47문항

세그먼트 필터를 바꾸면 모든 숫자가 같이 바뀌게

13. 한계

이 데이터로 말할 수 있는 것과 없는 것

기간이 짧음

7일 + 4일이라 장기 이탈은 모름. 가설 1도 이 때문에 보류

상관관계일 뿐

“이러면 더 돌아온다”가 아니라 “이런 사람이 더 돌아왔다”. 효과는 실험으로

없는 데이터

가입일, 유입 경로, 알림, 결제 기록 없음

가설 설계

가설 3은 결과가 정답률이라 이탈 방지와 간접 연결. 처음부터 리텐션으로 맞췄으면 더 좋았을 것