BDAI 3주차_정여진_공유

▼ 분석 코드(Python)

```
import pandas as pd
import numpy as np
pd.set_option("display.max_columns", None)

path = r"C:\Users\SAMSUNG\Desktop\learning_traces.13m.csv"

# 분석 설정 (NSM 정의: 7일이 온전히 포함된 첫 주 = 3/1~3/7)
OBS_START = "2013-03-01"   # 관측 시작일 (포함)
OBS_END = "2013-03-08"     # 관측 종료일의 다음 날 (미포함) = RFM 기준일
DATA_START = "2013-03-01"  # 하루가 온전한 데이터 구간 (포함)
DATA_END = "2013-03-12"    # 하루가 온전한 데이터 구간 끝 (미포함)

# 세그먼트 6개 (기존 초반 이탈 + 중반 이탈 → "멈춤-저활동형"으로 합침)
# 이름 체계: 위 3개 = 최근 활동 중(R≥4), 아래 3개 = 최근 이틀 미학습(R≤3, "멈춤-")
#   기존 이름 → 새 이름
#   핵심 학습자 → 꾸준형 / 습관 형성 중 → 습관 형성형 / 최근 1일 학습 → 최근 단발형
#   중단 위험 → 멈춤-꾸준형 / 몰입 후 이탈 → 멈춤-몰입형
#   초반 이탈 + 중반 이탈 → 멈춤-저활동형
# 이름을 바꾸려면 여기만 고치면 됨
SEG_ORDER = ["꾸준형", "습관 형성형", "최근 단발형",
             "멈춤-꾸준형", "멈춤-몰입형", "멈춤-저활동형"]

# 1. 불러오기: 12개 열 전부 (문자열 열은 category로 메모리 절약)
df = pd.read_csv(path, dtype={"user_id": "category", "learning_language": "category",
"ui_language": "category",
    "lexeme_id": "category", "lexeme_string": "category",})

# 2. EDA: 중복 제거 (12개 열이 전부 같은 행, 첫 행만 남김)
before = len(df)
df = df.drop_duplicates()
print(before - len(df), "행 제거")   # 81행이 나옴

# 2-1. 결측·범위 점검 (전부 0이어야 정상). 아래에서 열을 줄이기 전에 확인
print(df.isna().any(axis=1).sum(), "행: 결측값 있음")
print((df["delta"] < 0).sum(), "행: delta가 음수")
print((~df["p_recall"].between(0, 1)).sum(), "행: p_recall이 0~1 밖")

# 분석에 쓰는 열만 남기기
df = df[["user_id", "timestamp", "learning_language",
         "lexeme_id", "session_seen", "session_correct"]]

# 3. 시간 변환 + 하루가 온전한 기간(3/1~3/11)만 남기기
#    (3/8~3/11은 나중에 세그먼트 검증용으로 보관)
df["dt"] = pd.to_datetime(df["timestamp"], unit="s")
df = df[(df["dt"] >= DATA_START) & (df["dt"] < DATA_END)].copy()
df["date"] = df["dt"].dt.normalize()
print(df["dt"].min(), "~", df["dt"].max())
print(df["user_id"].nunique(), "명 (3/1~3/11 전체)")   # 109504명

# 4. 논리 오류 점검 (둘 다 0이어야 정상)
print((df["session_correct"] > df["session_seen"]).sum(), "행: 정답 수가 출제 수보다 큼")
```

```
print((df["session_seen"] <= 0).sum(), "행: 출제 수가 0 이하")

# 5. 관측 기간(3/1~3/7)만 잘라서 유저별 집계
obs = df[(df["dt"] >= OBS_START) & (df["dt"] < OBS_END)]

user = obs.groupby("user_id", observed=True).agg(
    first_active=("date", "min"),               # 관측 주 첫 학습일 (코호트용)
    last_active=("date", "max"),                # R의 재료
    active_days=("date", "nunique"),            # F: 학습한 날짜 수
    words_seen=("session_seen", "sum"),         # M: 학습 문항 수 (팀 정의)
    words_correct=("session_correct", "sum"),   # 정답률 계산용
    sessions=("timestamp", "nunique"),          # 군집 분석용 (세션 = 유저+timestamp 추정)
)

# R: 기준일(3/8) - 마지막 학습일  -> 3/7에 학습했으면 1, 3/1이면 7
user["recency"] = (pd.Timestamp(OBS_END) - user["last_active"]).dt.days

# 파생 지표 (군집 분석 등에서 사용)
user["accuracy"] = user["words_correct"] / user["words_seen"]
user["per_day"] = user["words_seen"] / user["active_days"]            # 활동일당 문항 수
user["sessions_per_day"] = user["sessions"] / user["active_days"]     # 활동일당 세션 수

# 6. 확인
print("\n관측 기간 유저 수:", len(user), "명")
print("recency 범위:", user["recency"].min(), "~", user["recency"].max())   # 1~7이어야
정상
print(user.head())

print("\n[active_days 분포]")
print(user["active_days"].value_counts().sort_index())

# NSM: 7일 중 4일 이상 학습한 유저 수 (팀 정의)
nsm = (user["active_days"] >= 4).sum()
print(f"\nNSM 지속 학습 사용자: {nsm}명 ({nsm / len(user):.1%})")

print("\n[요약 통계]")
print(user[["recency", "active_days", "words_seen", "accuracy", "per_day"]]
      .describe(percentiles=[.5, .9, .99, .999]))

print("\n[words_seen 상위 10명]")
print(user.sort_values("words_seen", ascending=False).head(10))

# F 점수: 구간을 직접 지정 (4일 = 팀 NSM 경계)
user["F"] = pd.cut(user["active_days"], bins=[0, 1, 2, 3, 4, 7],
                   labels=[1, 2, 3, 4, 5]).astype(int)
print(user["F"].value_counts().sort_index())

# M 점수: 5분위 (문항 수가 많을수록 5점)
# [수정] rank(method="first")를 빼서 같은 문항 수는 같은 점수를 받도록 함.
#        경계값과 같은 유저는 아래 구간에 포함 (예: 경계가 108이면 108문항은 3점)
#        → 점수별 인원이 정확히 20%씩은 아님
user["M"], m_edges = pd.qcut(user["words_seen"], 5, labels=[1, 2, 3, 4, 5], retbins=Tr
ue)
user["M"] = user["M"].astype(int)
print("\nM 경계값:", m_edges)
print(user.groupby("M")["words_seen"].agg(["min", "max", "count"]))
```

```
# R: 점수를 매기기 전에 분포부터 확인
print(user["recency"].value_counts().sort_index())

# R 점수
user["R"] = pd.cut(user["recency"], bins=[0, 1, 2, 4, 6, 7],
                   labels=[5, 4, 3, 2, 1]).astype(int)
print(user["R"].value_counts().sort_index())

# 맨 마지막
print(pd.crosstab(user["R"], user["F"]))

# 세그먼트 규칙 (위에서부터 순서대로 적용, 처음 충족한 그룹에 배정)
#   순서를 반영한 실제 조건
#   1 꾸준형          : R≥4 & F≥4
#   2 습관 형성형     : R≥4 & F 2~3
#   3 최근 단발형     : R≥4 & F=1
#   4 멈춤-꾸준형     : R 2~3 & F≥3   (R=1은 학습일이 1일뿐이라 해당 없음)
#   5 멈춤-몰입형     : R≤3 & F≤2 & M≥4 (109문항 이상)
#   6 멈춤-저활동형   : R≤3 & F≤2 & M≤3 (나머지 전부)
conditions = [
    (user["R"] >= 4) & (user["F"] >= 4),                      # 1
    (user["R"] >= 4) & (user["F"].isin([2, 3])),              # 2
    (user["R"] >= 4) & (user["F"] == 1),                      # 3
    (user["R"] <= 3) & (user["F"] >= 3),                      # 4
    (user["R"] <= 3) & (user["M"] >= 4),                      # 5
]
# [수정] 기존 6번 규칙(R == 1, 초반 이탈)을 지우고, 나머지를 모두 하나의 그룹으로 받음
#        초반/중반 이탈은 마지막 학습일만 다르고 액션이 같으며,
#        관측 기간이 짧아 복귀율 차이를 성향 차이와 경과 시간 차이로 분리할 수 없어서 합침
labels = SEG_ORDER[:5]
user["segment"] = np.select(conditions, labels, default=SEG_ORDER[5])

# 규칙 점검 1: 모든 유저가 6개 중 하나에 배정됐는지
assert user["segment"].isin(SEG_ORDER).all()
# 규칙 점검 2: 나머지 그룹(default)에 의도한 조합만 들어갔는지
#              R 1~3점, F 1~2점, M 1~3점 조합만 나와야 정상
print(f"\n[{SEG_ORDER[5]}에 들어간 점수 조합]")
print(user.loc[user["segment"] == SEG_ORDER[5], ["R", "F", "M"]].value_counts().sort_i
ndex())

print(user["segment"].value_counts().reindex(SEG_ORDER))
print((user["segment"].value_counts(normalize=True) * 100).round(1).reindex(SEG_ORDE
R))

# 1) 세그먼트별 평균 프로필
profile = user.groupby("segment").agg(
    users=("R", "size"),
    recency=("recency", "mean"),
    active_days=("active_days", "mean"),
    words_seen=("words_seen", "median"),
    accuracy=("accuracy", "mean"),
).round(2).reindex(SEG_ORDER)
print(profile)

# 2) 관측 이후(3/8~3/11)에 다시 학습했는지
later = df[df["dt"] >= OBS_END]
user["returned"] = user.index.isin(later["user_id"].unique())
```

```
print(user.groupby("segment")["returned"].mean().round(3).reindex(SEG_ORDER))
# -> 활동이 많은 세그먼트일수록 복귀율이 높음. 세그먼트 규칙이 이후 행동을 어느 정도 구분한다고 볼 수 있음
#    (단, 세그먼트가 학습 활동으로 정의되어 있으므로 개입 효과가 아니라 분류의 타당성 확인임)

print("\n[활동일 수별 복귀율]")
print(user.groupby("active_days")["returned"].mean().round(3))

# 3) 세그먼트 요약표 (보고서 요약표 열 전부)
summary = user.groupby("segment").agg(
    users=("R", "size"),
    words_seen=("words_seen", "sum"),
    returned=("returned", "mean"),
).reindex(SEG_ORDER)
summary["고객 비중(%)"] = (summary["users"] / summary["users"].sum() * 100).round(1)
summary["학습량 비중(%)"] = (summary["words_seen"] / summary["words_seen"].sum() * 100).
round(1)
summary["인당 문항 수"] = (summary["words_seen"] / summary["users"]).round(0)
summary["집중도"] = (summary["학습량 비중(%)"] / summary["고객 비중(%)"]).round(2)
summary["4일 복귀율(%)"] = (summary["returned"] * 100).round(1)
summary = summary.drop(columns="returned")
print(summary)

# 합계 점검: 세그먼트별 인원·학습량을 더하면 전체와 같아야 함
assert summary["users"].sum() == len(user)
assert summary["words_seen"].sum() == user["words_seen"].sum()
print("합계 점검 통과: 인원", summary["users"].sum(), "/ 학습량", summary["words_seen"].sum
())

# ======================================================================
# 4) K-means 군집 분석 (RFM 세그먼트와 비교용)
#    필요 패키지: scikit-learn (없으면 pip install scikit-learn)
# ======================================================================
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score, adjusted_rand_score

# 4-1. 입력 변수: 세그먼트와 같은 재료(R·F·M 원값)
features = ["recency", "active_days", "words_seen"]
X = np.log1p(user[features])              # 오른쪽으로 긴 분포 완화
X = StandardScaler().fit_transform(X)     # 단위 통일: 평균 0, 표준편차 1

# 4-2. K=3~6 비교
k_results, k_labels = [], {}
for k in range(3, 7):
    km = KMeans(n_clusters=k, n_init=20, random_state=42)
    lab = km.fit_predict(X)
    sil = silhouette_score(X, lab, sample_size=5000, random_state=42)
    k_results.append({"K": k, "silhouette": round(sil, 4), "inertia": round(km.inertia
_, 1)})
    k_labels[k] = lab
k_results = pd.DataFrame(k_results)
print("\n[K별 비교]")
print(k_results)

# 4-3. 실루엣이 가장 높은 K 선택
best_k = int(k_results.loc[k_results["silhouette"].idxmax(), "K"])
print("선택한 K:", best_k)
```

```
# 4-4. 군집 번호 고정: 활동일 수 평균이 낮은 군집부터 C1, C2, ...
user["cluster_raw"] = k_labels[best_k]
order = (user.groupby("cluster_raw")[["active_days", "words_seen"]].mean()
         .sort_values(["active_days", "words_seen"]).index)
user["cluster"] = user["cluster_raw"].map({c: f"C{i+1}" for i, c in enumerate(order)})
user = user.drop(columns="cluster_raw")

# 4-5. 군집 프로필
cluster_profile = user.groupby("cluster").agg(
    users=("R", "size"),
    recency_med=("recency", "median"),
    active_days_med=("active_days", "median"),
    words_seen_med=("words_seen", "median"),
    accuracy_mean=("accuracy", "mean"),
    words_seen_sum=("words_seen", "sum"),
    return_rate=("returned", "mean"),
)
cluster_profile["고객 비중(%)"] = (cluster_profile["users"] / len(user) * 100).round(1)
cluster_profile["학습량 비중(%)"] = (cluster_profile["words_seen_sum"] / user["words_see
n"].sum() * 100).round(1)
cluster_profile["복귀율(%)"] = (cluster_profile["return_rate"] * 100).round(1)
cluster_profile = cluster_profile.drop(columns=["words_seen_sum", "return_rate"]).roun
d(2)
print("\n[군집 프로필]")
print(cluster_profile)

# 4-6. 세그먼트 × 군집 교차표
cross = pd.crosstab(user["segment"], user["cluster"]).reindex(SEG_ORDER)
cross_pct = (cross.div(cross.sum(axis=1), axis=0) * 100).round(1)
print("\n[세그먼트 × 군집 인원]")
print(cross)
print("\n[세그먼트 × 군집 비중(%)]")
print(cross_pct)

# 4-7. ARI: 두 분류의 일치 정도 (1 = 완전 일치, 0 = 우연 수준)
ari = adjusted_rand_score(user["segment"], user["cluster"])
print(f"\nARI (세그먼트 vs 군집): {ari:.4f}")

# 5. 결과 저장 (utf-8-sig: 엑셀에서 한글 깨짐 방지)
summary.to_csv("segment_summary.csv", encoding="utf-8-sig")
k_results.to_csv("kmeans_k_compare.csv", index=False, encoding="utf-8-sig")
cluster_profile.to_csv("cluster_profile.csv", encoding="utf-8-sig")
cross.to_csv("segment_cluster_counts.csv", encoding="utf-8-sig")
cross_pct.to_csv("segment_cluster_pct.csv", encoding="utf-8-sig")
user.to_csv("user_rfm.csv", encoding="utf-8-sig")
```

▼ 지표 체계 설계

▼ 1️⃣ 가설 정리

가설 1. 학습 규칙성 → 리텐션

> 학습일 사이 간격이 규칙적인 사용자일수록 이후 학습을 지속할 가능성이 높을 것이다.

연결 지표: 규칙적 학습자 비율

가설 2. 성과 변화 → 리텐션

> 학습 초반 대비 후반 정답률이 상승한 사용자일수록 이후 학습을 지속할 가능성이 높을 것이다.

연결 지표: 학습 성과 개선율

가설 3. 복습 타이밍 → 리텐션

> 학습 빈도가 비슷하더라도, 적정 간격 안에 복습하는 비율이 높은 사용자일수록 이후 학습을 지속할 가능성이 높을 것이다.

연결 지표: 적정 간격 복습 비율

▼ 2️⃣ 북극성 지표(NSM) 1개 확정(선정 근거+계산 가능 여부)

- **정의:** 7일 중 4일 이상 학습 기록이 있는 사용자 수 (user_id별 서로 다른 학습 날짜 수 기준)
- **선정 근거:** 팀의 최종 목표는 '이탈 방지'이며, 세 가설 모두 사용자가 학습을 지속하게 만드는 요인을 다룬다. 단순 접속자 수는 한 번 들어왔다 떠난 사용자도 포함하므로, ~~학습이 습관으로 자리 잡은 사용자를~~ 주기적으로 학습을 이어가는 사용자를 세는 이 지표가 이탈 방지 목표를 가장 직접적으로 반영한다.
  - **4일을 기준으로 고른 이유**
    - 일주일의 과반
    - active_days 분포로 계산했을 때 아래와 같은 비율이 계산된다.

기준	충족 유저	비율
2일 이상	35,380	42.9%
3일 이상	18,246	22.1%
4일 이상	**9,834**	**11.9%**
5일 이상	5,086	6.2%
6일 이상	2,363	2.9%

    → 2일 이상은 거의 절반이 충족해서 “한두 번 와 본 사람”과 구분이 안 된다.

    → 6일 이상은 3% 미만이라 너무 소수이다.

    → **4일은 ‘꾸준한 소수(약 12%)’와 나머지를 가르면서, 늘릴 여지가 있는 규모로 볼 수 있다.**
- 한계: ‘학습일 수가 많을수록 복귀율이 높다’는 사실은 데이터에서 관찰된다. 때문에 NSM은 지속 학습과 함께 움직이는 지표로 볼 수 있다. 그렇다고 **‘학습일을 늘리면 복귀율이 오른다’는 인과 관계를 설명할 수는 없다.**

구간	복귀율	직전 대비 증가
1일	21.8%	
2일	39.0%	+17.2%p
3일	55.1%	+16.1%p
4일	69.7%	+14.6%p
5일	80.4%	+10.7%p
6일	88.3%	+7.9%p
7일	96.6%	+8.3%p

  *복귀=관측 기간 이후 4일(3/8~3/11) 중 하루라도 학습 기록이 있는 경우
- **계산 가능 여부:** user_id와 timestamp만으로 계산 가능하다. 단, 데이터 기간이 약 12일이라 7일이 온전히 포함된 첫 주(3/1~3/7)를 기준값으로 사용한다.

▼ 3️⃣ Input Metrics 3~5개 도출(NSM과의 연결 논리 포함), 지표 정의서 작성(계산식/사용 컬럼/집계 기준, 5주차 KPI 카드로 재사용)

1. 기반 지표 (Input Metrics 개수에 포함하지 않음)

지표명	산식	분모 기준	비고
주간 지속 학습 사용자 수 (NSM)	count(사용자 | 활동일 수 ≥ 4)	해당 없음 (비율은 주간 활성 학습자 수 기준)	NSM 그 자체
주간 활성 학습자 수	count(사용자 | 활동일 수 ≥ 1)	해당 없음	NSM 비율의 분모

2. Input Metrics (4개)

지표명	산식	분모 기준	기간	NSM과의 연결	가설과의 연결
규칙적 학습자 비율 (=학습 간격이 일	count(사용자 | 인접 세션 간 간격(시간)의 변동계수 < 1) ÷ count(계산 대상 사용자)	세션 3개 이상 사용자	관측 주간 7일	학습 간격이 일정한 사용자는 학습일이 꾸준히 쌓여 7일 중 4일에 도달하기 쉽다	가설 1

지표명	산식	분모 기준	기간	NSM과의 연결	가설과의 연결
정한 유저가 전체 대상의 몇 %인지)	변동계수 = 표본 표준편차 ÷ 평균, 변동계수가 1 미만이면 '규칙적'으로 봄				
학습 성과 개선율 (=시간이 지나면서 정답률이 오른 유저가 전체 대상의 몇 %인지)	count(사용자 | 후반 정답률 > 초반 정답률) ÷ count(계산 대상 사용자) 사용자별 정답률 = session_correct 합 ÷ session_seen 합 세션을 시간순으로 앞 절반/뒤 절반으로 분할, 세션 수가 홀수면 가운데 세션 제외)	세션 3개 이상 사용자	관측 주간 7일	성과가 오르면 학습을 이어갈 동기가 유지되어 학습일이 늘어난다	가설 2
적정 간격 복습 비율 (=이미 배운 단어를 12~48시간 뒤에 복습한 비율)	사용자별: delta가 12~48시간 (43,200~172,800초)인 복습 기록 수 ÷ 복습 기록 수 복습 기록 = history_seen ≥ 1인 행) 서비스 집계: 사용자별 값의 중앙값	사용자별: 복습 기록 수 서비스 집계: 세션 3개 이상 사용자	관측 주간 7일	제때 복습하면 학습 효과를 느껴 다음 학습으로 이어진다	가설 3
다음날 재학습률	count(활동일 d 중 d+1에도 활동) ÷ count(활동일 d)	사용자-활동일 조합 (d = 1~6일차)	관측 주간 7일	연속으로 학습할수록 7일 중 4일 달성이 쉬워진다.	가설 1 보조

- 학습 문항 수는 `session_seen`의 합계이고, 세션은 동일한 `(user_id, timestamp)`로 추정한다.
- 규칙성은 팀 문서 AARRR 부분에서 언급된 "delta 활용"과 달리 세션 간격으로 정의했다. `delta`가 단어별 경과 시간이라 유저의 일관성을 직접 반영하기 어렵기 때문이다.
- 기준값(변동계수 1, 12~48시간)은 분석자가 계산 전에 정한 값이며, 결과를 보고 조정하지 않는다.

3. 보류 지표

지표명	산식	분모 기준	기간	NSM과의 연결	가설과의 연결
첫 학습일 학습량	사용자별: 첫 활동일의 학습 문항 수서비스 집계: 사용자별 값의 중앙값	서비스 집계: 주간 활성 학습자	사용자별 첫 활동일 1일	첫날 경험이 좋으면 이후 학습일이 늘어 NSM 달성 가능성이 높아진다는 가정(그러나 검증 필요함)	새로운 가설 필요 ex. 첫 학습일 학습량이 많으면 리텐션이 높다
첫날 다회 세션 비율	count(첫 활동일 세션 수 ≥ 2인 사용자) ÷ count(신규 추정 사용자)	신규 추정 사용자	사용자별 첫 활동일 1일	위와 동일	새로운 가설 필요
첫날 새 단어 비율	사용자별: 첫 활동일 거의 새 단어의 학습 문항 수 ÷ 첫 활동일 학습 문항 수서비스 집계: 사용자별 값의 중앙값	사용자별: 첫 활동일 학습 문항 수서비스 집계: 신규 추정 사용자	사용자별 첫 활동일 1일	위와 동일	새로운 가설 필요
첫날 단어 당 반복 노출	사용자별: 첫 활동일 학습 문항 수 ÷ 첫 활동일 count(distinct `lexeme_id`) 서비스 집계: 사용자별 값의 중앙값	사용자별: 첫 활동일 고유 단어 수서비스 집계: 신규 추정 사용자	사용자별 첫 활동일 1일	위와 동일	새로운 가설 필요
활동일 당 세션 수	사용자별: 세션 수 ÷ 활동일 수서비스 집계: 사용자별 값의 중앙값	사용자별: 해당 사용자의 활동일 수 서비스 집계: 주간 활성 학습자	관측 주간 7일	활동일 당 세션 수는 하루 안의 학습 강도를 잴 뿐 학습일 수를 직접 늘리지 않음. 즉 이 지표는	연결되는 가설 없음

				NSM과 반대로 움직일 수도 있음. 우리가 설정한 NSM과 연결고리가 약함.	

- ❗논의 사항❗
  - 세분화 하면서 가설, NSM, Input Metrics가 연결되지 않는 부분이 있다고 생각했습니다..!
  - 우선 3주차에 확정한 가설 1~3의 연결 지표(규칙적 학습자 비율, 학습 성과 개선율, 적정 간격 복습 비율)가 Input Metrics에는 없었습니다. 따라서 제가 임의로 가설1~3과 연결되는 3개의 지표를 추가해 뒀는데, 이 부분 확인해 주시면 감사하겠습니다.
  - 첫날 지표 4개(첫 학습일 학습량, 첫날 다회 세션 비율, 첫날 새 단어 비율, 첫날 단어 당 반복 노출)는 저희가 정리한 가설 1~3과는 연결되는 부분이 없었습니다. 만약 이와 연결되는 가설을 하나 더 만든다면 AARRR의 활성화 부분과 연결되는 분석이 가능할 것 같습니다.
  - '활동일 당 세션 수'도 딱히 연결되는 가설이 없습니다.

▼ 4️⃣ AARRR 단계별 지표 매핑(측정 불가 단계는 사유 명시)

1) Acquisition (획득) — 측정 불가

- 지표: 신규 유입 사용자 수, 유입 채널별 사용자 수
- 사유: 광고, 검색, SNS, 추천 등 사용자의 유입 경로 및 가입 정보가 데이터에 포함되어 있지 않음

2) Activation (활성화) — 측정 가능

- **첫 학습일 학습량: 데이터 내 최초 관측 학습일의 학습량**
- **초기 학습 성과: 초기 학습 구간의 p_recall 등 학습 성과**
- **의미: 사용자가 서비스 이용 초기에 어떤 학습 경험을 했는지 측정**

3) Retention (유지) — 측정 가능 / 핵심

- **주간 지속 학습 사용자 수 (NSM): 7일 중 4일 이상 학습한 고유 사용자 수**
- **복습 규칙성: 사용자별 delta를 활용한 복습 간격의 규칙성**
- **학습 성과 개선율: 초기 대비 후기 학습 성과 변화**
- **의미: 사용자가 일회성 학습에 그치지 않고 지속적으로 학습하는지 측정**

4) Revenue (수익) — 측정 불가

- 지표: 유료 전환율, 구독 매출, ARPU 등
- 사유: 결제 여부, 구독 여부, 결제 금액 등 수익 관련 데이터가 없음

5) Referral (추천) — 측정 불가

- 지표: 친구 초대 수, 추천률, 공유율 등
- 사유: 친구 초대, 추천 코드, 콘텐츠 공유 등 추천 행동 관련 데이터가 없음

▼ 고객 세분화

▼ RFM 기준일 확정 및 5분위 스코어링

▼ RFM 기준일 확정

- RFM
  - R: 마지막 학습일로부터 경과일
  - F: 기간 내 학습한 날짜 수
  - M: 푼 문제 수
- 데이터 기간: 2013-02-28 18:28:01~2013-03-12 16:14:57
  - → 2/28과 3/12는 하루가 온전하지 않으므로 분석 기간에서 제외
  - → 7일이 온전히 포함된 03-01~03-07을 분석 기간으로 확정
  - → RFM 기준일: 2013-03-08

▼ 5분위 스코어링

: 유저를 지표 순으로 줄 세운 뒤, 인원이 똑같은 5개 그룹으로 잘라서 1~5점을 주는 것

▼ 유저별 집계

	`obs` (관측 기간 원본)	`user` (집계 결과)
1행의 의미	유저 × 레슨 × 단어	**유저 1명**
행 수	약 778만 (3/1~3/7)	82,467
열	`user_id`, `date`, `timestamp`, `session_seen`, `session_correct` 등	`first_active`, `last_active`, `active_days`, `words_seen`, `words_correct`, `sessions` 등

새로 만든 변수

변수	계산	의미	용도
`first_active`	`date`의 최솟값	관측 주 첫 학습일 (가입일 아님)	코호트 분석
`last_active`	`date`의 최댓값	마지막 학습일	R의 재료
`recency`	기준일(3/8) − `last_active`	마지막 학습 후 경과일 (1~7)	**R**
`active_days`	`date`의 고유 개수	학습한 날짜 수 (1~7)	**F**
`words_seen`	`session_seen` 합계	학습 문항 수	**M**
`words_correct`	`session_correct` 합계	정답 수	정답률 계산용
`accuracy`	`words_correct` ÷ `words_seen`	정답률	군집 분석
`sessions`	`timestamp`의 고유 개수	세션 수 (유저+timestamp로 추정)	군집 분석
`per_day`, `sessions_per_day`	각각 ÷ `active_days`	활동일당 문항 수 / 세션 수	군집 분석

집계 기준과 주의점

- 3/1~3/11 전체 유저는 109,504명인데, 그중 **27,037명은 3/8~3/11에만 나타나서** 관측 기간 집계에서 제외됨. RFM 대상은 "관측 주에 학습 기록이 있는 유저".
- `active_days`는 `count`(행 수)가 아니라 `nunique`(고유 날짜 수)로 셈. 하루에 단어를 많이 학습해도 학습한 날은 1일이기 때문.
- `sessions`는 데이터에 세션 ID가 없어서 같은 `(user_id, timestamp)`를 한 레슨으로 보고 추정한 값.

- `first_active`는 관측 주(3/1~3/7) 안에서의 첫 학습일. 데이터가 2/28 저녁부터 시작하므로 가입일로 해석하지 않음.
- 원본 `df`는 3/1~3/11 전체를 그대로 두어 3/8~3/11를 세그먼트 검증에 쓸 수 있도록 함.

▼ R: 마지막 학습일로부터 경과일

recency	유저 수	비율
1 (3/7 학습)	23,798	28.9%
2	15,069	18.3%
3	11,277	13.7%
4	9,129	11.1%
5	8,283	10.0%
6	7,269	8.8%
7 (3/1이 마지막)	7,642	9.3%

- R은 값 종류가 7개뿐이라 5분위로 나누면 같은 날 학습한 유저가 서로 다른 점수를 받게 됨. 그래서 recency 값 단위로 묶어 5개 구간을 만들었음. 마지막 구간(recency 7일, 9.3%)을 제외하면 각 구간이 18~29%로 비슷함.

R 점수	recency	유저 수	의미	비율
5	1일	23,798	3/7에 학습 (마지막 날)	28.9%
4	2일	15,069	3/6에 학습	18.3%
3	3~4일	20,406	3/4~3/5에 학습	24.7%
2	5~6일	15,552	3/2~3/3에 학습	18.9%
1	7일	7,642	3/1이 마지막	9.3%

▼ F: 기간 내 학습한 날짜 수

F 점수	active_days	유저 수	비율
1	1일	47,087	57.1%
2	2일	17,134	20.8%
3	3일	8,412	10.2%
4	4일	4,748	5.8%
5	5~7일	5,086	6.2%

- 5분위 스코어링을 하지 않은 이유: F는 값이 1~7일로 종류가 적고 57.1%가 1일에 몰려 있음. 이 상태에서 인원이 같도록 5분위로 나누면 똑같이 하루만 학습한 유저가 서로 다른 점수를 받게 됨. 같은 행동인데 점수가 달라지는 것.
- 따라서 경계를 직접 지정함. 기준은 NSM(7일 중 4일 이상 학습)을 적용함.
- 결과적으로 점수별 비율은 균등하지 않게 됨.

▼ M: 푼 문제 수

M 점수	문항 수	유저 수	비율
1	1~24	16,877	20.5%
2	25~53	16,482	20.0%
3	54~108	16,244	19.7%
4	109~239	16,406	19.9%
5	240 이상	16,458	20.0%

- M은 값이 연속적이어서 5분위(`pd.qcut`)로 나누었음. **[수정]** 기존의 `rank(method="first")`를 빼서 **같은 문항 수는 같은 점수**를 받도록 함. 경계값과 같은 유저는 아래 구간에 포함(예: 108문항은 3점, 109문항부터 4점).

- 그래서 점수별 인원이 정확히 20%씩은 아님(19.7~20.5%). 기존 방식에서는 경계값 동점자가 순서에 따라 서로 다른 점수로 갈렸음.

경계	동점 유저	전체 대비	현재 처리	세그먼트 영향
24문항 (1점/2점)	638명	0.8%	모두 1점	없음 (규칙에서 M≥4만 사용)
53문항 (2점/3점)	436명	0.5%	모두 2점	없음 (규칙에서 M≥4만 사용)
108문항 (3점/4점)	236명	0.3%	모두 3점	모두 3점 → 멈춤-몰입형(M≥4) 대상에서 빠짐
239문항 (4점/5점)	85명	0.1%	모두 4점	없음 (규칙에서 M≥4만 사용)

- 이 수정으로 M 점수가 바뀐 유저는 914명이며, 그중 56명이 멈춤-몰입형에서 멈춤-저활동형으로 이동함.

💬 RFM 요약

지표	방식	이유
R	구간 지정	값이 7종류뿐이라 5분위 불가능
F	구간 지정 (NSM 경계 4일 반영)	57%가 1일에 몰려서 5분위 불가능
M	5분위 (같은 값은 같은 점수)	값이 연속적이라 5분위 가능. 동점은 같은 점수로 처리

▼ 세그먼트 규칙 정의(6개 그룹)

: R, F, M의 점수 조합이 너무 많아서 그대로는 쓸 수가 없음. R, F, M이 각각 5가지니까 조합이 5×5×5 = 125가지나 되는데, 125개 그룹을 하나씩 해석하고 마케팅 액션을 짜는 건 불가능함. 그래서 비슷한 점수 조합을 묶어서 6개의 의미 있는 그룹으로 줄이는 게 세그먼트 규칙.

1. 설계 목적

- 팀의 목표인 이탈 방지에 맞춰, 지속 학습 중인 유저와 이탈 위험이 있는 유저를 구분하고 세그먼트별로 다른 후속 액션을 줄 수 있도록 한다.

2. 입력과 기준

- 관측 기간 3/1~3/7(NSM 정의의 7일이 온전히 포함된 첫 주), RFM 기준일 3/8
- R·F·M 점수는 모두 5점이 가장 좋은 방향
- 대상: 관측 기간에 학습 기록이 있는 82,467명

3. 설계 원칙

1. 최근성(R)으로 최근 활동 여부를 먼저 나눈다. R≥4(최근 2일 내 학습)와 R≤3(마지막 학습 후 3일 이상 경과. 즉, 마지막 학습이 3/5 이전)
2. 지속성(F)으로 습관 정도를 나눈다. 경계는 NSM 기준인 4일을 따른다.
3. 학습량(M)은 F로 구분이 어려운 멈춤 유저를 세분화하는 데에만 사용한다. 멈춤 유저는 대부분 학습일이 1~2일이라 F만으로는 차이가 드러나지 않기 때문이다.
4. 규칙은 위에서 아래로 순서대로 적용하고, 처음 충족한 하나의 세그먼트에만 배정한다.
5. 세그먼트는 6개로 하고, 각 그룹은 전체의 4% 이상이 되도록 한다. 서로 다른 액션을 줄 수 있는 단위여야 한다.
6. 이름 체계: 위 3개는 최근 활동 중(R≥4), 아래 3개는 최근 이틀 미학습(R≤3)으로 이름 앞에 "멈춤-"을 붙인다.

4. 규칙(적용 순서)

순서	세그먼트	조건	기존 이름
1	꾸준형	R≥4 & F≥4	핵심 학습자
2	습관 형성형	R≥4 & F=2~3	습관 형성 중
3	최근 단발형	R≥4 & F=1	최근 1일 학습
4	멈춤-꾸준형	R≤3 & F≥3	중단 위험
5	멈춤-몰입형	R≤3 & M≥4	몰입 후 이탈

순서	세그먼트	조건	기존 이름
6	멈춤-저활동형	위 조건에 모두 해당하지 않는 나머지 (실제로 R≤3 & F≤2 & M≤3)	초반 이탈 + 중반 이탈

- **[수정] 초반 이탈(R=1)과 중반 이탈을 멈춤-저활동형으로 합침.** 두 그룹은 마지막 학습일만 다르고 액션이 같으며, 관측 기간이 짧아 복귀율 차이를 그룹의 성향 차이와 쉰 기간 차이로 분리할 수 없기 때문(6. 검증 및 한계 참고).
- 규칙 점검: 모든 유저가 6개 중 하나에 배정됨. 나머지 그룹(멈춤-저활동형)에는 R 1~3점·F 1~2점·M 1~3점 조합만 들어감(15개 조합).
- 임계값은 분석자 판단.

기준	근거
F≥4	팀 NSM 정의(7일 중 4일 이상 학습)
F=2~3	NSM 직전 단계로 해석 (분석자 판단)
R≥4 (최근 2일)	R 분포에서 상위 두 구간. 이틀 이상 미접속을 멈춤 신호로 봄 (분석자 판단)
멈춤-꾸준형 F≥3	NSM에 근접한 학습 이력 (분석자 판단)
M≥4 (109문항 이상)	학습량 상위 40% (분석자 판단)

5. 세그먼트 규칙 적용 결과

#	세그먼트	규칙	의미	인원	비율
1	꾸준형	최근 2일 내 학습 & 학습일 4일 이상	NSM 충족, 지속 학습 중	8,882	10.8%
2	습관 형성형	최근 2일 내 학습 & 학습일 2~3일	반복 학습 중, 지속 학습자 후보	14,583	17.7%
3	최근 단발형	최근 2일 내 학습 & 학습일 1일	신규/복귀 추정	15,402	18.7%
4	멈춤-꾸준형	마지막 학습 후 3일 이상 경과 & 학습일 3일 이상	여러 날 학습하다 멈춤	3,627	4.4%
5	멈춤-몰입형	마지막 학습 후 3일 이상 경과 & 학습일 2일 이하 & 109문항 이상	짧게 많이 풀고 멈춤	9,303	11.3%
6	멈춤-저활동형	마지막 학습 후 3일 이상 경과 & 학습일 2일 이하 & 108문항 이하	가볍게 학습 후 멈춤	30,670	37.2%

- 기존 7개 그룹과 비교: 위 4개 그룹의 인원은 같음. 멈춤-몰입형은 M 점수 수정으로 56명 줄었고(9,359명→9,303명), 멈춤-저활동형은 기존 초반 이탈(6,350명)+중반 이탈(24,264명)에 이 56명이 더해진 30,670명.

세그먼트별 평균 프로필

세그먼트	평균 recency	평균 학습일 수	문항 수 (중앙값)	평균 정답률
꾸준형	1.24	4.91	435	91%
습관 형성형	1.41	2.39	151	90%
최근 단발형	1.45	1.00	43	89%
멈춤-꾸준형	3.54	3.31	242	90%
멈춤-몰입형	4.73	1.46	177	90%
멈춤-저활동형	4.95	1.13	36	89%

6. 검증 및 한계

- 규칙 정의에 쓰지 않은 3/8~3/11의 세그먼트별 복귀율이 80.3%~17.5%로 뚜렷한 차이를 보임. 다만 세그먼트가 학습 활동으로 정의되어 있어 이 결과는 분류의 타당성 확인이며, 개입 효과를 의미하지 않음.(활동이 많은 그룹이 이후에도 활동이 많은 건 어느 정도 당연함. '학습 알림' 같은 개입 없이도 나올 수 있는 결과)

세그먼트	복귀율
꾸준형	80.3%

세그먼트	복귀율
습관 형성형	52.2%
멈춤-꾸준형	45.7%
최근 단발형	32.5%
멈춤-몰입형	26.4%
멈춤-저활동형	17.5%

- 관측 기간(7일)과 복귀 확인 기간(4일)이 짧아 장기 이탈 여부는 판단할 수 없음. 멈춤-꾸준형도 4일 안에 45.7%가 돌아옴.
- 기존의 초반 이탈(3/1이 마지막, 복귀율 13.6%)과 중반 이탈(3/2~3/5가 마지막, 18.6%)의 차이에는 마지막 학습 후 경과 시간의 영향이 섞여 있었음. 쉰 기간이 짧을수록 돌아오기 쉽기 때문에, 두 그룹의 차이를 그룹의 성격과 쉰 기간으로 분리할 수 없음. → 두 그룹을 멈춤-저활동형으로 합친 이유.

	효과 ① 그룹의 성격	효과 ② 쉰 기간
내용	두 그룹은 원래 다른 유형의 유저라서 복귀 성향이 다르다	마지막 학습 후 지난 시간이 달라서 복귀 가능성이 다르다
기존 초반 이탈	3/1에 학습	3/8까지 **7일** 쉼
기존 중반 이탈	3/2~3/5에 학습	3/8까지 **3~6일** 쉼

▼ 세그먼트 요약표 작성(고객 수, 고객 비중, 매출 비중)

- '매출 비중' 자리에는 '학습량 비중(학습 문항 수 기준)'을 넣었고, 매출이 아니라 서비스 이용 기여도의 대리 지표임
- '집중도'는 학습량 비중÷고객 비중. 1보다 크면 인원 대비 학습량 기여가 큰 그룹

세그먼트	고객 수	고객 비중	학습량 비중	인당 문항 수	집중도	4일 복귀율
꾸준형	8,882	10.8%	38.5%	611	3.56	80.3%
습관 형성형	14,583	17.7%	22.0%	212	1.24	52.2%
최근 단발형	15,402	18.7%	7.5%	69	0.40	32.5%
멈춤-꾸준형	3,627	4.4%	8.3%	321	1.89	45.7%
멈춤-몰입형	9,303	11.3%	14.9%	226	1.32	26.4%
멈춤-저활동형	30,670	37.2%	8.8%	40	0.24	17.5%

분석

- **학습량이 소수 그룹에 크게 쏠려 있음**
  - 꾸준형은 고객의 10.8%인데 학습량의 38.5%를 차지. 인원 대비 3.6배. 꾸준형, 습관 형성형, 멈춤-몰입형 세 그룹(고객의 39.7%)이 학습량의 75.4%를 만듦. 반대로 최근 단발형, 멈춤-저활동형 두 그룹은 고객의 55.9%인데 학습량은 16.3%임.
- **멈춤-꾸준형 그룹은 작지만 무게가 있음**
  - 인원은 4.4%인데 학습량은 8.3%(집중도 1.89)이고, 인당 문항 수(321)가 습관 형성형(212)보다 높음. 3일 이상 안 온 유저이면서 과거 기여가 큰 그룹이라 눈여겨볼 만함.
- **멈춘 그룹 쪽에도 학습량이 많이 있음**
  - 멈춤-꾸준형과 멈춤-몰입형을 합치면 고객의 15.7%, 학습량의 23.2%임. 마지막 학습 후 3일 이상 경과한 유저인데도 복귀율이 각각 45.7%, 26.4%라서, 이들이 떠나면 서비스 이용량이 크게 줄 수 있음.
  - 멈춤-저활동형은 고객의 37.2%로 가장 큰 그룹이지만 학습량은 8.8%, 복귀율은 17.5%로 가장 낮음.

▼ 세그먼트별 마케팅 액션 제안(대상 규모, 액션, 움직일 지표)

우선순위	세그먼트	진단	액션안	연결 가설	성공 지표
1	습관 형성형	NSM 4일에 한 걸음 모자람, 복귀율 52%로 이미 반응이 있음	주간 "4일 학습" 목표와 진행률 표시, 간격이 벌어지기 전 알림	가설 1(규칙성), 가설 3(복습 타이밍)	4일 이상 학습 전환율

우선순위	세그먼트	진단	액션안	연결 가설	성공 지표
2	멈춤-꾸준형	소수지만 인당 학습량 높음, 마지막 학습 후 3일 이상 경과	"잊기 전에 복습" 알림	가설 3(복습 타이밍)	4일 내 복귀율
2	멈춤-몰입형	짧게 많이 풀고 멈춤, 복귀율 26%	몰아서 풀기 대신 "매일 소량" 목표 제안	가설 1(규칙성)	재학습일 수
3	꾸준형	학습량 38.5%, 복귀율 80%	평소 학습 시간대에 맞춘 알림, 연속 학습 보상(과한 알림은 피함)	가설 1(규칙성)	NSM 유지율
4	최근 단발형	규모는 크지만 인당 학습량 낮음	첫 학습 직후 성취 피드백, 다음 날 이어서 하기 안내	가설 2(성과 변화)	다음 날 복귀율
5	멈춤-저활동형	규모 최대(37.2%), 학습량 낮고 복귀율 최저	저비용 일괄 리마인드	연결 약함	알림 반응률

우선순위 설정 기준

기준	질문
규모	액션을 할 만큼 인원이 되는가
학습량 비중, 집중도	서비스 이용에서 얼마나 큰 몫인가
NSM과의 거리, 복귀율	조금만 움직이면 NSM에 닿는가, 이미 반응이 있는가

- **단, 액션의 효과는 해당 데이터로 확인할 수 없음.**

▼ (선택) K-means 군집 결과와 RFM 세그먼트 비교

1. 방법

- 입력 변수: 세그먼트와 같은 재료인 `recency`, `active_days`, `words_seen` 원값. 오른쪽으로 긴 분포를 log1p로 완화한 뒤 표준화(평균 0, 표준편차 1).
- K=3~6을 비교(`n_init=20`, `random_state=42`), 실루엣 점수(표본 5,000명)가 가장 높은 K를 선택. 군집 번호는 평균 학습일 수가 낮은 군집부터 C1, C2, ...

2. K별 비교

K	실루엣	inertia
3	**0.3735**	94,617.2
4	0.3357	75,612.4
5	0.3188	62,879.8
6	0.3370	53,679.9

- K=3의 실루엣이 0.3735로 가장 높아 K=3을 선택. 0.37은 군집이 어느 정도 나뉘지만 경계가 겹치는 수준임.

3. 군집 프로필

군집	해석	인원	고객 비중	recency 중앙값	학습일 수 중앙값	문항 수 중앙값	학습량 비중	복귀율
C1	멈춤·저활동	38,552	46.7%	5	1	46	19.7%	18.9%
C2	최근 1일 학습	20,781	25.2%	1	1	48	10.1%	35.1%
C3	여러 날 활발 학습	23,134	28.1%	1	3	295	70.2%	63.3%

4. 세그먼트 × 군집 비중(%)

세그먼트	C1	C2	C3	인원
꾸준형	0.0	0.1	99.9	8,882
습관 형성형	0.0	37.0	63.0	14,583

세그먼트	C1	C2	C3	인원
최근 단발형	0.0	99.9	0.1	15,402
멈춤-꾸준형	6.2	0.0	93.8	3,627
멈춤-몰입형	82.3	0.0	17.7	9,303
멈춤-저활동형	100.0	0.0	0.0	30,670

- ARI(두 분류의 일치 정도, 1=완전 일치, 0=우연 수준) = **0.6065**. 상당히 일치하지만 같지는 않음. ARI는 정확도가 아님.

5. 해석

- 군집은 세그먼트를 크게 세 덩어리로 묶은 형태임. 꾸준형·멈춤-꾸준형은 대부분 C3, 최근 단발형은 C2, 멈춤-저활동형은 전부 C1.
- 갈리는 그룹은 둘: **습관 형성형**은 C2 37.0% / C3 63.0%, **멈춤-몰입형**은 C1 82.3% / C3 17.7%. 학습량이 군집 경계에 걸쳐 있는 그룹이라는 뜻.
- 군집은 최근성(R)과 지속성(F)의 차이를 세그먼트처럼 세밀하게 나누지 못함(예: C3에 꾸준형과 멈춤-꾸준형이 함께 들어감). 액션 단위로는 해석이 쉬운 6개 규칙 세그먼트를 쓰고, 군집 결과는 세그먼트 구분이 데이터 구조와 크게 어긋나지 않는다는 보조 근거로 사용한다.