코호트분석 통합본 수정판

이번 수정에서 바뀐 점

1. **이탈 곡선 추가(⑥)** 마지막 학습일을 기준으로 맞춰, 쉰 날 수에 따라 돌아올 가능성이 어떻게 줄어드는지 새로 분석했다.
2. **"다음 날" 해석 수정(④)** 이어서 학습한 사람이 조금 더 이어지는 것은 맞지만, 그보다 "다시 돌아오는지" 여부의 차이가 훨씬 크다는 쪽으로 결론을 고쳤다.
3. **주말 표시(①, ③)** 후속 4일 중 3/9와 3/10은 주말이다. 날짜별 표와 차트에 요일을 붙이고, 주말 하락을 따로 설명했다.
4. **이탈 곡선 관측 기간 통일(⑥, 10/20)** 쉰 날마다 그 시점부터 4일을 보도록 다시 계산했다. 곡선에 이틀째 꺾이는 점이 없어, "이틀 미학습 = 멈춤"은 운영상 정한 경계로 고쳐 적었다.

부록의 지표와 세그먼트별 액션은 노션 확정본(듀오링고 이탈 방지 분석)과 같게 맞췄다. 차트는 핵심 대상만 색으로, 나머지는 회색으로 표시했다.

📌 코호트 분석 설계

> **기준 주간의 학습 행동으로 사용자를 고정하고, 이후 4일 동안 다시 학습하는지를 추적한다.** 여기에 마지막 학습일을 기준으로 다시 정렬한 이탈 곡선(⑥)을 더해, 언제 개입해야 하는지를 본다.

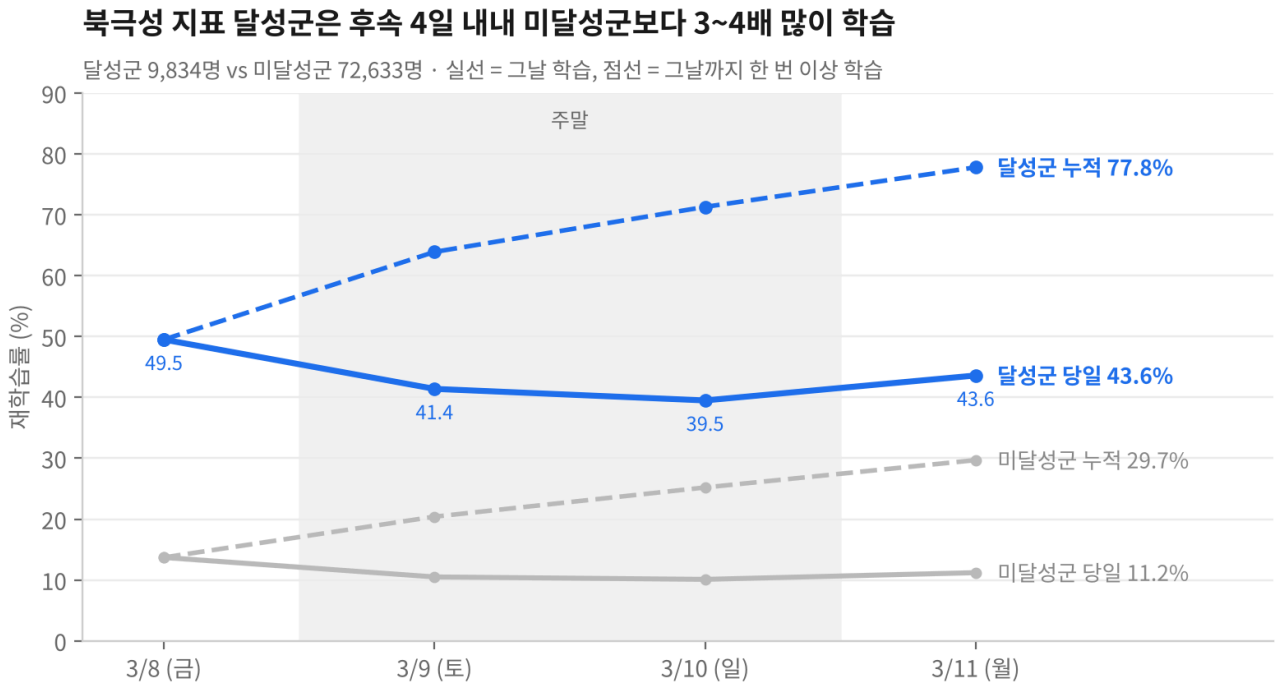
- 데이터: Duolingo Spaced Repetition Dataset. 12개 열이 모두 같은 중복 81행을 지우고, 하루가 온전한 3/1~3/11(UTC)만 쓴다.
- 기준 주간: 3/1(금)~3/7(목). 이 주에 한 번이라도 학습한 **82,467명**이 대상이다.
- 후속 4일: 3/8(금)~3/11(월). **3/9(토)와 3/10(일)이 주말**이다. 후속 결과로 코호트를 다시 나누지 않는다.
- 코호트 종류
    1. 북극성 지표 달성 여부: 기준 주간 4일 이상(달성) / 1~3일(미달성)
    2. 학습 일수: 기준 주간 학습일 1~7일
    3. 세그먼트: 노션 확정본의 6개 세그먼트
    4. 첫 후속 학습일: 후속 4일 중 처음 다시 학습한 날
    5. 관측 주 첫 학습일: 기준 주간에 처음 학습한 날 (가입일 아님)
    6. **마지막 학습일 기준 (신규)**: 학습한 날을 기준으로, 며칠을 쉬었는지에 따라 다시 돌아오는 비율

지표	정의
당일 재학습률	그날 학습한 사용자 ÷ 코호트 전체
누적 재학습률	그날까지 한 번 이상 학습한 사용자 ÷ 코호트 전체
복귀율	후속 4일 중 하루 이상 학습 ÷ 코호트 전체
반복 복귀율	후속 4일 중 서로 다른 이틀 이상 학습 ÷ 코호트 전체
쉰 날 수별 복귀율 (신규)	학습한 뒤 쉬는 날 수별로, 그때까지 안 온 사람 중 다음 날 다시 학습한 비율과 그 시점부터 4일 안에 다시 학습한 비율

- 분모는 처음 정한 코호트 전체 인원이다. 후속 학습이 없는 사용자도 분모에 남긴다.
- 관측 기간(3/11)을 넘는 날짜는 0%가 아니라 "미관측"으로 둔다.

📊 ① 북극성 지표 달성 여부 코호트

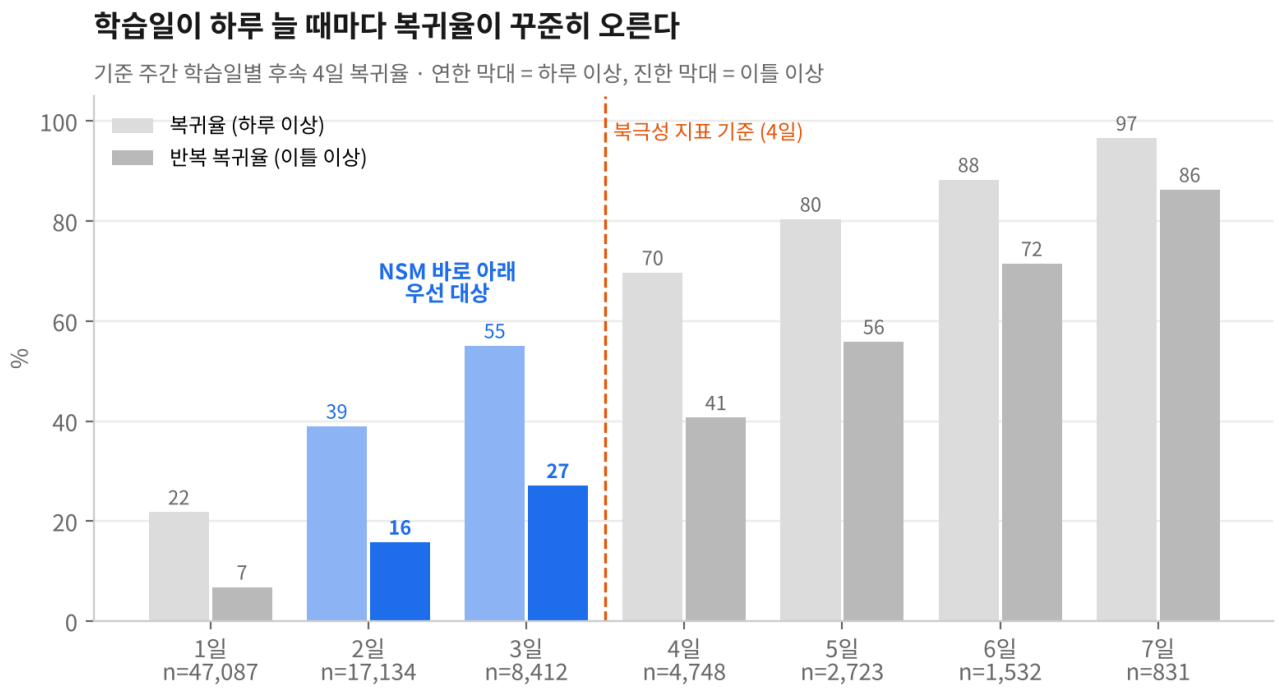
구분	사용자 수	비율	복귀율	반복 복귀율
달성군 (4~7일)	9,834	11.9%	**77.8%**	**53.5%**
미달성군 (1~3일)	72,633	88.1%	29.7%	11.3%
합계	82,467	100%	35.5%	16.3%



집단	3/8 (금)	3/9 (토)	3/10 (일)	3/11 (월)
달성군 당일	49.5%	41.4%	39.5%	43.6%
달성군 누적	49.5%	63.9%	71.3%	77.8%
미달성군 당일	13.7%	10.5%	10.1%	11.2%
미달성군 누적	13.7%	20.4%	25.2%	29.7%

- 달성군은 모든 날짜에 미달성군보다 3~4배 많이 학습했다. 3/11까지 복귀율은 77.8% 대 29.7%다.
- 두 집단 모두 주말(3/9, 3/10)에 당일 학습률이 낮아졌다가 월요일(3/11)에 다시 오른다. 날짜별 하락의 일부는 요일 효과다.
- 북극성 지표 달성 자체가 높은 복귀율을 만들었다고 단정할 수는 없다.

📊 ② 학습 일수별 코호트



학습 일수	코호트 규모	복귀율	반복 복귀율
1일	47,087	21.8%	6.8%
2일	17,134	39.0%	15.8%
3일	8,412	55.1%	27.1%
4일	4,748	69.7%	40.7%
5일	2,723	80.4%	55.9%
6일	1,532	88.3%	71.5%
7일	831	96.6%	86.3%
합계	82,467	35.5%	16.3%

- 학습일이 늘수록 복귀율이 단계적으로 높아진다. 1일 21.8%, 4일 69.7%, 7일 96.6%.
- 가장 크게 오르는 구간은 1일에서 2일(+17.2%p)이다. 4일에서 갑자기 바뀌기보다 학습일에 따라 꾸준히 오른다.
- 1일 학습자가 47,087명(57.1%)으로 가장 많다.

마지막 학습일을 3/7로 맞춘 비교

학습 일수	1일	2일	3일	4일	5일	6일	7일
반복 복귀율	15.4%	24.5%	34.9%	45.8%	58.5%	73.7%	86.3%
인원	8,444	5,063	3,538	2,719	1,920	1,283	831

- 마지막 학습일을 맞춰도 학습 일수에 따른 차이가 유지된다.

학습 일수와 학습량 교차 분석

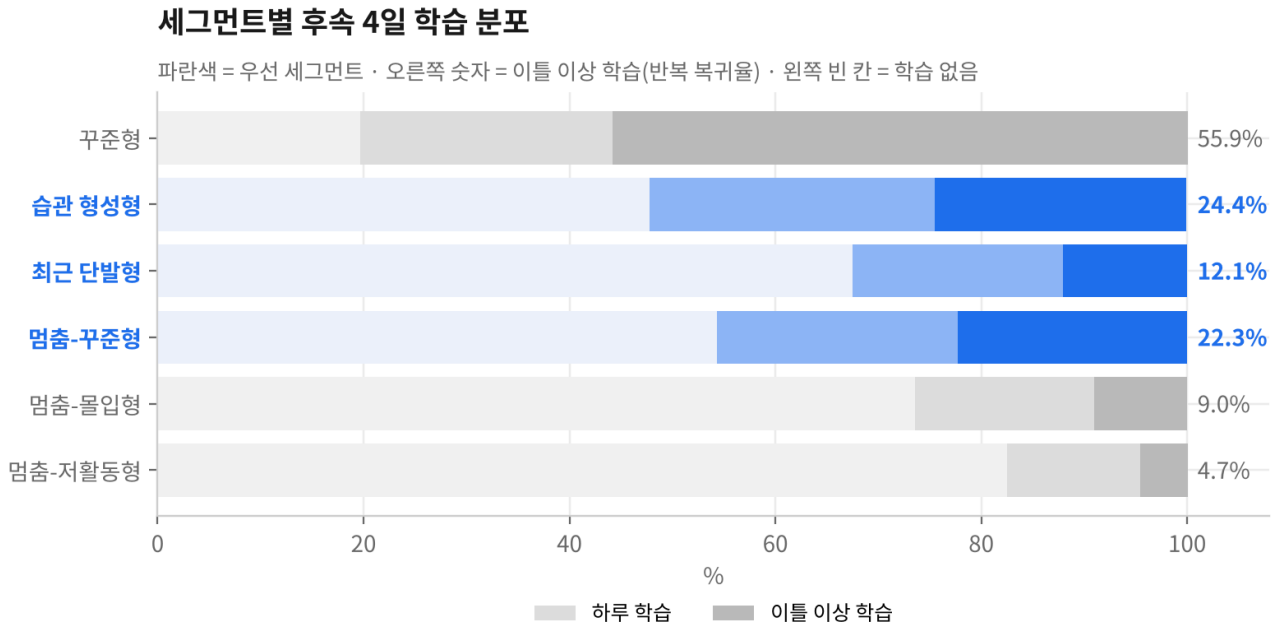
- 학습량은 기준 주간에 푼 문항 수이며, 중앙값 75문항으로 나눴다.

집단	학습 일수	학습량	사용자 수	복귀율	반복 복귀율
A	1~3일	75문항 미만	40,825	22.2%	6.9%
B	1~3일	75문항 이상	31,808	39.4%	17.0%
C	4~7일	75문항 미만	188	61.7%	32.4%
D	4~7일	75문항 이상	9,646	78.1%	53.9%

학습 일수	75문항 미만	75문항 이상	차이
1일	5.7% · n=34,642	9.9% · n=12,445	+4.2%p
2일	12.4% · n=5,328	17.4% · n=11,806	+5.0%p
3일	18.5% · n=855	28.0% · n=7,557	+9.5%p
4일 이상	32.4% · n=188	53.9% · n=9,646	+21.5%p

- 반복 복귀율 기준. 학습 일수가 같으면 학습량이 많은 쪽이 높지만, 1~3일 구간의 차이(+4~10%p)는 학습 일수에 따른 차이보다 작다. C 집단은 188명으로 작아 해석에 주의한다.
- 학습량은 학습 일수를 보완하는 요인이며, 학습 일수의 차이를 대신 설명하지는 못한다.

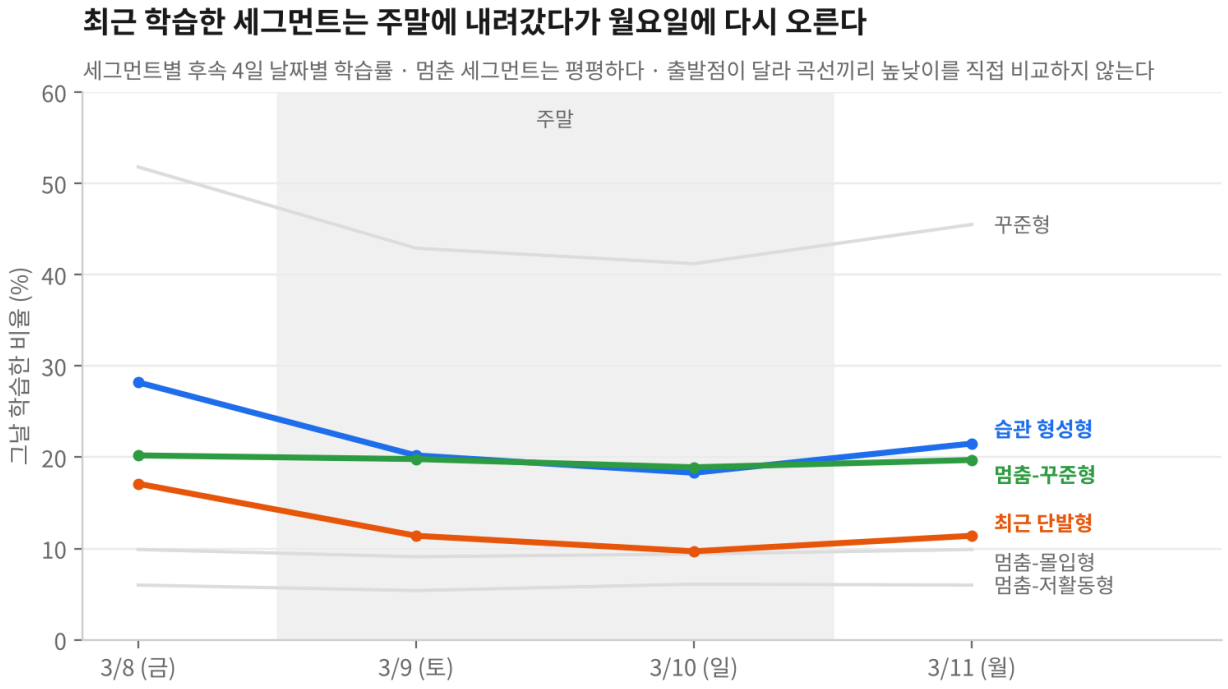
🔍 ③ 세그먼트별 코호트



세그먼트	인원	3/8 (금)	3/9 (토)	3/10 (일)	3/11 (월)	복귀율	반복 복귀율
꾸준형	8,882	51.8	42.9	41.2	45.5	80.3%	**55.9%**
습관 형성형	14,583	28.2	20.2	18.3	21.5	52.2%	**24.4%**
최근 단발형	15,402	17.1	11.4	9.7	11.4	32.5%	**12.1%**
멈춤-꾸준형	3,627	20.2	19.8	18.9	19.7	45.7%	**22.3%**
멈춤-몰입형	9,303	9.9	9.1	9.4	9.9	26.4%	**9.0%**
멈춤-저활동형	30,670	6.0	5.4	6.1	6.0	17.5%	**4.7%**

- 날짜 칸은 당일 학습률(%)이다. 반복 복귀율이 꾸준형 55.9%부터 멈춤-저활동형 4.7%까지 크게 차이 난다.
- 세그먼트는 기준 주간 행동으로 정의했으므로 이 차이는 분류가 이후 행동을 구분한다는 확인이며, 개입 효과를 뜻하지 않는다.

날짜별 흐름과 주말



- 최근에 학습한 세그먼트(꾸준형, 습관 형성형, 최근 단발형)는 주말에 내려갔다가 월요일에 다시 오른다. 습관 형성형은 28.2% → 18.3% → 21.5%.
- 멈춘 세그먼트(멈춤-꾸준형, 멈춤-몰입형, 멈춤-저활동형)는 4일 내내 거의 평평하다.
- 3/8은 세그먼트마다 마지막 학습 후 지난 날이 다르다. 최근 단발형에게는 다음 날이지만 멈춤-꾸준형에게는 사흘 이상 지난 날이다. 그래서 곡선의 높낮이를 세그먼트끼리 직접 비교하지 않고, 마지막 학습일을 맞춘 비교(아래)와 ⑥을 쓴다.

습관 형성형의 날짜별 재학습

날짜	3/8 (금)	3/9 (토)	3/10 (일)	3/11 (월)
당일 재학습률	28.2%	20.2%	18.3%	21.5%
누적 재학습률	28.2%	38.9%	45.6%	52.2%

- 분모 14,583명. 4일 동안 52.2%가 다시 학습했지만 이틀 이상은 24.4%에 그친다. 한 번 돌아온 학습이 여러 날로 충분히 이어지지 않는다.

마지막 학습일을 맞춘 세그먼트 비교

마지막 학습	꾸준형	습관 형성형	최근 단발형
3/7 (1일 전)	59.7% · n=6,753	28.8% · n=8,601	15.4% · n=8,444
3/6 (2일 전)	43.8% · n=2,129	18.2% · n=5,982	8.1% · n=6,958

- 반복 복귀율 기준. 마지막 학습일이 같아도 세그먼트 간 차이가 유지된다. 같은 세그먼트 안에서도 하루 더 쉰 쪽(3/6)이 크게 낮다.

2~3일 학습자 안의 차이

구분	인원	반복 복귀율
2~3일 학습자 전체	25,546	19.5%
└ 최근 이틀 안에 학습 (습관 형성형)	14,583	**24.4%**
└ 마지막 학습이 3/5 이전 (멈춤 계열)	10,963	13.0%

- 북극성 지표 바로 아래 단계(2~3일)라도 최근에 학습했는지에 따라 반복 복귀율이 두 배 가까이 다르다.

📅 ④ 첫 후속 학습일 코호트

> 후속 4일 중 처음 다시 학습한 날을 D0로 맞추고, 그 뒤 날짜별로 학습했는지를 본다. D0 = 100%는 정의상 값이고, 3/11 이후는 미관측이다.

전체

첫 후속 학습일	인원	D0	D1	D2	D3
3/8 (금)	14,846	100%	36.9%	33.5%	37.2%
3/9 (토)	6,241	100%	33.0%	29.3%	미관측
3/10 (일)	4,227	100%	27.1%	미관측	미관측
3/11 (월)	3,926	100%	미관측	미관측	미관측

습관 형성형

첫 후속 학습일	인원	D0	D1	D2	D3
3/8 (금)	4,106	100%	33.3%	29.1%	35.1%
3/9 (토)	1,573	100%	31.8%	29.6%	미관측
3/10 (일)	971	100%	27.5%	미관측	미관측
3/11 (월)	958	100%	미관측	미관측	미관측

- 돌아온 뒤 이틀(D1, D2) 안에 또 학습한 비율: 전체 50.0% (21,087명 중 10,538명), 습관 형성형 47.6%. 돌아온 사람의 절반은 그 뒤 이틀 안에 다시 끊긴다.

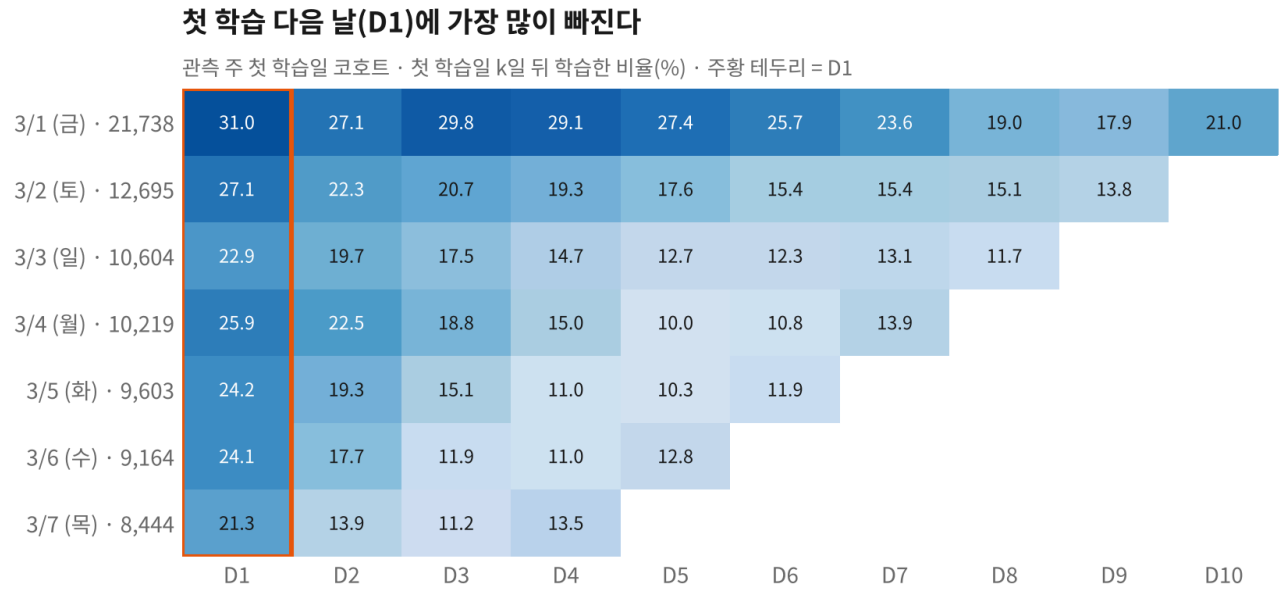
- 행끼리 비교할 때 주의: D1은 3/8 행이 토요일, 3/9 행이 일요일, 3/10 행이 월요일이다. 행 사이의 차이에는 요일 효과와 "늦게 돌아온 사람일수록 원래 덜 오는 사람"이라는 차이가 섞여 있어, 늦게 돌아온 사람이 덜 이어진다는 결론으로 쓰지 않는다.

이어서 학습 vs 하루 쉬고 재개 (3/8에 돌아온 사람)

세그먼트	3/7에도 학습 (이어서)	3/6이 마지막 (하루 쉬고 재개)	차이
꾸준형	71.8% · n=3,759	65.5% · n=843	**+6.3%p** (±3.5)
습관 형성형	49.7% · n=2,799	42.0% · n=1,307	**+7.7%p** (±3.3)
최근 단발형	40.1% · n=1,795	34.1% · n=841	**+6.0%p** (±3.9)

- 결과는 3/9와 3/10 중 추가로 학습한 비율이다. 세 세그먼트 모두 이어서 학습한 쪽이 6~8%p 더 이어졌다.
- **수정된 해석**: 이 차이는 실제로 있지만 크기가 작다. ⑥에서 보듯 학습 다음 날 돌아올 확률은 34.7%인데, 하루를 쉬고 나면 19.9%로 떨어진다. 즉 "이어서 했는지"보다 **"쉬는 날이 늘기 전에 다시 돌아오는지"**가 훨씬 큰 갈림길이다. 개입의 목표는 쉬는 날이 쌓이기 전에, 가능하면 학습한 다음 날 다시 학습하게 만드는 것이다.
- 다음 두 날이 모두 주말인 같은 날짜끼리의 관찰 비교이며, 재개 자체의 인과 효과는 아니다.

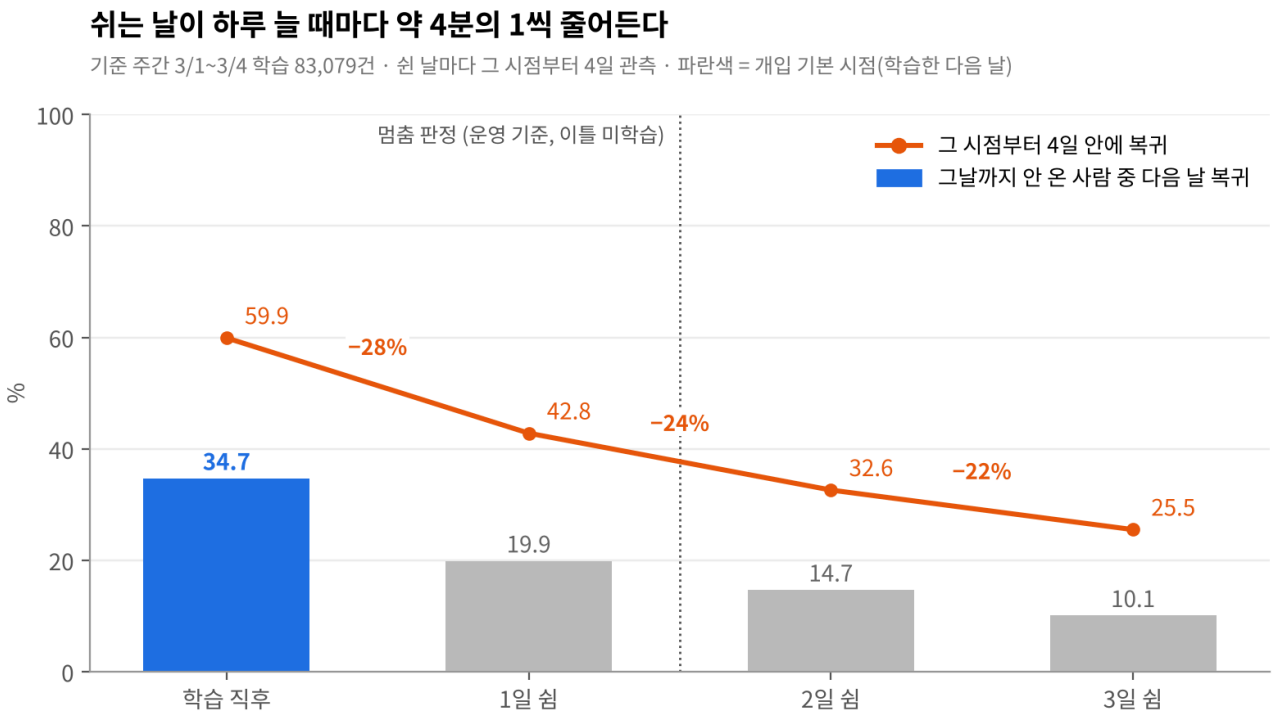
📅 ⑤ 관측 주 첫 학습일 코호트



- 첫 학습일 다음 날(D1)에 다시 학습한 비율은 3/2~3/7 코호트에서 21.3~27.1%다. 3/1 코호트(31.0%)에는 데이터 시작(2/28 저녁) 전부터 학습하던 사용자가 많이 섞여 있다.
- 가장 큰 감소는 첫 학습 직후에 일어난다. 3/2 코호트는 D1 27.1% 이후 D9 13.8%까지 완만하게 줄어든다.
- 관측 주 첫 학습일은 가입일이 아니며, 대상 대부분은 이전부터 쓰던 사용자다. 세로로 같은 열(D1, D2 …)도 요일이 서로 다르다.

📉 ⑥ 마지막 학습일 기준 이탈 곡선 신규

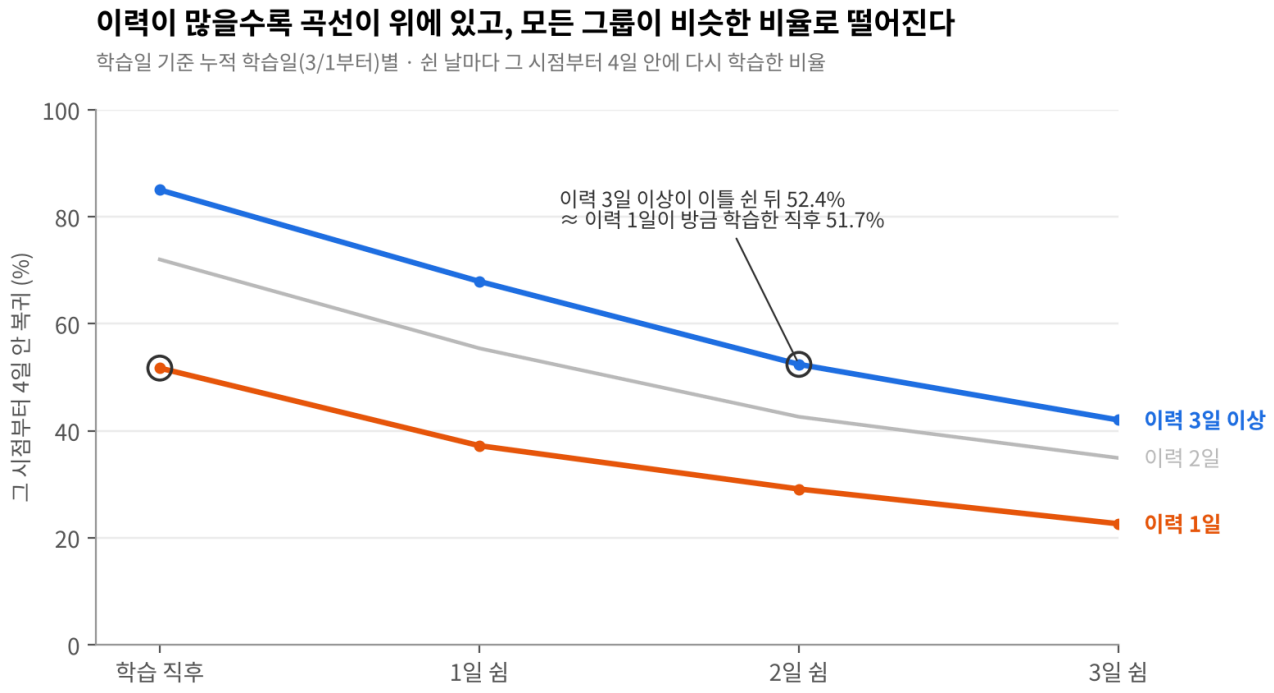
> ③과 ④는 3/8을 출발점으로 삼아, 사용자마다 마지막 학습 후 지난 날이 달랐다. 여기서는 **학습한 날을 출발점으로 맞추고**, 그 뒤 며칠을 쉬었는지에 따라 다시 돌아오는 비율을 본다. 대상은 기준 주간 3/1~3/4의 학습 83,079건이며, **쉰 날마다 그 시점부터 4일 안에** 돌아오는지 본다. 3/4에 출발한 학습도 데이터 끝(3/11) 안에 들어오도록 3일 쉼까지만 본다.



마지막 학습 후	남아 있는 건수	그날까지 안 온 사람 중 다음 날 복귀	그 시점부터 4일 안에 복귀	누적 복귀
학습 직후	83,079	**34.7%**	**59.9%**	34.7%
1일 쉼	54,246	19.9%	42.8%	47.7%
2일 쉼	43,433	14.7%	32.6%	55.4%
3일 쉼	37,035	10.1%	25.5%	59.9%

- **쉬는 날이 하루 늘 때마다 약 4분의 1씩 줄어든다.** 4일 안 복귀는 학습 직후 59.9%, 하루 쉬면 42.8%, 이틀 쉬면 32.6%다(−28%, −24%, −22%).
- 다음 날 복귀로 보면 쉬는 첫날의 감소가 −43%로 가장 크고, 그 뒤는 −26%, −31%다. **이틀째에 특별히 꺾이는 점은 없다.** 따라서 개입은 **학습한 다음 날**이 가장 좋다.
- **멈춤 기준**: 세그먼트의 "최근 이틀 학습 없음 = 멈춤"은 이 곡선에서 나온 것이 아니라, 다음 날 알림을 놓친 사람을 구분하려고 정한 운영 기준이다(노션 4-5).
- 이전 버전은 처음 학습일부터 7일을 봐서 오래 쉰 열일수록 남은 관측 기간이 짧아졌다(2일 쉼은 5일, 4일 쉼은 3일). 그만큼 하락이 부풀려져 있었다.

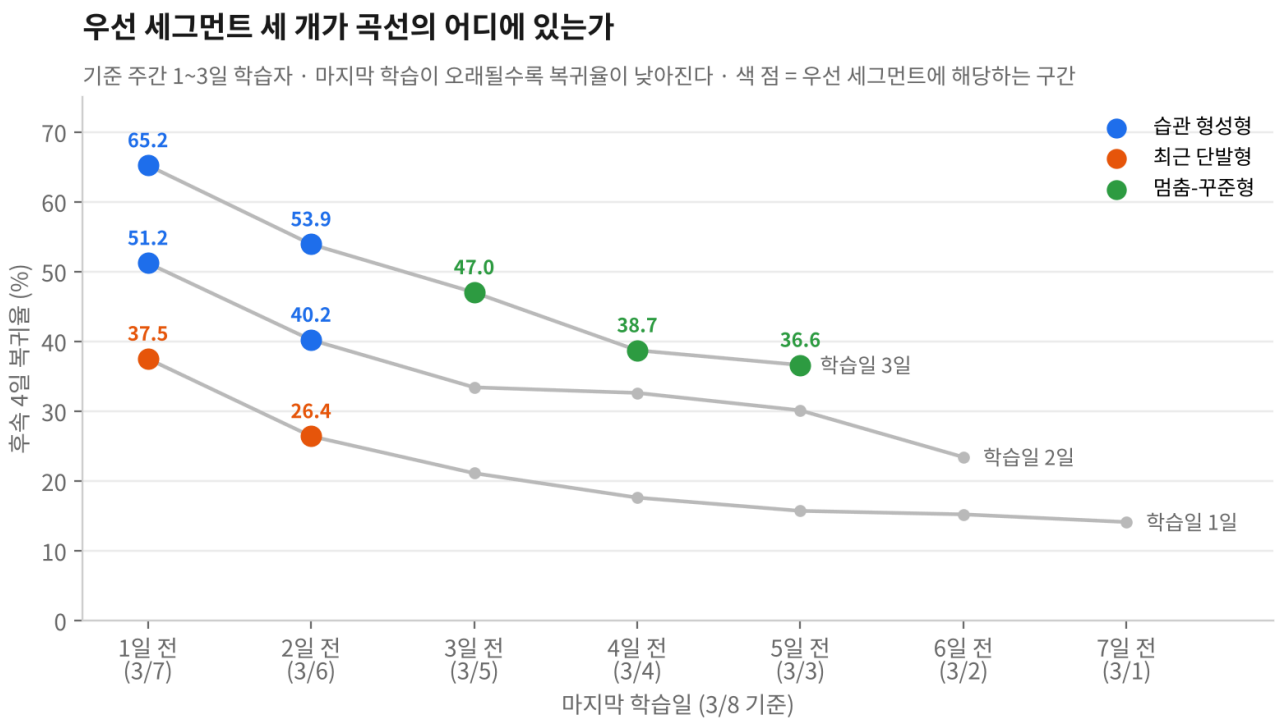
학습 이력별 이탈 곡선



그 시점부터 4일 안에 복귀	학습 직후	1일 쉼	2일 쉼	3일 쉼
이력 1일 (n=55,256)	51.7%	37.2%	29.1%	22.6%
이력 2일 (n=18,862)	72.0%	55.4%	42.6%	34.9%
이력 3일 이상 (n=8,961)	85.0%	67.9%	52.4%	42.0%

- 이력은 3/1부터 그날까지 학습한 날의 수다. 이력이 많을수록 곡선이 위에 있지만, 쉬는 날이 늘면 모든 그룹에서 비슷한 비율로 떨어진다.
- **이력 3일 이상이 이틀 쉰 뒤(52.4%)는 이력 1일이 방금 학습한 직후(51.7%)와 비슷하다.** 멈춤-꾸준형처럼 이력이 많은 사람은 멈춘 뒤에도 돌아올 여지가 크므로, 다음 날 알림을 놓쳤더라도 멈춤으로 바뀐 날 두 번째 알림을 보낼 가치가 있다.

우선 세그먼트 관점에서 본 경과일별 복귀율



학습 일수	1일 전 (3/7)	2일 전 (3/6)	3일 전 (3/5)	4일 전 (3/4)	5일 전 (3/3)	6일 전 (3/2)	7일 전 (3/1)
1일	**37.5%** n=8,444	**26.4%** n=6,958	21.1% n=6,303	17.6% n=5,754	15.7% n=6,003	15.2% n=5,983	14.1% n=7,642
2일	**51.2%** n=5,063	**40.2%** n=3,783	33.4% n=2,878	32.6% n=2,289	30.1% n=1,835	23.4% n=1,286	-
3일	**65.2%** n=3,538	**53.9%** n=2,199	**47.0%** n=1,364	**38.7%** n=866	**36.6%** n=445	-	-

- 후속 4일 복귀율. 굵은 칸이 우선 세그먼트에 해당한다. 최근 단발형은 1일 학습 · 1~2일 전, 습관 형성형은 2~3일 학습 · 1~2일 전, 멈춤-꾸준형은 3일 학습 · 3일 이상 전이다(4일 이상 학습한 멈춤-꾸준형은 표 밖).
- 같은 학습 일수 안에서 마지막 학습이 오래될수록 복귀율이 낮아진다. 최근 단발형은 하루 차이로 37.5%에서 26.4%로 떨어진다.

해석할 때 주의

- 쉰 날이 늘수록 남아 있는 사람 중에는 원래 잘 안 오는 사람의 비중이 커진다. 그래서 곡선의 하락에는 "쉬면 멀어진다"와 "원래 안 올 사람이 남는다"가 섞여 있고, 둘을 이 데이터로 나눌 수 없다. 다만 개입 시점을 정하는 데에는 어느 쪽이든 "돌아올 가능성이 남아 있을 때 먼저 연락한다"는 같은 결론이 나온다.
- 출발일이 3/1(금)~3/4(월)에 걸쳐 있어 쉰 날마다 요일이 섞인다.

🎯 시사점 및 실험 제안

코호트 결과에서 나온 시사점

관찰 결과	시사점
학습 일수가 많을수록 복귀율이 꾸준히 높다	북극성 지표(4일)는 목표선으로 두고, 바로 아래 단계(2~3일) 사용자를 우선 대상으로 본다
2~3일 학습자 중 최근에 학습한 습관 형성형의 반복 복귀율이 멈춤 계열의 두 배 가까이 된다	우선 대상 1순위는 습관 형성형
쉬는 날이 하루 늘 때마다 돌아올 가능성이 약 4분의 1씩 줄고, 쉬는 첫날 감소가 가장 크다	개입은 학습한 다음 날이 기본. "이틀"은 운영 기준이다
이어서 학습한 사람이 6~8%p 더 이어지지만, 다시 돌아오는지 여부의 차이가 훨씬 크다	쉬는 날이 쌓이기 전에, 가능하면 학습한 다음 날 돌아오게 한다
이력이 많은 사람은 이틀 쉰 뒤에도 돌아올 여지가 크다	멈춤-꾸준형은 이틀을 쉬고 멈춤으로 바뀐 날 두 번째 알림
습관 형성형은 돌아와도 이틀 이상 이어지는 비율이 낮다	돌아온 다음 날 다시 이어지도록 안내

우선 세그먼트별 개입 (노션 확정본과 동일)

순위	세그먼트	개입 시점	액션과 먼저 할 대상	평가 지표
1	습관 형성형	학습한 다음 날	"이어서 하기" 알림, 학습일 3일인 사람(5,737명)에게 "4일까지 하루 남음"	E1 4일 학습 전환율, E5 다음 날 복귀율
2	최근 단발형	학습한 다음 날	학습 직후 성취 피드백과 다음 날 안내, 3/7 학습자(쉬는 날 0일, 8,444명)부터	E5 다음 날 복귀율
3	멈춤-꾸준형	이틀을 쉬고 멈춤으로 바뀐 날	이전 학습 이어하기 알림, 북극성 지표 달성 이력자(952명)부터	E2 4일 내 복귀율

- 먼저 할 대상은 세 세그먼트 모두 **북극성 지표까지의 거리**와 **쉬는 날 수**로 골랐다. 복귀율이 높은지 낮은지는 기준으로 쓰지 않았다(노션 5-4).

실험 설계 (습관 형성형)

항목	내용
실험 대상	습관 형성형 (기준 주간 2~3일 학습 + 최근 이틀 안에 학습)
실험군	학습한 다음 날 "이어서 하기" 알림 + 주간 4일 목표 진행률 표시
대조군	기존 서비스 유지
배정 방식	사용자 단위 무작위 배정, 학습 언어 구성을 비슷하게
평가 지표	E1 4일 학습 전환율(개입 후 7일 중 4일 이상), E5 다음 날 복귀율. 보조로 복귀율과 반복 복귀율
보조 분석	실험군 안에서 쉰 날 수별 복귀 곡선이 대조군보다 위로 올라가는지

- 안내의 실제 효과는 실험으로 확인해야 한다. 현재 데이터는 추적이 4일이라 E1(개입 후 7일 중 4일 이상 학습)의 기준값은 계산할 수 없다.

📌 코호트 분석 요약 및 한계

요약

- 북극성 지표 달성군의 복귀율은 77.8%로 미달성군(29.7%)보다 높다.
- 학습 일수가 1일에서 7일로 늘수록 복귀율이 21.8%에서 96.6%로 꾸준히 높아진다. 마지막 학습일을 맞춰도 유지된다.
- 6개 세그먼트의 반복 복귀율은 55.9%(꾸준형)부터 4.7%(멈춤-저활동형)까지 다르다. 마지막 학습일을 맞춰도 유지된다.
- **학습 뒤 쉬는 날이 하루 늘 때마다 4일 안 복귀가 약 4분의 1씩 줄고, 쉬는 첫날 감소가 가장 크다.** 개입은 학습한 다음 날이 기본이다.
- 최근에 학습한 세그먼트는 주말에 학습이 줄고 월요일에 다시 오른다.

한계

- 관찰 데이터이므로 학습 일수, 세그먼트, 쉰 날 수가 복귀를 직접 바꾼다고 단정할 수 없다.
- 후속 관측이 4일(금, 토, 일, 월)이라 주말이 포함되고, 장기 이탈은 판단할 수 없다.
- 이탈 곡선은 3/1~3/4 학습을 쉰 날마다 4일씩 추적해 3일 쉼까지만 볼 수 있고, 쉰 날이 늘수록 원래 덜 오는 사람이 남는 효과가 섞여 있다.
- 기준 주간에 학습 기록이 있는 사용자만 대상이다. 관측 주 첫 학습일은 가입일이 아니며, 대부분 이전부터 쓰던 사용자다.
- 기록이 없다는 것은 이 데이터에 학습 기록이 없다는 뜻이며, 앱 미사용이나 영구 이탈을 뜻하지 않는다.

📎 부록. 대시보드용 집계

> 본문과 같은 데이터와 기준(기준 주간 3/1~3/7 사용자 82,467명, 노션 확정본의 세그먼트 규칙, 후속 3/8~3/11)으로 계산했다. 지표 이름과 ID는 노션 확정본의 지표정의서를 따른다.

A. 이탈 위험 (O3)

- 이탈 위험 = 후속 4일 동안 학습 기록이 없는 사용자. **53,227명(64.5%)**. 100%에서 복귀율을 뺀 값과 같다.
- 주말이 포함된 4일 동안 기록이 없다는 뜻이며, 영구 이탈이 아니다.

B. 세그먼트별 규모, 학습량, 이탈 위험

세그먼트	인원 (비중)	학습량 비중	1인당 학습량	이탈 위험	I1 (후속 기간)	반복 복귀율 (95% 구간)
꾸준형	8,882 (10.8%)	38.5%	611문항	19.7%	57.8%	55.9% (54.8~56.9)
습관 형성형	14,583 (17.7%)	22.0%	212문항	47.8%	36.3%	24.4% (23.7~25.1)
최근 단발형	15,402 (18.7%)	7.5%	69문항	67.5%	29.9%	12.1% (11.6~12.6)
멈춤-꾸준형	3,627 (4.4%)	8.3%	321문항	54.3%	41.0%	22.3% (21.0~23.7)
멈춤-몰입형	9,303 (11.3%)	14.9%	226문항	73.6%	29.8%	9.0% (8.5~9.6)
멈춤-저활동형	30,670 (37.2%)	8.8%	40문항	82.5%	24.0%	4.7% (4.4~4.9)

- I1 (후속 기간)은 3/8~3/10에 학습한 날 중 다음 날에도 학습한 비율이다(전체 40.2%, 37,814건). 세그먼트를 기준 주간 학습일 수로 나눴으므로, 같은 기준 주간으로 재면 분류 기준을 다시 재는 것이 되어 후속 기간에서 쟀다.
- 후속 기간은 건수가 적고 주말이 섞여 있어 참고값으로만 쓴다.

C. 노션 확정 지표의 현재값

ID	지표	정의	값
N1	북극성 지표	기준 주간 학습일 4일 이상 사용자 수	9,834명
I1	다음날 재학습률	3/1~3/6에 학습한 날 중 다음 날에도 학습한 날의 비율 (학습한 날 단위)	35.8% (46,635 / 130,409)
I2	멈춤 사용자 복귀율	최근 이틀 미학습자 중 후속 4일 복귀 비율	21.8% (43,600명 중)
I1·I2 세그먼트별	판단은 세그먼트별 값으로 한다	I1은 후속 기간에서 잰 값(부록 B), I2는 멈춤 세그먼트별 복귀율	I2: 멈춤-꾸준형 45.7%, 멈춤-몰입형 26.4%, 멈춤-저활동형 17.5%
I3	첫 학습일 학습량 (보조)	관측 주 첫 학습일 학습량의 중앙값	47문항
AC1	첫 학습일 다음날 재학습률	첫 학습일(3/1~3/6) 다음 날에도 학습한 사용자 비율	26.7%
O3	이탈 위험	후속 4일 학습 없음	53,227명 (64.5%)

- 활동일당 세션 수는 노션 확정본에서 쓰지 않기로 해 뺐다. 세 가지 "다음 날" 지표(I1, AC1, ④·⑤의 D1)는 단위와 대상이 달라 대시보드에서 이름을 구분해 표기한다.

💻 분석 코드

- 파일: `cohort_v2.py` (분석) → `results.json`, `charts_v2.py` (하이라이트 차트), `build_report.py` (이 문서)
- 실행: `pip install pandas numpy matplotlib playwright` → `python cohort_v2.py <원본 CSV> <출력 폴더>` → `python charts_v2.py <출력 폴더>`
- 원본 보고서의 모든 수치(북극성 지표, 학습 일수, 세그먼트, 첫 후속 학습일, 관측 주 첫 학습일, 부록)가 같은 값으로 재현되는지 코드 안에서 확인한다.
- 아래는 분석 부분 코드다.

```
"""듀오링고 코호트 분석 수정판 — 분석 부분
실행: python cohort_v2.py <원본 csv 또는 csv.gz> <출력 폴더>
결과: <출력 폴더>/results.json (보고서·차트가 읽는 모든 수치)
"""
import sys, os, json
from math import sqrt
import numpy as np
import pandas as pd

SRC, OUT = sys.argv[1], sys.argv[2]
os.makedirs(OUT, exist_ok=True)
T = pd.Timestamp
R = {}

# 1. 전처리: 12개 열 완전 중복 제거, 하루가 온전한 3/1~3/11 (UTC)
df = pd.read_csv(SRC, dtype={"user_id": "category", "learning_language": "category", "ui_language": "categor
y",
                             "lexeme_id": "category", "lexeme_string": "category"})
n_raw = len(df); df = df.drop_duplicates(); R["dup"] = n_raw - len(df)
df = df[["user_id", "timestamp", "session_seen"]]
df["dt"] = pd.to_datetime(df["timestamp"], unit="s")
df = df[(df["dt"] >= "2013-03-01") & (df["dt"] < "2013-03-12")].copy()
df["date"] = df["dt"].dt.normalize(); df["user_id"] = df["user_id"].astype(str)
ud = df.groupby(["user_id", "date"]).agg(seen=("session_seen", "sum")).reset_index()   # 사용자-학습일
del df
ACT = set(zip(ud.user_id, ud.date))

# 2. 기준 주간(3/1~3/7) 사용자 표 + 6개 세그먼트 (노션 확정 규칙)
```

```
obs = ud[ud.date < T("2013-03-08")]; fol = ud[ud.date >= T("2013-03-08")]
u = obs.groupby("user_id").agg(first_active=("date", "min"), last_active=("date", "max"),
                               active_days=("date", "nunique"), words_seen=("seen", "sum"))
u["recency"] = (T("2013-03-08") - u.last_active).dt.days
u["F"] = pd.cut(u.active_days, [0, 1, 2, 3, 4, 7], labels=[1, 2, 3, 4, 5]).astype(int)
u["M"] = pd.qcut(u.words_seen, 5, labels=[1, 2, 3, 4, 5]).astype(int)
u["R"] = pd.cut(u.recency, [0, 1, 2, 4, 6, 7], labels=[5, 4, 3, 2, 1]).astype(int)
SEG = ["꾸준형", "습관 형성형", "최근 단발형", "멈춤-꾸준형", "멈춤-몰입형", "멈춤-저활동형"]
cond = [(u.R >= 4) & (u.F >= 4), (u.R >= 4) & u.F.isin([2, 3]), (u.R >= 4) & (u.F == 1),
        (u.R <= 3) & (u.F >= 3), (u.R <= 3) & (u.M >= 4)]
u["segment"] = np.select(cond, SEG[:5], default=SEG[5])
DATES = list(pd.date_range("2013-03-08", "2013-03-11")); AC = ["a8", "a9", "a10", "a11"]
for d, c in zip(DATES, AC):
    u[c] = [(i, d) in ACT for i in u.index]
u["fdays"] = u[AC].sum(axis=1); u["ret1"] = u.fdays >= 1; u["ret2"] = u.fdays >= 2
u["first_return"] = np.where(u.ret1, u[AC].values.argmax(axis=1), -1)
assert len(u) == 82467 and (u.active_days >= 4).sum() == 9834
assert u.segment.value_counts().reindex(SEG).tolist() == [8882, 14583, 15402, 3627, 9303, 30670]
R["n_users"] = len(u); R["ret1"] = int(u.ret1.sum()); R["ret2"] = int(u.ret2.sum())


def rate(k, n): return round(k / n * 100, 1) if n else None


def wilson(k, n, z=1.96):
    p = k / n; den = 1 + z * z / n; c = (p + z * z / (2 * n)) / den
    h = z * sqrt(p * (1 - p) / n + z * z / (4 * n * n)) / den
    return [round((c - h) * 100, 1), round((c + h) * 100, 1)]


# ① 북극성 지표 달성 여부
R["nsm"] = {}
for key, sub in [("hit", u[u.active_days >= 4]), ("miss", u[u.active_days < 4])]:
    R["nsm"][key] = dict(n=len(sub), r1=rate(sub.ret1.sum(), len(sub)), r2=rate(sub.ret2.sum(), len(sub)),
                         daily=[rate(sub[c].sum(), len(sub)) for c in AC],
                         cum=[rate((sub[AC[:i + 1]].sum(axis=1) > 0).sum(), len(sub)) for i in range(4)])

# ② 학습 일수
g = u.groupby("active_days").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"))
R["days"] = [dict(d=int(d), n=int(r.n), r1=rate(r.k1, r.n), r2=rate(r.k2, r.n)) for d, r in g.iterrows()]
g = u[u.recency == 1].groupby("active_days").agg(n=("F", "size"), k2=("ret2", "sum"))
R["days_last37"] = [dict(d=int(d), n=int(r.n), r2=rate(r.k2, r.n)) for d, r in g.iterrows()]
MED = u.words_seen.median(); R["median_words"] = float(MED)
u["hi"] = u.words_seen >= MED
u["grp"] = np.where(u.active_days >= 4, np.where(u.hi, "D", "C"), np.where(u.hi, "B", "A"))
g = u.groupby("grp").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"))
R["abcd"] = {k: dict(n=int(r.n), r1=rate(r.k1, r.n), r2=rate(r.k2, r.n)) for k, r in g.iterrows()}
u["dg"] = u.active_days.clip(upper=4)
g = u.groupby(["dg", "hi"]).agg(n=("F", "size"), k2=("ret2", "sum"))
R["grid"] = [dict(d=int(d), hi=bool(h), n=int(r.n), r2=rate(r.k2, r.n)) for (d, h), r in g.iterrows()]

# ③ 세그먼트
R["seg"] = []
for s in SEG:
    x = u[u.segment == s]; n = len(x)
    R["seg"].append(dict(seg=s, n=n, daily=[rate(x[c].sum(), n) for c in AC],
                         cum=[rate((x[AC[:i + 1]].sum(axis=1) > 0).sum(), n) for i in range(4)],
                         r1=rate(x.ret1.sum(), n), r2=rate(x.ret2.sum(), n),
                         none=rate((x.fdays == 0).sum(), n), one=rate((x.fdays == 1).sum(), n),
                         ci2=wilson(int(x.ret2.sum()), n)))
R["all_daily"] = [rate(u[c].sum(), len(u)) for c in AC]
g = u[u.recency.isin([1, 2])].groupby(["recency", "segment"]).agg(n=("F", "size"), k2=("ret2", "sum"))
R["seg_rec"] = [dict(rec=int(a), seg=b, n=int(r.n), r2=rate(r.k2, r.n)) for (a, b), r in g.iterrows()
                if b in SEG[:3]]
two = u[u.active_days.isin([2, 3])]
R["two3"] = dict(all=[len(two), rate(two.ret2.sum(), len(two))],
                 hab=[int((two.segment == "습관 형성형").sum()), rate(two[two.segment == "습관 형성형"].ret2.sum
(), (two.segment == "습관 형성형").sum())],
                 stop=[int((two.segment != "습관 형성형").sum()), rate(two[two.segment != "습관 형성형"].ret2.sum
(), (two.segment != "습관 형성형").sum())])

# ④ 첫 후속 학습일 코호트 + 이어서 학습 vs 하루 쉬고 재개
def fr_table(s):
    out = []
    for i in range(4):
        gg = s[s.first_return == i]; row = dict(date=DATES[i].strftime("%m/%d"), n=len(gg), D={})
```

```
        for k in range(1, 4):
            if i + k < 4:
                row["D"][k] = rate(gg[AC[i + k]].sum(), len(gg))
        out.append(row)
    gg = s[s.first_return.isin([0, 1])]
    ok = sum((gg.iloc[j][AC[r + 1]] or gg.iloc[j][AC[r + 2]]) for j, r in enumerate(gg.first_return))
    return out, [len(gg), int(ok), rate(ok, len(gg))]


R["fr_all"], R["d12_all"] = fr_table(u)
R["fr_hab"], R["d12_hab"] = fr_table(u[u.segment == "습관 형성형"])
R["resume"] = []
for sg in ["꾸준형", "습관 형성형", "최근 단발형"]:
    s = u[(u.segment == sg) & u.a8]
    row = dict(seg=sg)
    for rec, lab in [(1, "cont"), (2, "rest")]:
        t = s[s.recency == rec]; row[lab] = [len(t), rate((t.a9 | t.a10).sum(), len(t))]
    na, pa = row["cont"][0], row["cont"][1] / 100; nb, pb = row["rest"][0], row["rest"][1] / 100
    row["diff"] = round((pa - pb) * 100, 1); row["ci"] = round(1.96 * sqrt(pa * (1 - pa) / na + pb * (1 - pb) /
nb) * 100, 1)
    R["resume"].append(row)

# ⑤ 관측 주 첫 학습일 코호트
R["tri"] = []
for f in pd.date_range("2013-03-01", "2013-03-07"):
    ids = u.index[u.first_active == f]; row = dict(first=f.strftime("%m/%d"), dow=f.day_name()[:3], n=len(ids),
D={})
    for k in range(1, 11):
        d = f + pd.Timedelta(days=k)
        if d > T("2013-03-11"): break
        row["D"][k] = rate(sum((i, d) in ACT for i in ids), len(ids))
    R["tri"].append(row)

# ⑥ 이탈 곡선: 마지막 학습 뒤 쉰 날 수별 복귀 (학습일 d = 3/1~3/4, 쉰 날마다 그 시점부터 4일 관측)
uds = ud.sort_values(["user_id", "date"]).copy()
uds["next"] = uds.groupby("user_id").date.shift(-1); uds["gap"] = (uds.next - uds.date).dt.days
uds["hist"] = uds.groupby("user_id").cumcount() + 1                  # 3/1부터 d까지 누적 학습일
base = uds[uds.date <= T("2013-03-04")].copy()
base["g"] = base.gap.where(base.gap <= 7, 99).fillna(99)
W = 4                                                                # 3/4 출발 + 3일 쉼 + 4일 = 3/11 (데이터 끝)


def hazard(b):
    n = len(b); rows = []
    for k in range(4):                                               # 쉰 날 0~3일
        risk = (b.g >= k + 1).sum(); ev = (b.g == k + 1).sum()
        rows.append(dict(rest=k, n_risk=int(risk), next=rate(ev, risk),
                         within4=rate(((b.g >= k + 1) & (b.g <= k + W)).sum(), risk), cum=rate((b.g <= k + 1).s
um(), n)))
    return dict(n=n, rows=rows)


R["haz_all"] = hazard(base)
base["hg"] = np.where(base["hist"] >= 3, "3일 이상", np.where(base["hist"] == 2, "2일", "1일"))
R["haz_hist"] = {k: hazard(base[base.hg == k]) for k in ["1일", "2일", "3일 이상"]}
# 세그먼트 관점: 기준 주간 1~3일 학습자의 마지막 학습 경과일별 후속 4일 복귀율
g = u[u.active_days <= 3].groupby(["active_days", "recency"]).agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret
2", "sum"))
R["rec_curve"] = [dict(d=int(a), rec=int(b), n=int(r.n), r1=rate(r.k1, r.n), r2=rate(r.k2, r.n)) for (a, b), r
in g.iterrows()]

# 부록 B: 세그먼트 규모·학습량·이탈 위험·다음날 재학습률(사용자-학습일 단위)
WS = u.words_seen.sum()
ad6 = obs[obs.date <= T("2013-03-06")].copy()
ad6["nx"] = [(a, b + pd.Timedelta(days=1)) in ACT for a, b in zip(ad6.user_id, ad6.date)]
nseg = ad6.groupby(ad6.user_id.map(u.segment)).nx.agg(["sum", "size"])
R["segB"] = []
for s in SEG:
    x = u[u.segment == s]
    nd = nseg.loc[s] if s in nseg.index else None
    R["segB"].append(dict(seg=s, n=len(x), share=rate(len(x), len(u)), vol=rate(x.words_seen.sum(), WS),
                          per=int(round(x.words_seen.sum() / len(x))), risk=rate((~x.ret1).sum(), len(x)),
                          nextday=rate(nd["sum"], nd["size"]) if nd is not None and nd["size"] > 0 else None,
                          r2=rate(x.ret2.sum(), len(x)), ci2=wilson(int(x.ret2.sum()), len(x))))
R["I1"] = [int(ad6.nx.sum()), len(ad6), rate(ad6.nx.sum(), len(ad6))]
stop = u[u.recency >= 3]; R["I2"] = [len(stop), rate(stop.ret1.sum(), len(stop))]
fv = obs.merge(u[["first_active"]], left_on="user_id", right_index=True)
R["I3"] = float(fv[fv.date == fv.first_active].groupby("user_id").seen.sum().median())
```

```
act = u[u.first_active <= T("2013-03-06")]
R["AC1"] = [len(act), rate(sum((i, f + pd.Timedelta(days=1)) in ACT for i, f in zip(act.index, act.first_activ
e)), len(act))]
R["risk"] = [int((~u.ret1).sum()), rate((~u.ret1).sum(), len(u))]
R["single_next"] = [int(((u.segment == "최근 단발형") & (u.recency == 1)).sum()),
                    int(((u.segment == "최근 단발형") & (u.recency == 1) & u.a8).sum())]

json.dump(R, open(os.path.join(OUT, "results.json"), "w"), ensure_ascii=False, indent=1)
print("완료", OUT)
```