BDAI 4주차_퍼널 분석_수합_1015

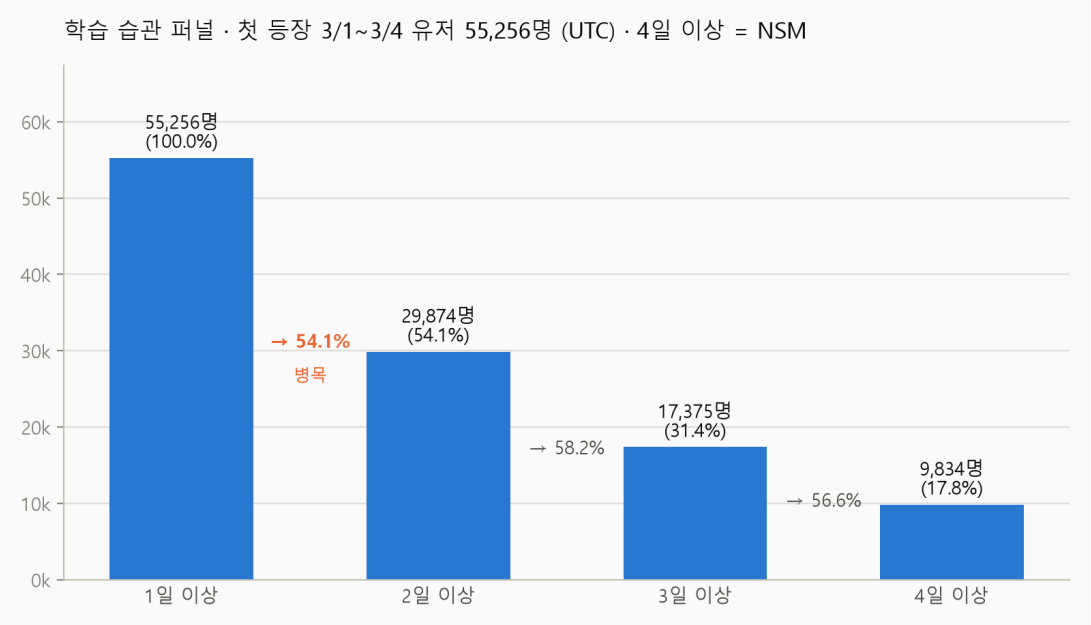
📌 퍼널 단계 정의

> **본 데이터에는 가입·결제 등 고객 여정 이벤트가 없어 전통적인 구매 퍼널 구성 불가.NSM(7일 중 4일 이상 학습)에 도달하려면 학습일을 1일 → 2일 → 3일 → 4일로 쌓아야 하므로, 누적 학습일 수를 단계로 하는 '학습 습관 퍼널'로 설계함.**

- 퍼널 단계: 1일 학습 → 2일 이상 → 3일 이상 → 4일 이상(= NSM 달성)
- 각 단계는 연속일 필요 없음. 관찰 기간 안에 해당 일수만큼 학습했는지로 판정함.
- 판정 단위: 유저(user_id). 하루에 여러 번 학습해도 1일로 셈.
- 관찰 기간: 2013-03-01 00:00 ~ 2013-03-07 23:59:59 (UTC)
  - 관찰 기간 전체 유저: 82,467명
- 전체 퍼널 대상: 관찰 기간 중 첫 학습일이 3/1~3/4인 유저 **55,256명**
  - 3/5 이후 시작한 유저(27,211명)는 기간 안에 4일 도달이 불가능해 제외.
  - 제외해도 4일 이상 학습자(9,834명)는 그대로임.
- 그룹 비교 대상: 첫 학습일이 3/1인 유저 **21,738명**
  - 3/4에 시작한 유저는 남은 4일을 모두 학습해야 NSM에 도달하는 등 시작일마다 기회가 다름 → 7일을 모두 관찰 가능한 3/1 시작 유저끼리만 비교함.

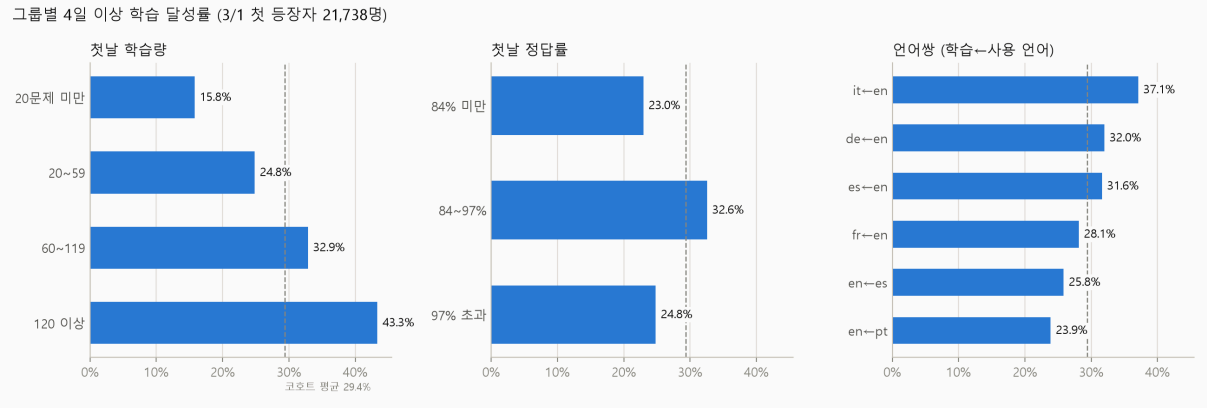
📊 전체 퍼널 결과

단계	유저 수	전체 대비	이전 단계 대비 전환율	이탈 유저
1일 학습	55,256	100%	–	–
2일 이상	29,874	54.1%	**54.1%**	**25,382**
3일 이상	17,375	31.4%	58.2%	12,499
4일 이상 (NSM)	9,834	17.8%	56.6%	7,541



> 💡 **병목은 1일 → 2일 단계.**
>
> - 전환율 54.1%로 가장 낮음. 학습 시작자의 46%가 같은 주에 두 번째 학습으로 이어지지 않음.
> - 이 단계 이탈(25,382명)이 2→3, 3→4 단계 이탈 합계(20,040명)보다 많음.
> - 2일째를 넘기면 단계마다 약 58% 수준으로 전환됨.

🔍 세분화 분석 — 누가 어디서 막히는가 (3/1 시작 유저 21,738명)



① 첫날 학습량별

첫날 푼 문제 수	유저 수	1→2	2→3	3→4	4일 달성률
20문제 미만	3,676	49.2%	56.8%	56.4%	**15.8%**
20~59	8,189	60.9%	64.7%	63.0%	24.8%
60~119	4,822	70.6%	70.8%	65.9%	32.9%
120 이상	5,051	77.2%	76.1%	73.8%	**43.3%**

- 첫날 학습량이 많을수록 모든 단계에서 전환율이 높음.
- 20문제 미만 vs 120 이상의 4일 달성률 약 2.7배 차이.

- 같은 날(3/1) 시작한 유저끼리 비교했고, 정답률 구간을 고정해도 같은 경향이 유지됨. 3/2~3/4 시작자에서도 같은 경향을 확인함(아래 보강 표).

📌 **보강: 다른 날 시작한 유저에서도 같은 경향이 나타나는가?**
위 분석은 3/1 시작자 기준이므로, 3/2~3/4 시작자까지 포함해 시작일별로 첫날 학습량 효과를 비교했다.

1→2 전환율

시작일	20문제 미만	20~59	60~119	120 이상	차이
3/1	49.2%	60.9%	70.6%	77.2%	28.0%p
3/2	39.8%	50.1%	59.2%	65.6%	25.7%p
3/3	34.5%	40.5%	45.9%	56.8%	22.3%p
3/4	30.7%	40.6%	49.3%	61.8%	31.1%p

4일 달성률

시작일	20문제 미만	20~59	60~119	120 이상
3/1	15.8%	24.8%	32.9%	43.3%
3/2	8.9%	13.3%	18.2%	24.1%
3/3	3.9%	8.0%	9.1%	15.1%
3/4	2.1%	4.6%	5.5%	12.2%

- 어느 날 시작했든 첫날 학습량이 많을수록 1→2 전환율과 4일 달성률이 모두 단계적으로 높아졌다.
- 1→2 전환율은 가장 적게 푼 그룹과 가장 많이 푼 그룹의 차이가 22~31%p로 시작일과 상관없이 비슷했다.
- 따라서 첫날 학습량 효과는 3/1 시작자만의 특징이나 시작일 효과로 설명되지 않는다.

② 첫날 정답률별

첫날 정답률	유저 수	첫날 학습량 중앙값	4일 달성률
84% 미만	3,789	36문제	23.0%
84~97%	13,732	**70문제**	**32.6%**
97% 초과	4,217	32문제	24.8%

- 겉으로는 84~97% 그룹이 가장 높은 역U자 패턴.
- 그런데 84~97% 그룹은 첫날 학습량이 다른 그룹의 약 2배임. 적게 풀면 다 맞히거나 많이 틀리기 쉬움.
- 학습량 구간을 고정하고 비교하면 정답률에 따른 차이가 크게 줄어듦.

첫날 학습량	84% 미만	84~97%	97% 초과
20문제 미만	14.0%	18.4%	15.4%
20~59	20.3%	25.8%	26.2%
60~119	29.9%	33.5%	32.6%
120 이상	46.3%	43.2%	41.6%

> **→ 정답률 차이는 대부분 학습량 차이로 설명됨. 정답률 자체의 효과라고 말하기는 어려움.**

③ 언어쌍별 (학습 언어 ← 앱 사용 언어, 1,000명 이상)

언어쌍	유저 수	1→2	2→3	3→4	4일 달성률
이탈리아어 ← 영어	1,303	72.4%	72.4%	70.7%	**37.1%**
독일어 ← 영어	2,664	67.2%	68.6%	69.4%	32.0%
스페인어 ← 영어	5,814	66.6%	69.5%	68.4%	31.6%
프랑스어 ← 영어	3,474	63.6%	67.6%	65.4%	28.1%
영어 ← 스페인어	5,861	62.1%	65.9%	63.1%	25.8%
영어 ← 포르투갈어	1,516	60.8%	64.3%	61.2%	**23.9%**

- 영어를 배우는 그룹(스페인어·포르투갈어 사용자)의 지속률이 전반적으로 낮음.
- 여러 언어를 학습한 유저는 이번 주 학습량이 가장 많은 언어쌍으로 분류함.

④ 병목 심층 — 다음날 재학습 여부

구분	유저 수	4일 달성률
첫날 다음날 재학습 O	6,749	**61.9%**
첫날 다음날 재학습 X	14,989	**14.7%**

- 약 4.2배 차이. '첫 학습 다음날 다시 오게 하기'가 가장 큰 레버임.
- 단, 다음날 재학습 시 이미 학습일 2일을 채운 상태이므로 인과 효과가 아닌 병목 근거로만 활용함.

🎯 단계별 액션 제안

단계	문제	관련 하위 지표	액션
1 → 2일 (병목)	46%가 두 번째 학습으로 이어지지 않음	다음날 재학습률	다음날 복습 푸시, '어제 배운 단어 3개' 리마인드
1 → 2일	첫날 학습량 적은 유저 이탈 큼	일일 목표 학습량 달성률	첫날 학습량이 적은 유저를 조기 위험군으로 분류해 다음날 재학습 유도
2 → 3일	습관 미형성	–	연속 학습(스트릭) 시작 보상
3 → 4일	목표 직전 이탈	–	'이번 주 4일 달성까지 1일 남음' 미션 알림
전체	영어 학습 그룹 지속률 낮음	–	언어쌍별 온보딩 콘텐츠 점검

📌 퍼널 분석 요약 및 한계

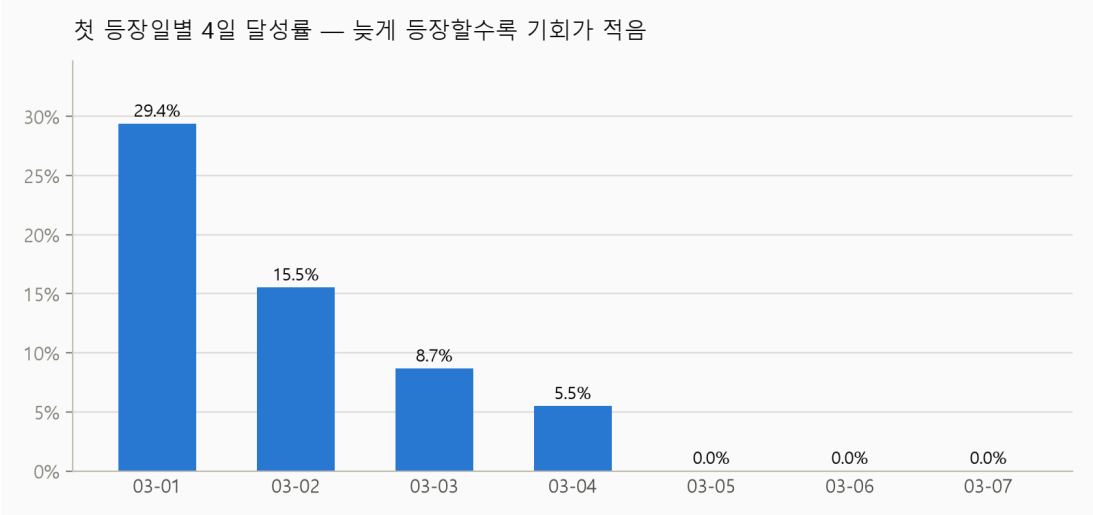
요약

- **학습 시작자의 46%가 같은 주에 두 번째 학습으로 이어지지 않아, 첫 재학습(1일 → 2일)이 NSM 도달의 가장 큰 병목임.**
- **첫날 학습량이 많은 유저일수록 모든 단계의 전환율이 높았고, 3/1~3/4 어느 날 시작한 유저끼리 비교해도 같은 경향이 유지되었음(3/1 시작자 기준 4일 달성률 15.8% → 43.3%).**
- **첫날 정답률의 차이는 학습량 차이로 대부분 설명됨. 정답률 자체를 레버로 보기는 어려움.**
- **첫날 다음날 재학습한 유저의 4일 달성률은 61.9%로, 재학습하지 않은 유저(14.7%)의 약 4.2배임. 단, 다음날 재학습한 유저는 이미 학습일 2일을 채운 상태이므로 인과 효과가 아닌 병목의 근거로 해석함.**
- 영어 학습 그룹(스페인어·포르투갈어 사용자)은 모든 단계에서 전환율이 낮음. **(3/1 시작자, 1,000명 이상 언어쌍 기준).**

한계

- 학습 기록 외의 단계 이벤트(가입, 결제, 알림 반응)가 없어 퍼널 분석의 활용 범위가 제한적임.

- 가입일 정보가 없어 '1일 학습자'를 신규 유저로 단정할 수 없음. 3/1 이전 학습 흔적(timestamp − delta) 기준으로 퍼널 대상의 82%(45,336명)는 기존 유저, 18%(9,920명)는 신규 추정 유저임.
- 관찰 기간이 7일이라 시작일마다 4일 도달 기회가 다름(3/1 시작 29.4% → 3/4 시작 5.5%). 그룹 비교는 3/1 시작 유저로 한정함. 다만 3/2~3/4 시작자에서도 첫날 학습량 효과가 유지됨을 확인함(① 첫날 학습량별 보강 표 참고)



- **첫날 학습량과 지속의 관계는 상관관계이며, 첫날 학습량을 늘리면 지속률이 오르는지는 실험으로 확인해야 함.** (같은 결과를 두 가지로 설명할 수 있기 때문)
  - **첫날 경험이 원인:** 첫날 많이 해 보면 재미나 성취감이 생겨서 다시 온다 → 첫날 학습량을 늘리면 효과가 있음
  - **원래 의욕이 원인:** 원래 의지가 강한 사람이 첫날도 많이 하고 다음 날도 온다 → 첫날 학습량을 억지로 늘려도 효과가 없음
  - 따라서 첫날 학습량은 '늘려야 할 목표'보다는 **재학습 가능성을 일찍 예측하는 신호**로 활용하고, 학습량 증대의 효과는 A/B 테스트로 검증함.
- 단계 미도달은 관찰 기간 안에 해당 일수만큼 학습하지 않았다는 뜻이며, 영구 이탈을 의미하지 않음.
- 날짜는 UTC 기준. 한국시간으로 자르면 3/1이 부분 관측일(03:28부터)이 되어 수치가 달라짐.

▼ 💻 분석 코드

- 파일: `funnel_analysis.py` (DuckDB + pandas + matplotlib)
- 실행 방법: `pip install duckdb pandas matplotlib` → `python funnel_analysis.py`
- 데이터 경로: 코드 상단 `DATA` 값을 본인 PC의 CSV 경로로 바꿔서 실행
- 결과 파일 (`outputs/funnel/`)
  - `01_funnel_overall.csv`: 전체 퍼널 (3/1~3/4 시작 유저)
  - `01b_funnel_by_population.csv`: 대상 범위별 퍼널 비교 (전체 / 3/1~3/4 시작 / 3/1 시작)
  - `02_reach_by_first_day.csv`: 시작일별 4일 달성률
  - `03~06_segment_*.csv`: 첫날 학습량 / 정답률 / 언어쌍 / 다음날 재학습별 퍼널
  - `07_accuracy_vs_items.csv`, `08_reach_by_items_x_accuracy.csv`: 정답률 효과가 학습량 때문인지 점검
  - `09_items_by_start_day.csv: 시작일별 첫날 학습량 효과 (보강)`

- `chart_01~03_*.png` : 전체 퍼널, 그룹별 달성률, 시작일별 달성률 차트

▼ 코드보기

```
"""
Duolingo 학습일 퍼널 분석 (2013-03-01 ~ 03-07, UTC)

퍼널 단계: 한 주 동안 학습한 날 수
    1일 이상 → 2일 이상 → 3일 이상 → 4일 이상(= NSM 달성)
분석 대상
    전체 퍼널 : 첫 등장 3/1~3/4 유저 (3/5 이후 첫 등장자는 4일 달성이 불가능해 제외)
    그룹 비교 : 첫 등장 3/1 유저 (7일 전체 관찰 가능 → 공정 비교)

실행
    pip install duckdb pandas matplotlib
    python funnel_analysis.py
결과
    outputs/funnel/ 에 CSV 10개 + 차트 PNG 3개
"""
import os

import duckdb
import matplotlib.pyplot as plt
import pandas as pd

# ---------------------------------------------------------------------------
# 설정
# ---------------------------------------------------------------------------
DATA = "learning_traces.13m.csv/learning_traces.13m.csv"
WEEK_START = "2013-03-01"          # 포함 (UTC)
WEEK_END = "2013-03-08"            # 미포함 (UTC) → 3/1~3/7, 7일
NSM_DAYS = 4                       # NSM: 7일 중 4일 이상
FUNNEL_LAST_D0 = "2013-03-04"      # 전체 퍼널: 이 날까지 첫 등장한 유저 (4일 달성 가능)
COHORT_DAY = "2013-03-01"          # 그룹 비교용: 7일을 모두 관찰할 수 있는 첫 등장일
MIN_GROUP_USERS = 1000             # 언어쌍 비교 최소 인원
OUT = "outputs/funnel"


def md(date_str):
    """'2013-03-04' → '3/4'"""
    return f"{int(date_str[5:7])}/{int(date_str[8:10])}"

# 차트 색상 (light 테마)
BLUE, ORANGE = "#2a78d6", "#eb6834"
```

```
INK, INK_2, MUTED, GRID, AXIS, SURFACE = "#0b0b0b", "#52514e", "#89878
1", "#e1e0d9", "#c3c2b7", "#fcfcfb"

os.makedirs(OUT, exist_ok=True)
pd.set_option("display.width", 200)
plt.rcParams.update({
    "font.family": "Malgun Gothic", "axes.unicode_minus": False,
    "figure.facecolor": SURFACE, "axes.facecolor": SURFACE,
    "axes.edgecolor": AXIS, "axes.labelcolor": INK_2, "text.color": INK,
    "xtick.color": MUTED, "ytick.color": MUTED, "axes.spines.top": Fals
e, "axes.spines.right": False,
})


def save_csv(df, name, title):
    print(f"\n==={title} ===")
    print(df.to_string(index=False))
    df.to_csv(f"{OUT}/{name}.csv", index=False, encoding="utf-8-sig")


def funnel(days, max_step=7):
    """학습일 수 Series → 단계별 사용자 수 / 전체 대비 / 이전 단계 대비 전환율 /
이탈 인원"""
    rows, prev = [], len(days)
    for k in range(1, max_step + 1):
        n = int((days >= k).sum())
        rows.append({"step": f"{k}일 이상", "users": n,
                     "pct_of_total": round(n / len(days), 4),
                     "step_conversion": round(n / prev, 4) if prev else
None,
                     "dropped": prev - n})
        prev = n
    return pd.DataFrame(rows)


def segment_funnel(df, col):
    """그룹별 1→2, 2→3, 3→4 전환율과 4일 달성률"""
    rows = []
    for key, g in df.groupby(col, observed=True):
        f = funnel(g.days, NSM_DAYS)
        rows.append({col: key, "users": len(g),
                     "conv_1to2": f.step_conversion[1], "conv_2to3": f.s
tep_conversion[2],
                     "conv_3to4": f.step_conversion[3], "reach_nsm": f.p
ct_of_total[3]})
    return pd.DataFrame(rows)


# ----------------------------------------------------------------------
-----
```

```
# 1. 데이터 로드 (UTC 기준 3/1~3/7) → 사용자-일 → 사용자 테이블
# ------------------------------------------------------------------------
-----
con = duckdb.connect()
con.execute("SET TimeZone='UTC'")   # DuckDB 기본값은 PC 시간대(한국시간)이
므로 반드시 UTC로 고정
raw_rows = con.sql(f"SELECT count(*) FROM read_csv_auto('{DATA}')").fetc
hone()[0]
con.execute(f"CREATE TABLE raw AS SELECT DISTINCT * FROM read_csv_auto
('{DATA}')")   # 완전 중복 행 제거
print(f"중복 제거:{raw_rows - con.sql('SELECT count(*) FROM raw').fetchon
e()[0]:,}행")
con.execute(f"""
    CREATE TABLE t AS
    SELECT user_id, CAST(to_timestamp("timestamp") AS DATE) AS d,
           learning_language || '←' || ui_language AS lang, session_see
n, session_correct
    FROM raw
    WHERE to_timestamp("timestamp") >= TIMESTAMPTZ '{WEEK_START} 00:00:0
0+00'
      AND to_timestamp("timestamp") <  TIMESTAMPTZ '{WEEK_END} 00:00:00+
00'
""")
con.execute("DROP TABLE raw")
con.execute("""
    CREATE TABLE user_day AS
    SELECT user_id, d, sum(session_seen) AS items, sum(session_correct)
/ sum(session_seen) AS acc
    FROM t GROUP BY 1, 2
""")
# 여러 언어를 학습한 사용자는 이번 주 학습량이 가장 많은 언어쌍으로 지정 (동률이면
이름순)
con.execute("""
    CREATE TABLE user_lang AS
    SELECT user_id, lang FROM (
        SELECT user_id, lang,
               row_number() OVER (PARTITION BY user_id ORDER BY sum(sess
ion_seen) DESC, lang) AS rn
        FROM t GROUP BY 1, 2
    ) WHERE rn = 1
""")
users = con.sql("""
    WITH f AS (SELECT user_id, min(d) AS d0 FROM user_day GROUP BY 1)
    SELECT f.user_id, f.d0, any_value(ul.lang) AS lang,
           count(*) AS days,
           max((ud.d = f.d0 + 1)::INT) AS next_day_return,
           max(CASE WHEN ud.d = f.d0 THEN ud.items END) AS d0_items,
           max(CASE WHEN ud.d = f.d0 THEN ud.acc END) AS d0_acc
    FROM f JOIN user_day ud USING (user_id) JOIN user_lang ul USING (use
r_id)
```

```
    GROUP BY 1, 2
""").df()
users["d0"] = pd.to_datetime(users.d0)

# ------------------------------------------------------------------------
-----
# 2. 전체 퍼널
# ------------------------------------------------------------------------
-----
funnel_users = users[users.d0 <= pd.Timestamp(FUNNEL_LAST_D0)]
overall = funnel(funnel_users.days)
save_csv(overall, "01_funnel_overall", f"전체 학습일 퍼널 (첫 등장 ~{md(FUN
NEL_LAST_D0)} 유저{len(funnel_users):,}명)")

# 참고: 대상 범위에 따른 퍼널 비교 (4일 이상 인원은 A·B 동일)
pops = {"A. 기간 내 전체 활동 유저": users,
        f"B. 첫 등장 3/1~{md(FUNNEL_LAST_D0)} (본 분석)": funnel_users,
        f"C. 첫 등장{md(COHORT_DAY)} (그룹 비교)": users[users.d0 == pd.Ti
mestamp(COHORT_DAY)]}
pop_rows = []
for name, g in pops.items():
    f = funnel(g.days, NSM_DAYS)
    pop_rows.append({"population": name, **dict(zip(f.step, f.users)),
                     "conv_1to2": f.step_conversion[1], "conv_2to3": f.s
tep_conversion[2],
                     "conv_3to4": f.step_conversion[3], "reach_nsm": f.p
ct_of_total[3]})
save_csv(pd.DataFrame(pop_rows), "01b_funnel_by_population", "대상 범위별
퍼널 비교")

# ------------------------------------------------------------------------
-----
# 3. 첫 등장일별 4일 달성률 — 관찰 기회 차이 확인
# ------------------------------------------------------------------------
-----
by_d0 = (users.groupby("d0")
         .agg(users=("days", "size"), reach_nsm=("days", lambda x: round
((x >= NSM_DAYS).mean(), 4)))
         .reset_index())
by_d0["d0"] = by_d0.d0.dt.strftime("%m-%d")
save_csv(by_d0, "02_reach_by_first_day", "첫 등장일별 4일 달성률 (3/5 이후
첫 등장자는 4일 달성 불가)")

# ------------------------------------------------------------------------
-----
# 4. 세분화 비교 — 3/1 첫 등장자만 (모두 7일 관찰 가능하므로 공정 비교)
# ------------------------------------------------------------------------
-----
cohort = users[users.d0 == pd.Timestamp(COHORT_DAY)].copy()
print(f"\n비교 코호트:{COHORT_DAY} 첫 등장자{len(cohort):,}명, 4일 달성률{(co
```

```
hort.days >= NSM_DAYS).mean():.4f}")

cohort["first_day_items"] = pd.cut(cohort.d0_items, [0, 20, 60, 120, flo
at("inf")],
                                   labels=["20문제 미만", "20~59", "60~11
9", "120 이상"], right=False)
cohort["first_day_accuracy"] = pd.cut(cohort.d0_acc, [0, 0.84, 0.97, 1.0
001],
                                      labels=["84% 미만", "84~97%", "97%
초과"], right=False)
cohort["next_day"] = cohort.next_day_return.map({1: "다음날 재학습 O", 0:
"다음날 재학습 X"})

seg_items = segment_funnel(cohort, "first_day_items")
seg_acc = segment_funnel(cohort, "first_day_accuracy")
seg_lang = segment_funnel(cohort, "lang").query("users >= @MIN_GROUP_USE
RS").sort_values("reach_nsm", ascending=False)
seg_next = segment_funnel(cohort, "next_day")
save_csv(seg_items, "03_segment_first_day_items", "첫날 학습량별 퍼널 (3/1
코호트)")
save_csv(seg_acc, "04_segment_first_day_accuracy", "첫날 정답률별 퍼널 (3/1
코호트)")
save_csv(seg_lang, "05_segment_language", f"언어쌍별 퍼널 (3/1 코호트,{MIN_
GROUP_USERS:,}명 이상)")
save_csv(seg_next, "06_segment_next_day", "다음날 재학습 여부별 퍼널 (3/1 코
호트)")

# 4-1. 정답률 효과가 학습량 차이 때문인지 확인 (교란 점검)
acc_items = (cohort.groupby("first_day_accuracy", observed=True)
             .agg(users=("days", "size"), median_first_day_items=("d0_it
ems", "median"),
                  reach_nsm=("days", lambda x: round((x >= NSM_DAYS).mea
n(), 4)))
             .reset_index())
save_csv(acc_items, "07_accuracy_vs_items", "첫날 정답률 그룹별 첫날 학습량
중앙값")
cross = (cohort.groupby(["first_day_items", "first_day_accuracy"], obser
ved=True)
         .agg(users=("days", "size"), reach_nsm=("days", lambda x: round
((x >= NSM_DAYS).mean(), 4)))
         .reset_index())
save_csv(cross, "08_reach_by_items_x_accuracy", "학습량 구간 안에서 정답률별
4일 달성률")

# 4-2. 보강: 3/2~3/4 시작자에서도 첫날 학습량 효과가 유지되는지 (시작일별 비교)
#      그룹 비교를 3/1 시작자로 한정했으므로, 다른 시작일에서도 같은 경향인지 확인
fu = funnel_users.copy()
fu["first_day_items"] = pd.cut(fu.d0_items, [0, 20, 60, 120, float("in
f")],
                               labels=["20문제 미만", "20~59", "60~119",
```

```
"120 이상"], right=False)
fu["start"] = fu.d0.dt.strftime("%m-%d")
by_start = (fu.groupby(["start", "first_day_items"], observed=True)
              .agg(users=("days", "size"),
                   conv_1to2=("days", lambda x: round((x >= 2).mean(),
4)),
                   reach_nsm=("days", lambda x: round((x >= NSM_DAYS).me
an(), 4)))
              .reset_index())
save_csv(by_start, "09_items_by_start_day", "시작일별 첫날 학습량 효과 (보
강)")

# ------------------------------------------------------------------------
-----
# 5. 차트
# ------------------------------------------------------------------------
-----
# 5-1. 전체 퍼널 (1~4일)
f4 = overall.head(NSM_DAYS)
fig, ax = plt.subplots(figsize=(8, 4.6))
bars = ax.bar(f4.step, f4.users, width=0.56, color=BLUE)
for b, (_, r) in zip(bars, f4.iterrows()):
    ax.text(b.get_x() + b.get_width() / 2, b.get_height() + f4.users[0]
* 0.015,
            f"{r.users:,}명\n({r.pct_of_total:.1%})", ha="center", va="b
ottom", fontsize=10, color=INK)
for i in range(1, len(f4)):
    x = i - 0.5
    y = f4.users[i - 1] * 0.55
    color = ORANGE if i == 1 else INK_2
    ax.annotate(f"→{f4.step_conversion[i]:.1%}", (x, y), ha="center", fo
ntsize=10,
                color=color, fontweight="bold" if i == 1 else "normal")
ax.text(0.5, f4.users[0] * 0.47, "병목", ha="center", fontsize=9, color=O
RANGE)
ax.set_title(f"학습 습관 퍼널 · 첫 등장 3/1~{md(FUNNEL_LAST_D0)} 유저{len(fu
nnel_users):,}명 (UTC) ·{NSM_DAYS}일 이상 = NSM",
             loc="left", fontsize=12, pad=14)
ax.set_ylim(0, f4.users[0] * 1.22)
ax.yaxis.set_major_formatter(lambda v, _: f"{v/1000:.0f}k")
ax.grid(axis="y", color=GRID, linewidth=0.8)
ax.set_axisbelow(True)
ax.tick_params(axis="x", colors=INK_2, length=0)
fig.tight_layout()
fig.savefig(f"{OUT}/chart_01_funnel_overall.png", dpi=200)
plt.close(fig)

# 5-2. 세분화별 4일 달성률 (small multiples)
avg = (cohort.days >= NSM_DAYS).mean()
panels = [("첫날 학습량", seg_items, "first_day_items"),
```

```
          ("첫날 정답률", seg_acc, "first_day_accuracy"),
          ("언어쌍 (학습←사용 언어)", seg_lang, "lang")]
fig, axes = plt.subplots(1, 3, figsize=(13, 4.4), sharex=True)
for ax, (title, df, col) in zip(axes, panels):
    labels = df[col].astype(str).tolist()[::-1]
    vals = df.reach_nsm.tolist()[::-1]
    ax.barh(labels, vals, height=0.56, color=BLUE)
    for y, v in enumerate(vals):
        ax.text(v + 0.008, y, f"{v:.1%}", va="center", fontsize=9, color
=INK,
                bbox=dict(facecolor=SURFACE, edgecolor="none", pad=1.5),
zorder=3)
    ax.axvline(avg, color=MUTED, linestyle="--", linewidth=1)
    ax.set_title(title, loc="left", fontsize=11)
    ax.xaxis.set_major_formatter(lambda v, _: f"{v:.0%}")
    ax.grid(axis="x", color=GRID, linewidth=0.8)
    ax.set_axisbelow(True)
    ax.tick_params(axis="y", colors=INK_2, length=0)
axes[0].text(avg, -0.9, f"코호트 평균{avg:.1%}", fontsize=8, color=MUTED,
ha="left")
fig.suptitle(f"그룹별{NSM_DAYS}일 이상 학습 달성률 (3/1 첫 등장자{len(cohor
t):,}명)", x=0.01, ha="left", fontsize=12)
fig.tight_layout()
fig.savefig(f"{OUT}/chart_02_reach_by_segment.png", dpi=200)
plt.close(fig)

# 5-3. 첫 등장일별 달성률 (관찰 기회 편향)
fig, ax = plt.subplots(figsize=(8, 3.8))
bars = ax.bar(by_d0.d0, by_d0.reach_nsm, width=0.56, color=BLUE)
for b, v in zip(bars, by_d0.reach_nsm):
    ax.text(b.get_x() + b.get_width() / 2, v + 0.006, f"{v:.1%}", ha="ce
nter", fontsize=9, color=INK)
ax.set_title(f"첫 등장일별{NSM_DAYS}일 달성률 — 늦게 등장할수록 기회가 적음", l
oc="left", fontsize=12, pad=12)
ax.set_ylim(0, by_d0.reach_nsm.max() * 1.18)
ax.yaxis.set_major_formatter(lambda v, _: f"{v:.0%}")
ax.grid(axis="y", color=GRID, linewidth=0.8)
ax.set_axisbelow(True)
ax.tick_params(axis="x", colors=INK_2, length=0)
fig.tight_layout()
fig.savefig(f"{OUT}/chart_03_reach_by_first_day.png", dpi=200)
plt.close(fig)

print(f"\n저장 위치:{OUT}/")
```