코호트분석 통합본

📌 코호트 분석 설계

> **기준 주간의 학습 행동으로 사용자를 고정하고, 이후 4일 동안 다시 학습하는지를 추적함.** NSM(7일 중 4일 이상 학습)이 학습의 지속을 나타내는 지표이므로, NSM 달성 여부·학습 일수·행동 세그먼트·학습 시작일에 따라 이후 재학습이 어떻게 달라지는지 비교함.

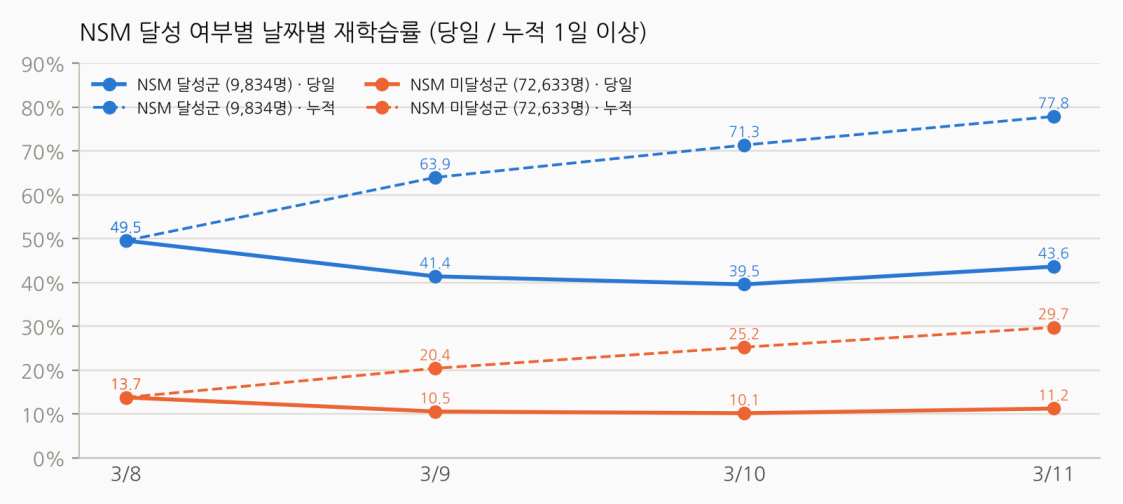
- 데이터: Duolingo Spaced Repetition Dataset. 세그먼트 분석 최신 코드와 같은 전처리(12개 열 완전 중복 81행 제거, 하루가 온전한 3/1~3/11 UTC)
- 기준 주간: 2013-03-01 ~ 03-07 (UTC). 대상: 기준 주간에 1일 이상 학습한 사용자 **82,467명**
  - 3/8~3/11에만 나타난 27,037명은 기준 주간 행동이 없어 제외
- 후속 관측: 2013-03-08 ~ 03-11 (UTC) 4일. 기준 주간 이후 결과로 코호트를 다시 나누지 않음
- 코호트 종류
  - ① NSM 달성 여부: 기준 주간 4~7일 학습(달성) / 1~3일(미달성)
  - ② 학습 일수: 기준 주간 학습 일수 1~7일
  - ③ 행동 세그먼트: 세그먼트 기본의 6개 세그먼트(R·F·M 규칙)
  - ④ 첫 후속 학습일: 후속 기간 중 처음 다시 학습한 날(D0)
  - ⑤ 관측 주 첫 학습일: 기준 주간에 처음 학습한 날(가입일 아님)

지표	정의
당일 재학습률	해당 날짜에 학습한 사용자 ÷ 코호트 전체
누적 재학습률	해당 날짜까지 1일 이상 학습한 사용자 ÷ 코호트 전체
1일 이상 재학습률	후속 4일 중 1일 이상 학습 ÷ 코호트 전체
2일 이상 재학습률	후속 4일 중 서로 다른 2일 이상 학습 ÷ 코호트 전체 (반복학습)

- 분모는 처음 정한 코호트 전체 인원. 후속 학습이 없는 사용자도 분모에 남김.
- 관측 기간(3/11)을 넘는 날짜는 0%가 아니라 '미관측'으로 둠.

📊 ① NSM 달성 여부 코호트

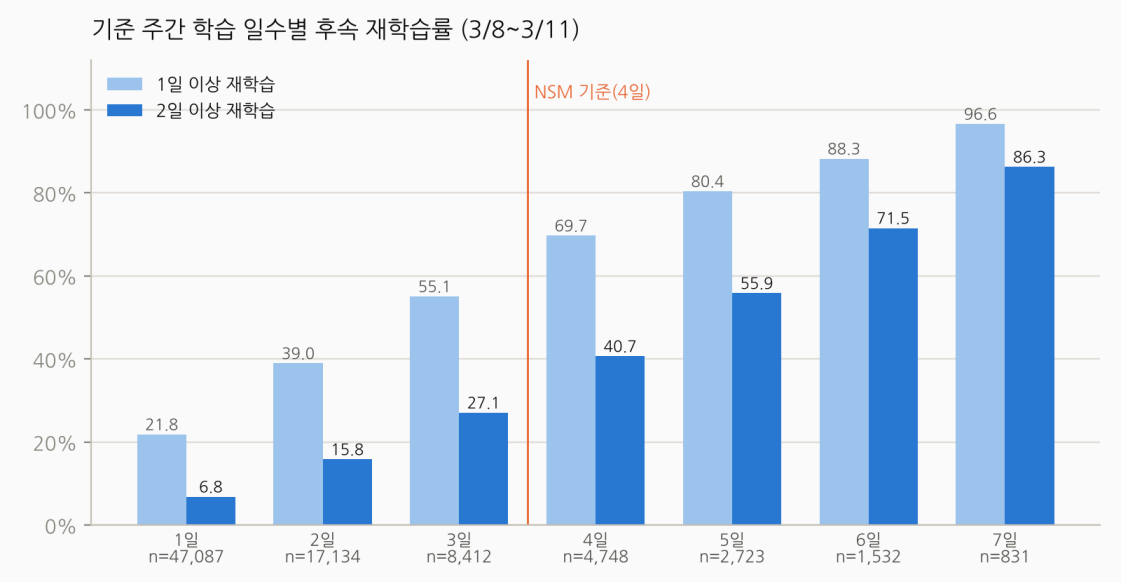
구분	유저 수	비율	1일 이상 재학습	2일 이상 재학습
NSM 달성군 (4~7일)	9,834	11.92%	**77.83%**	**53.54%**
NSM 미달성군 (1~3일)	72,633	88.08%	29.72%	11.29%
합계	82,467	100.00%	35.46%	16.33%



집단	날짜	당일 재학습자	당일 재학습률	누적 재학습자	누적 재학습률
NSM 달성군	3/8	4,869	49.51%	4,869	49.51%
NSM 달성군	3/9	4,067	41.36%	6,286	63.92%
NSM 달성군	3/10	3,887	39.53%	7,013	71.31%
NSM 달성군	3/11	4,286	43.58%	7,654	77.83%
NSM 미달성군	3/8	9,977	13.74%	9,977	13.74%
NSM 미달성군	3/9	7,649	10.53%	14,801	20.38%
NSM 미달성군	3/10	7,365	10.14%	18,301	25.20%
NSM 미달성군	3/11	8,139	11.21%	21,586	29.72%

- NSM 달성군은 모든 날짜에서 미달성군보다 재학습률이 높음. 3/11 누적 1일 이상 재학습률은 77.83% vs 29.72%로 48.11%p 차이(약 2.62배).
- 당일 재학습률은 달성군 약 40~50%, 미달성군 약 10~14% 수준을 유지. 3/9(토)·3/10(일)에 두 집단 모두 낮아짐.
- 다만 NSM 달성 자체가 높은 재학습률을 만들었다고 단정할 수는 없음.

📊 ② 학습 일수별 코호트



학습 일수	코호트 규모	1일 이상 재학습자	1일 이상 재학습률	2일 이상 재학습자	2일 이상 재학습률
1일	47,087	10,278	21.83%	3,214	6.83%

학습 일수	코호트 규모	1일 이상 재학습자	1일 이상 재학습률	2일 이상 재학습자	2일 이상 재학습률
2일	17,134	6,675	38.96%	2,711	15.82%
3일	8,412	4,633	55.08%	2,276	27.06%
4일	4,748	3,310	69.71%	1,931	40.67%
5일	2,723	2,189	80.39%	1,521	55.86%
6일	1,532	1,352	88.25%	1,096	71.54%
7일	831	803	96.63%	717	86.28%
합계	82,467	29,240	35.46%	13,466	16.33%

- 학습 일수가 늘수록 재학습률이 단계적으로 높아짐. 1일 21.83% → 4일 69.71% → 7일 96.63%.
- 3일 → 4일 증가폭(14.64%p)은 1→2일(17.13%p), 2→3일(16.12%p)과 비슷함. 4일에서 갑자기 달라지기보다 학습 일수에 따라 점진적으로 높아지는 패턴.
- 1일 학습자가 47,087명(전체의 57.10%)으로 가장 많음.

마지막 학습일을 3/7로 맞춘 비교

- 학습 일수가 많은 사용자는 최근에도 학습했을 가능성이 높아, 마지막 학습일이 같은(3/7) 사용자끼리 다시 비교함.

학습 일수	1일	2일	3일	4일	5일	6일	7일
2일 이상 재학습률	15.4%	24.5%	34.9%	45.8%	58.5%	73.7%	86.3%
인원	8,444	5,063	3,538	2,719	1,920	1,283	831

- 마지막 학습일을 맞춰도 학습 일수에 따른 차이가 유지됨.

학습 일수 × 학습량 교차 분석

- 학습량 = 기준 주간 session_seen 합(학습 문항 수). 세그먼트 기본 정의(12개 열 기준 중복 제거)의 중앙값 **75문항**으로 구분.

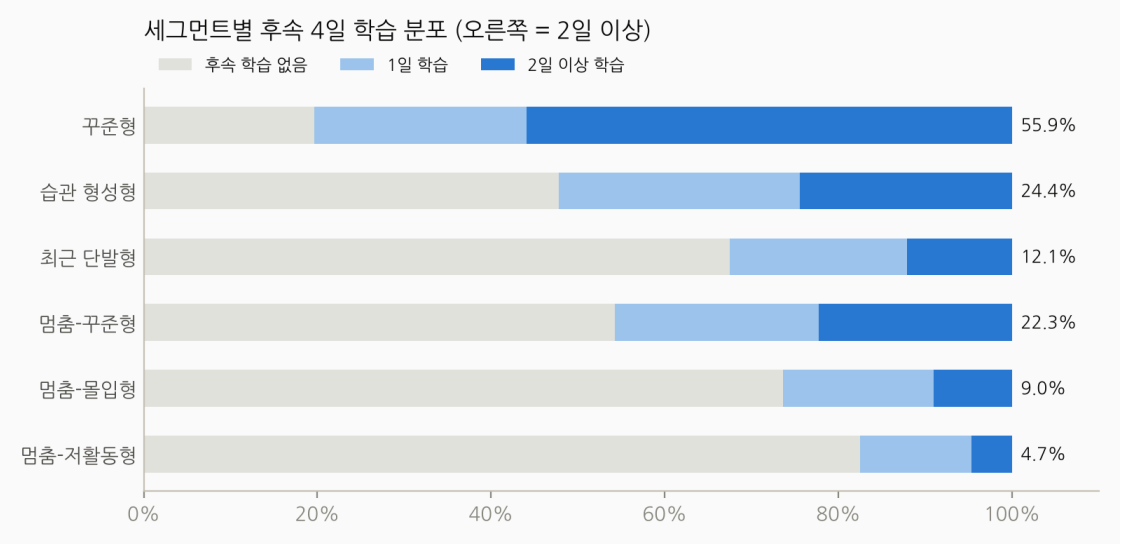
집단	학습 일수	학습량	유저 수	1일 이상 재학습률	2일 이상 재학습률
A	1~3일	75문항 미만	40,825	22.2%	6.9%
B	1~3일	75문항 이상	31,808	39.4%	17.0%
C	4~7일	75문항 미만	188	61.7%	32.4%
D	4~7일	75문항 이상	9,646	78.1%	53.9%

- 같은 학습량 구간 안에서는 학습 일수가 많은 집단의 재학습률이 높음(A 6.9% → C 32.4%, B 17.0% → D 53.9%). C 집단은 188명으로 작아 해석에 주의.
- A와 B의 차이에는 학습 일수 구성 차이가 섞여 있음. 1일 학습자 비중이 A는 84.9%, B는 39.1%로, B에 2~3일 학습자가 더 많음. 그래서 학습 일수를 나눠 다시 비교함.

학습 일수	학습량 75문항 미만	학습량 75문항 이상	차이
1일	5.7% · n=34,642	9.9% · n=12,445	+4.1%p
2일	12.4% · n=5,328	17.4% · n=11,806	+4.9%p
3일	18.5% · n=855	28.0% · n=7,557	+9.5%p
4일 이상	32.4% · n=188	53.9% · n=9,646	+21.5%p

- 2일 이상 재학습률. 학습 일수가 같은 사용자끼리 비교해도 학습량이 많은 쪽이 높지만, 1~3일 구간의 차이는 +4.1~9.5%p로 A·B 차이(10.1%p)보다 작음.
- 학습량은 학습 일수를 보완하는 요인이며, 학습 일수의 차이를 대신 설명하지는 않음.

🔍 ③ 세그먼트별 코호트



세그먼트	기준 주간 행동	인원	3/8	3/9	3/10	3/11	1일 이상	2일 이상
꾸준형	4일 이상, 최근 2일 내 학습	8,882	51.8	42.9	41.2	45.5	80.3%	**55.9%**
습관 형성형	2~3일, 최근 2일 내 학습	14,583	28.2	20.2	18.3	21.5	52.2%	**24.4%**
최근 단발형	1일, 최근 2일 내 학습	15,402	17.1	11.4	9.7	11.4	32.5%	**12.1%**
멈춤-꾸준형	3일 이상, 3/5 이전 마지막	3,627	20.2	19.8	18.9	19.7	45.7%	**22.3%**
멈춤-몰입형	2일 이하, 3/5 이전 마지막, 109문항 이상	9,303	9.9	9.1	9.4	9.9	26.4%	**9.0%**
멈춤-저활동형	2일 이하, 3/5 이전 마지막, 108문항 이하	30,670	6.0	5.4	6.1	6.0	17.5%	**4.7%**

- 날짜 칸 = 당일 재학습률(%). 꾸준형 55.9%부터 멈춤-저활동형 4.7%까지 반복학습률 차이가 큼.
- 세그먼트는 기준 주간 행동으로 정의했으므로 이 차이는 분류의 타당성 확인이며, 개입 효과를 뜻하지 않음.

습관 형성형의 날짜별 재학습

날짜	3/8 (금)	3/9 (토)	3/10 (일)	3/11 (월)
당일 재학습률	28.2%	20.2%	18.3%	21.5%
누적 재학습률	28.2%	38.9%	45.6%	52.2%

- 분모 14,583명. 3/11까지 1일 이상 52.2%가 다시 학습했지만 2일 이상은 24.4%에 그침. 재학습이 여러 날의 학습으로 충분히 이어지지 않음.

마지막 학습일을 맞춘 세그먼트 비교

마지막 학습	꾸준형	습관 형성형	최근 단발형
3/7 (1일 전)	59.7% · n=6,753	28.8% · n=8,601	15.4% · n=8,444
3/6 (2일 전)	43.8% · n=2,129	18.2% · n=5,982	8.1% · n=6,958

- 2일 이상 재학습률. 마지막 학습일이 같아도 세그먼트 간 차이가 유지됨.

2~3일 학습자 안의 차이

구분	인원	2일 이상 재학습률
2~3일 학습자 전체	25,546	19.5%
└ 최근 2일 내 학습 (습관 형성형)	14,583	**24.4%**
└ 마지막 학습이 3/5 이전 (멈춤 계열)	10,963	13.0%

- NSM 직전 단계(2~3일)라도 최근 학습 여부에 따라 재학습률이 크게 다름.

📅 ④ 첫 후속 학습일 코호트

> 후속 기간에 처음 다시 학습한 날을 D0로 맞추고, 그 뒤 날짜별로 학습했는지를 비교함. D0 = 100%는 정의상 값. 3/11 이후는 미관측.

전체

첫 후속 학습일	인원	D0	D1	D2	D3
3/8	14,846	100.0%	36.9%	33.5%	37.2%
3/9	6,241	100.0%	33.0%	29.3%	미관측
3/10	4,227	100.0%	27.1%	미관측	미관측
3/11	3,926	100.0%	미관측	미관측	미관측

습관 형성형

첫 후속 학습일	인원	D0	D1	D2	D3
3/8	4,106	100.0%	33.3%	29.1%	35.1%
3/9	1,573	100.0%	31.8%	29.6%	미관측
3/10	971	100.0%	27.5%	미관측	미관측
3/11	958	100.0%	미관측	미관측	미관측

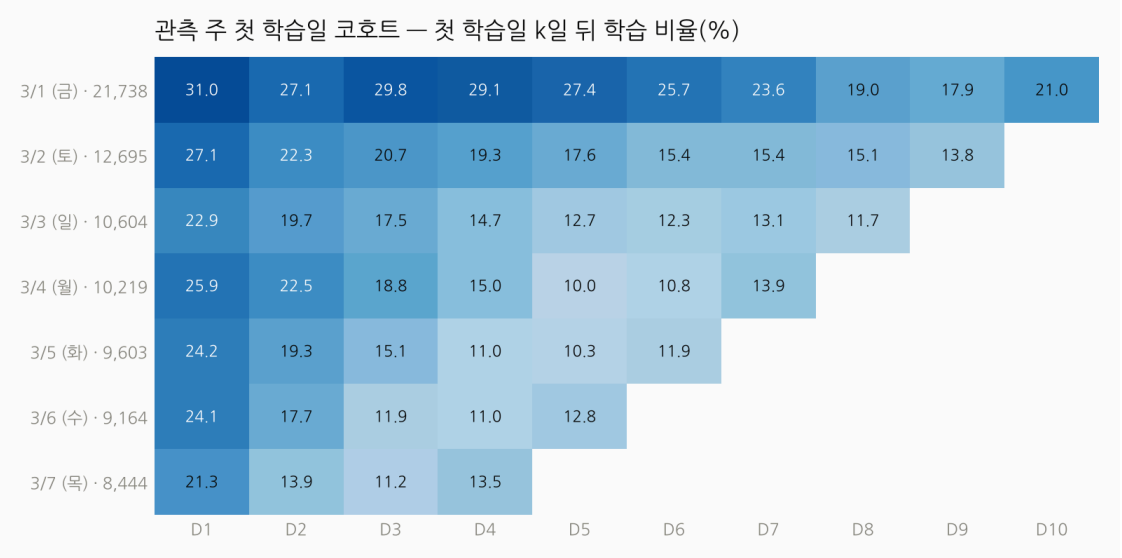
- 재학습 뒤 2일(D1·D2) 안에 추가로 학습한 비율: 전체 50.0% (21,087명 중 10,538명), 습관 형성형 47.6% (5,679명 중 2,704명). D1·D2가 모두 관측되는 3/8·3/9 재학습자만 분모에 포함.
- **행끼리 비교할 때 주의**: D1이 36.9%(3/8) → 33.0%(3/9) → 27.1%(3/10)로 낮아지지만, D1에 해당하는 요일이 각각 토·일·월로 다르고, 늦게 돌아온 사용자일수록 기준 주간 이후 더 오래 쉰 사용자임. 이 차이를 '늦게 돌아온 사용자는 덜 이어진다'는 결론으로 쓰지 않음.
- 첫 후속 학습자에는 전날(3/7)에도 학습한 사람이 포함됨. 아래에서 이어서 학습한 사람과 쉬었다 재개한 사람을 나눠 봄.

이어서 학습 vs 하루 쉬고 재개 (3/8 첫 후속 학습자)

세그먼트	3/7에도 학습 (이어서)	3/6이 마지막 (하루 쉬고 재개)	차이
꾸준형	71.8% · n=3,759	65.5% · n=843	**6.3%p**
습관 형성형	49.7% · n=2,799	42.0% · n=1,307	**7.7%p**
최근 단발형	40.1% · n=1,795	34.1% · n=841	**5.9%p**

- 결과 = 3/9·3/10 중 추가 학습 비율. 습관 형성형 차이 7.7%p (95% CI ±3.3%p). 세 세그먼트 모두 하루 쉬고 재개한 쪽이 덜 이어짐.
- 다음 두 날이 모두 주말(토·일)인 같은 날짜끼리의 관측 비교이며, 재개 자체의 인과 효과는 아님.

📅 ⑤ 관측 주 첫 학습일 코호트



- 첫 학습일 다음날(D1) 다시 학습한 비율은 3/2~3/7 코호트에서 21.3~27.1%. 3/1 코호트(31.0%)에는 데이터 시작(2/28 저녁) 전부터 학습하던 사용자가 많이 섞여 있음.
- 가장 큰 감소는 첫 학습일 직후. 3/2 코호트는 D1 27.1% 이후 D9 13.8%까지 완만하게 줄어듦.
- 관측 주 첫 학습일은 가입일이 아님. 퍼널 분석과 같은 방식(timestamp − delta)으로 보면 신규 추정 사용자는 20,286명(24.6%)이며, 신규 추정 사용자만 본 D1은 3/1 23.3%, 3/2 25.7%, 3/3 24.3%, 3/4 27.5%, 3/5 25.3%, 3/6 27.4%, 3/7 24.9%로 전체와 비슷한 수준.

🎯 시사점 및 실험 제안

학습 일수 코호트별 학습 지속 지원 방향

대상 집단	관측 결과	개선 방향
1일 학습군	후속 재학습률 21.83%	다음 학습일 설정 및 학습 재참여 안내
2~3일 학습군	후속 재학습률 38.96~55.08%	주간 4일 학습 목표 제시
4~6일 학습군	후속 재학습률 69.71~88.25%	주간 학습 목표 유지 피드백
7일 학습군	후속 재학습률 96.63%	학습 성취 피드백 및 장기 목표 제공

- 규모가 큰 1~3일 학습군(72,633명, 88.1%)의 재학습 참여를 지원하는 것이 중요한 과제. 그중 2~3일 학습군(25,546명, 31.0%)은 이미 여러 날 학습한 경험이 있지만 NSM 기준에 도달하지 못한 집단.

코호트 결과에서 나온 시사점

관찰 결과	시사점
학습 일수가 많을수록 재학습률이 점진적으로 높음	NSM(4일)은 목표선으로 두고, 바로 아래 단계(2~3일) 사용자를 우선 대상으로 봄
2~3일 학습자 중 최근 학습한 습관 형성형의 재학습률이 멈춤 계열보다 높음	우선 대상은 2~3일 학습자 중 습관 형성형
습관 형성형의 재학습이 여러 날로 이어지지 않음 (1일 이상 52.2% vs 2일 이상 24.4%)	다시 학습한 뒤 다음 학습으로 연결하는 안내가 필요
하루 쉬고 재개한 사용자가 이어서 학습한 사용자보다 덜 이어짐	학습 직후 다음 학습일을 정하게 하는 시점이 유효

항목	내용
실험 대상	습관 형성형 (기준 주간 2~3일 학습 + 최근 2일 내 학습)
실험군	학습 직후 다음 학습일 안내 + 주간 4일 학습 목표 표시

항목	내용
대조군	기존 서비스 유지
배정 방식	사용자 단위 무작위 배정
평가 지표	학습 뒤 2일(D1·D2) 안 추가 학습 비율, 다음 7일 NSM 달성률, 후속 1일·2일 이상 재학습률

- 안내의 실제 효과는 실험으로 확인해야 함. 현재 데이터는 추적 4일이라 다음 7일 NSM 달성률의 기준값은 계산할 수 없음.

📌 코호트 분석 요약 및 한계

요약

- NSM 달성군의 후속 1일 이상 재학습률은 77.8%로 미달성군(29.7%)보다 높음.
- 학습 일수가 1일에서 7일로 늘수록 재학습률이 21.8%에서 96.6%로 점진적으로 높아짐. 마지막 학습일을 맞춰도 유지됨.
- 6개 세그먼트의 2일 이상 재학습률은 55.9%(꾸준형)~4.7%(멈춤-저활동형). 마지막 학습일을 맞춰도 차이가 유지됨.
- 재학습 뒤 2일 안에 추가 학습한 비율은 절반 수준이며, 하루 쉬고 재개한 사용자일수록 덜 이어짐.
- 관측 주에 처음 학습한 다음날 다시 학습한 사용자는 4명 중 1명 수준(신규 추정 사용자도 비슷).

한계

- 관찰 데이터이므로 학습 일수·세그먼트가 재학습을 직접 높인다고 단정할 수 없음.
- 후속 관측이 4일이라 D7·D30 리텐션, 다음 주 NSM 달성, 장기 이탈은 판단할 수 없음. 추적 4일(금·토·일·월)에 주말이 포함됨.
- 기준 주간에 학습 기록이 있는 사용자만 대상. 관측 주 첫 학습일은 가입일이 아니며, 사용자의 약 75%는 3/1 이전 학습 흔적이 있는 기존 사용자.
- 기록 없음은 이 데이터에 학습 기록이 없다는 뜻이며 앱 미사용이나 영구 이탈을 뜻하지 않음.
- 학습량(session_seen 합)은 노출·응답 시도 수이며 학습 시간이나 난이도를 반영하지 않음.

▼ 💻 분석 코드

- 파일: `build_cohort_report.py` (pandas + numpy, 차트 matplotlib)
- 실행 방법: `pip install pandas numpy matplotlib playwright pypdf` → `python build_cohort_report.py <원본 CSV> <출력 폴더>`
- 데이터 경로: 실행할 때 첫 번째 인자로 원본 CSV(또는 .csv.gz) 경로를 넘김
- 결과 파일 (`<출력 폴더>/`)
  - `charts/chart_01~04_*.png`: NSM 달성 여부별 날짜별 재학습, 학습 일수별 재학습, 세그먼트 분포, 첫 학습일 코호트
  - `코호트분석_최종통합본.pdf`: 이 문서
- 아래는 분석 부분 코드(차트와 문서 출력 부분 제외)

코드보기

```
"""듀오링고 코호트 분석 통합본 (코호트분석 + 코호트분석2) — 노션 문서 형식 PDF.

두 코호트 분석 파일의 코호트 분석 내용만 통합한다. 세그먼트는 '세그먼트 기본'(세그먼트 분석 최신 코드) 규칙을 그대로 적용한다.
실행: pip install pandas numpy matplotlib playwright pypdf && playwright install chromium
      python build_cohort_report.py <원본 csv 또는 csv.gz> <출력 폴더>
"""
import sys, os, json, html
from math import sqrt
import numpy as np, pandas as pd

SRC, OUTDIR = sys.argv[1], sys.argv[2]
CHART = os.path.join(OUTDIR, "charts"); os.makedirs(CHART, exist_ok=True)
PDF = os.path.join(OUTDIR, "코호트분석_최종통합본.pdf")
T = pd.Timestamp

# 1. 세그먼트 분석 최신 코드의 전처리 (12개 열 완전 중복 제거, 3/1~3/11 UTC)
df = pd.read_csv(SRC, dtype={"user_id": "category", "learning_language": "category", "ui_language": "category",
                             "lexeme_id": "category", "lexeme_string": "category"})
```

```
N_RAW = len(df); df = df.drop_duplicates(); N_DUP = N_RAW - len(df)
first_trace = (df.timestamp - df.delta).groupby(df.user_id.astype(str)).min()      # 신규 추정용(퍼널 분석과 같은 방식)
df = df[["user_id", "timestamp", "session_seen", "session_correct"]]
df["dt"] = pd.to_datetime(df["timestamp"], unit="s")
df = df[(df["dt"] >= "2013-03-01") & (df["dt"] < "2013-03-12")].copy()
df["date"] = df["dt"].dt.normalize(); df["user_id"] = df["user_id"].astype(str)
N_USERS_311 = df["user_id"].nunique()
ud = df.groupby(["user_id", "date"]).agg(seen=("session_seen", "sum"), sessions=("timestamp", "nunique")).reset_
index()
del df

# 2. 기준 주간(3/1~3/7) 사용자 집계와 6개 세그먼트
obs = ud[ud.date < T("2013-03-08")]; fol = ud[ud.date >= T("2013-03-08")]
u = obs.groupby("user_id").agg(first_active=("date", "min"), last_active=("date", "max"), active_days=("date",
"nunique"),
                               words_seen=("seen", "sum"))
u["recency"] = (T("2013-03-08") - u.last_active).dt.days
u["F"] = pd.cut(u.active_days, [0, 1, 2, 3, 4, 7], labels=[1, 2, 3, 4, 5]).astype(int)
u["M"], M_EDGES = pd.qcut(u.words_seen, 5, labels=[1, 2, 3, 4, 5], retbins=True); u["M"] = u.M.astype(int)
u["R"] = pd.cut(u.recency, [0, 1, 2, 4, 6, 7], labels=[5, 4, 3, 2, 1]).astype(int)
SEG = ["꾸준형", "습관 형성형", "최근 단발형", "멈춤-꾸준형", "멈춤-몰입형", "멈춤-저활동형"]
cond = [(u.R >= 4) & (u.F >= 4), (u.R >= 4) & u.F.isin([2, 3]), (u.R >= 4) & (u.F == 1), (u.R <= 3) & (u.F >=
3), (u.R <= 3) & (u.M >= 4)]
u["segment"] = np.select(cond, SEG[:5], default=SEG[5])
u["new"] = pd.to_datetime(first_trace.reindex(u.index), unit="s") >= T("2013-03-01")

# 3. 후속 관측(3/8~3/11) 날짜별 학습 여부
DATES = list(pd.date_range("2013-03-08", "2013-03-11")); AC = [f"a{d.day}" for d in DATES]
act = set(zip(fol.user_id, fol.date))
for d, c in zip(DATES, AC): u[c] = [int((i, d) in act) for i in u.index]
u["fdays"] = u[AC].sum(axis=1); u["ret1"] = (u.fdays >= 1).astype(int); u["ret2"] = (u.fdays >= 2).astype(int)
u["first_return"] = u[AC].values.argmax(axis=1).astype(float); u.loc[u.ret1 == 0, "first_return"] = np.nan

assert N_DUP == 81 and N_USERS_311 == 109504 and len(u) == 82467
assert (u.active_days >= 4).sum() == 9834 and u.ret1.sum() == 29240 and u.ret2.sum() == 13466
assert u.segment.value_counts().reindex(SEG).tolist() == [8882, 14583, 15402, 3627, 9303, 30670]
def rate(k, n): return k / n * 100
def pct(k, n, d=1): return f"{rate(k, n):.{d}f}%"

# ① NSM 달성 여부 코호트 (코호트분석2)
NSMG = {}
for key, sub in [("hit", u[u.active_days >= 4]), ("miss", u[u.active_days < 4])]:
    NSMG[key] = dict(n=len(sub), k1=int(sub.ret1.sum()), k2=int(sub.ret2.sum()), daily=[int(sub[c].sum()) for c
in AC],
                     cum=[int((sub[AC[:i + 1]].sum(axis=1) > 0).sum()) for i in range(4)])
assert NSMG["hit"]["daily"] == [4869, 4067, 3887, 4286] and NSMG["hit"]["cum"] == [4869, 6286, 7013, 7654]
assert NSMG["miss"]["daily"] == [9977, 7649, 7365, 8139] and NSMG["miss"]["cum"] == [9977, 14801, 18301, 21586]
# ② 학습 일수 코호트 (코호트분석2) + 마지막 학습일 통제 + 학습량 교차
days = u.groupby("active_days").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"))
TEAM = {1: (47087, 10278, 3214), 2: (17134, 6675, 2711), 3: (8412, 4633, 2276), 4: (4748, 3310, 1931), 5: (2723,
2189, 1521), 6: (1532, 1352, 1096), 7: (831, 803, 717)}
for d_, v in TEAM.items(): assert tuple(days.loc[d_]) == v
rec1_days = u[u.recency == 1].groupby("active_days").agg(n=("F", "size"), k2=("ret2", "sum"))
MED = u.words_seen.median(); assert MED == 75
u["grp"] = np.where(u.active_days >= 4, np.where(u.words_seen >= MED, "D", "C"), np.where(u.words_seen >= MED,
"B", "A"))
abcd = u.groupby("grp").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"))
grid = u.assign(dg=u.active_days.clip(upper=4), hi=u.words_seen >= MED).groupby(["dg", "hi"]).agg(n=("F", "siz
e"), k2=("ret2", "sum"))
one_day_share = {g: rate(((u.grp == g) & (u.active_days == 1)).sum(), (u.grp == g).sum()) for g in ["A", "B"]}
two3 = u[u.active_days.isin([2, 3])]; T23H = two3[two3.segment == "습관 형성형"]; T23P = two3[two3.segment != "습관
형성형"]
# ③ 세그먼트 코호트 (코호트분석)
seg = u.groupby("segment").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"), **{c: (c, "sum") for c i
n AC}).reindex(SEG)
assert seg.k2.tolist() == [4963, 3562, 1862, 808, 841, 1430]
seg_cum = {s: [rate((u[u.segment == s][AC[:i + 1]].sum(axis=1) > 0).sum(), seg.loc[s, "n"]) for i in range(4)] f
or s in SEG}
seg_rec = u[u.recency.isin([1, 2])].groupby(["recency", "segment"]).agg(n=("F", "size"), k2=("ret2", "sum"))
# ④ 첫 후속 학습일 코호트 (코호트분석)
def fr_table(s):
    out = []
    for i in range(4):
```

```
        g = s[s.first_return == i]; row = {"date": DATES[i], "n": len(g), "D": {}}
        for k in range(1, 4):
            if i + k < 4: row["D"][k] = rate(g[AC[i + k]].sum(), len(g))
        out.append(row)
    g = s[s.first_return.isin([0, 1])]
    ok = sum((g[AC[int(r)+1]].iloc[j] + g[AC[int(r)+2]].iloc[j]) > 0 for j, r in enumerate(g.first_return))
    return out, (len(g), int(ok))
FR_ALL, D12_ALL = fr_table(u); FR_HAB, D12_HAB = fr_table(u[u.segment == "습관 형성형"])
assert FR_ALL[0]["n"] == 14846 and FR_HAB[0]["n"] == 4106 and D12_HAB == (5679, 2704)
RESUME = {}
for sg in ["꾸준형", "습관 형성형", "최근 단발형"]:
    s = u[(u.segment == sg) & (u.a8 == 1)]
    for r, lab in [(1, "cont"), (2, "rest")]:
        t = s[s.recency == r]; RESUME[(sg, lab)] = (len(t), int(((t.a9 + t.a10) > 0).sum()))
assert RESUME[("습관 형성형", "cont")] == (2799, 1392) and RESUME[("습관 형성형", "rest")] == (1307, 549)
(na, ka), (nb, kb) = RESUME[("습관 형성형", "cont")], RESUME[("습관 형성형", "rest")]
pa, pb = ka / na, kb / nb; RES_CI = 1.96 * sqrt(pa * (1 - pa) / na + pb * (1 - pb) / nb) * 100
# ⑤ 관측 주 첫 학습일 코호트
allact = set(zip(ud.user_id, ud.date))
TRI = []
for f in pd.date_range("2013-03-01", "2013-03-07"):
    ids = u.index[u.first_active == f]; newids = u.index[(u.first_active == f) & u.new]
    row = {"first": f, "n": len(ids), "n_new": len(newids), "D": {}, "D1_new": rate(sum((i, f + pd.Timedelta(day
s=1)) in allact for i in newids), len(newids))}
    for k in range(1, 11):
        d = f + pd.Timedelta(days=k)
        if d > T("2013-03-11"): break
        row["D"][k] = rate(sum((i, d) in allact for i in ids), len(ids))
    TRI.append(row)
NEW_N = int(u.new.sum())
```