BDAI 4주차_코호트 분석_수합_1015

📌 분석의 결론

> **여러 날 학습한 사용자가 다시 돌아왔고, 하루 공백이 가장 큰 하락 지점이었다**
> 듀오링고 코호트 분석 · 최종 통합본(코호트분석 + 코호트분석2) · 노션·세그먼트 기본 기준 · 2026.10.15

- 대시보드 탭 1 · 개요
- 기준 주간: 2013-03-01 ~ 2013-03-07 (UTC) · 후속 관측: 2013-03-08 ~ 2013-03-11

North Star와 결과

지표	값	비고
주간 활성 학습자	82,467	3/1-3/7 1일 이상
NSM 지속 학습자	**9,834**	7일 중 4일 이상 · 11.9%
후속 4일 재학습	35.5%	3/8-3/11 1일 이상
후속 4일 반복학습	16.3%	3/8-3/11 2일 이상

Input Metrics (세그먼트 기본 정의)

지표	값	비고
다음날 재학습률	**35.8%**	사용자-활동일 기준
규칙적 학습자 비율	25.9%	세션 3개+ 사용자 · 정의 재검토 필요
학습 성과 개선율	51.6%	세션 3개+ 사용자
적정 간격 복습 비율	9.3%	사용자별 값의 중앙값

분석 질문별 답

1. **학습 일수가 늘수록 후속 재학습이 계단처럼 높아졌다 (NSM)**
   NSM 달성군 77.8%, 미달성군 29.7%. 1일 21.8% → 4일 69.7% → 7일 96.6%.
2. **6개 세그먼트의 반복학습률은 55.9%에서 4.7%까지 갈렸다 (분석 질문 1)**
   세그먼트 간 차이는 유의했고(카이제곱 p<0.001), 마지막 학습일을 맞춰도 순서가 유지됐다.
3. **하루를 쉬면 재학습 가능성이 가장 크게 떨어졌다 (분석 질문 3)**
   1일 학습자 기준 마지막 학습이 어제면 37.5%, 이틀 전이면 26.4%.
4. **Input metric 중 '다음날 재학습률'만 NSM과 같은 방향으로 움직였다 (가설)**
   규칙적 학습자는 오히려 반복학습이 낮았고(13.8% vs 28.8%) 정의에 구조적 문제가 있다. 성과 개선은 차이가 없었다.

> **실행 제안** NSM 직전 단계인 **습관 형성형**에게 학습을 마친 직후 **다음 학습일을 정하는 안내**를 주고, 다음날 재학습률(주 지표)과 주간 NSM 달성률(보조)로 효과를 실험한다.

🧭 대시보드 구성안

> **이 보고서의 각 장이 대시보드의 한 탭이 되도록 정리했다**
> 모든 수치는 dashboard_data 폴더의 CSV에서 다시 그릴 수 있다 · 사용자 단위 파일로 세그먼트·학습 일수 필터를 걸 수 있다

탭	답하는 질문	권장 시각화	데이터 파일	보고서
1 개요	NSM·Input metric은 어떤 수준인가	KPI 카드 8개, 세그먼트 구성 막대	01_kpi_summary, 04_segment_summary	분석의 결론
2 NSM 코호트	여러 날 학습할수록 다시 오는가	학습 일수별 막대, 달성/미달성 날짜별 선	02_cohort_active_days, 03_cohort_nsm_daily	NSM 관점의 코호트

탭	답하는 질문	권장 시각화	데이터 파일	보고서
3 세그먼트 코호트	어떤 유형이 계속 학습하는가	100% 누적 막대, 날짜×세그먼트 히트맵, 요약표	04_segment_summary, 05_segment_daily	행동 유형별 코호트
4 첫 학습일 코호트	처음 학습한 뒤 언제 끊기는가	삼각형 리텐션 히트맵	06_first_active_cohort	첫 학습일 코호트
5 이탈 위험	얼마나 쉬면 돌아오지 않는가	경과일별 선, 재개자 비교 막대	07_recency_curve, 08_resume_compare	비활동과 재학습
6 지표·가설	어떤 Input metric이 NSM과 함께 움직이는가	세그먼트×지표 표, 가설별 비교 막대	04_segment_summary, 09_input_metric_hypothesis	Input metric과 가설
7 액션	누구에게 무엇을, 무엇으로 잴 것인가	우선순위 표 + 성공 지표 기준값	10_action_baselines	누구에게 무엇을

공통 필터와 데이터 단위

- **필터**: 세그먼트(6개), 기준 주간 학습 일수(1~7일), NSM 달성 여부. 모두 11_user_level.csv(사용자 82,467행)의 열로 들어 있어 사용자 단위로 다시 집계할 수 있다.
- **집계 단위 주의**: 다음날 재학습률은 사용자-활동일 단위, 나머지 비율은 사용자 단위다. 한 화면에서 같은 축에 섞지 않는다.
- **기간 표기**: 기준 주간 2013-03-01~07, 후속 관측 03-08~11(UTC). 후속 7일 NSM·장기 유지는 이 데이터로 계산할 수 없어 '측정 불가'로 표시한다.
- **퍼널 탭**: 팀원 담당 퍼널 분석을 같은 필터(세그먼트·NSM 달성 여부)로 연결하면 두 분석을 한 대시보드에서 비교할 수 있다.

> **대시보드에서 강조할 흐름** 개요(NSM이 11.9%) → 누가 계속 학습하나(학습 일수·세그먼트) → 언제 끊기나(첫날 직후·하루 공백) → 무엇이 NSM을 움직이나(다음날 재학습률) → 누구에게 어떤 액션(습관 형성형).

📊 NSM 관점의 코호트

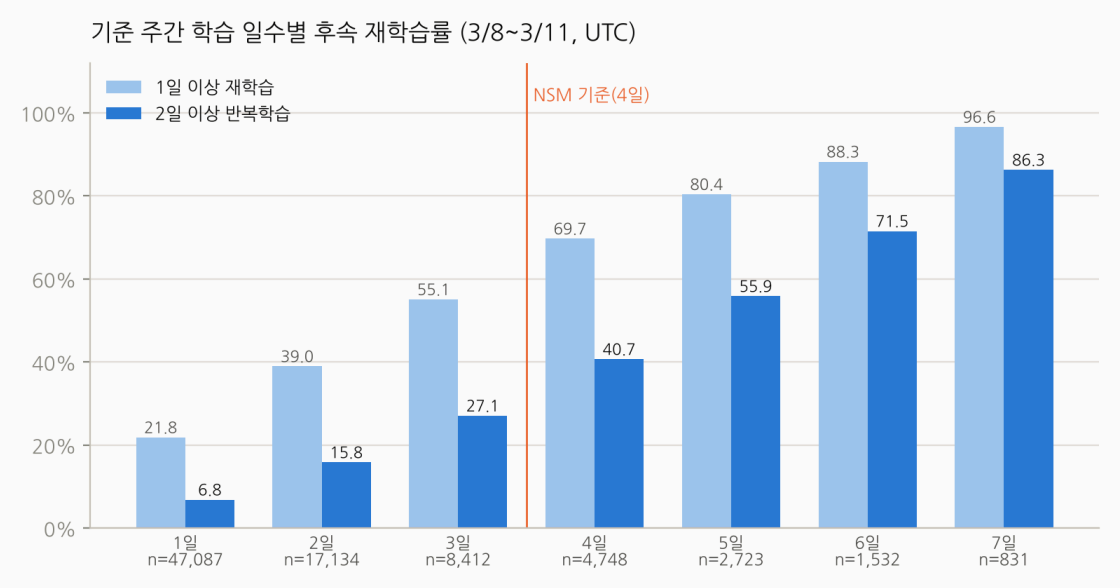
> **기준 주간 학습 일수가 늘수록 후속 재학습이 단계적으로 높아졌다**
> 코호트 = 3/1-3/7 학습 일수(세그먼트 기본의 F 원값) · 후속 3/8-3/11 · 분모: 각 코호트 전체 · 코호트분석2의 37개 값과 일치

- 대시보드 탭 2

구분	유저 수	1일 이상 재학습	2일 이상 반복학습
NSM 달성군 · 4~7일	9,834	**77.8%**	**53.5%**
NSM 미달성군 · 1~3일	72,633	29.7%	11.3%

- 날짜별 당일 재학습률(3/8→3/11): 달성군 49.5→41.4→39.5→43.6%, 미달성군 13.7→10.5→10.1→11.2%. 3/9·3/10은 주말이다.

학습 일수별 코호트 (1~7일)



학습 일수	유저 수	1일 이상 재학습	2일 이상 반복학습
1일	47,087	21.8%	6.8%
2일	17,134	39.0%	15.8%
3일	8,412	55.1%	27.1%
4일	4,748	69.7%	40.7%
5일	2,723	80.4%	55.9%
6일	1,532	88.3%	71.5%
7일	831	96.6%	86.3%

- 1일 학습자가 47,087명(57.1%). 세그먼트 기본의 'NSM 4일 선정 근거' 표(복귀율 21.8%→96.6%)와 같은 결과다.

마지막 학습일을 3/7로 맞춰도 계단은 유지됐다

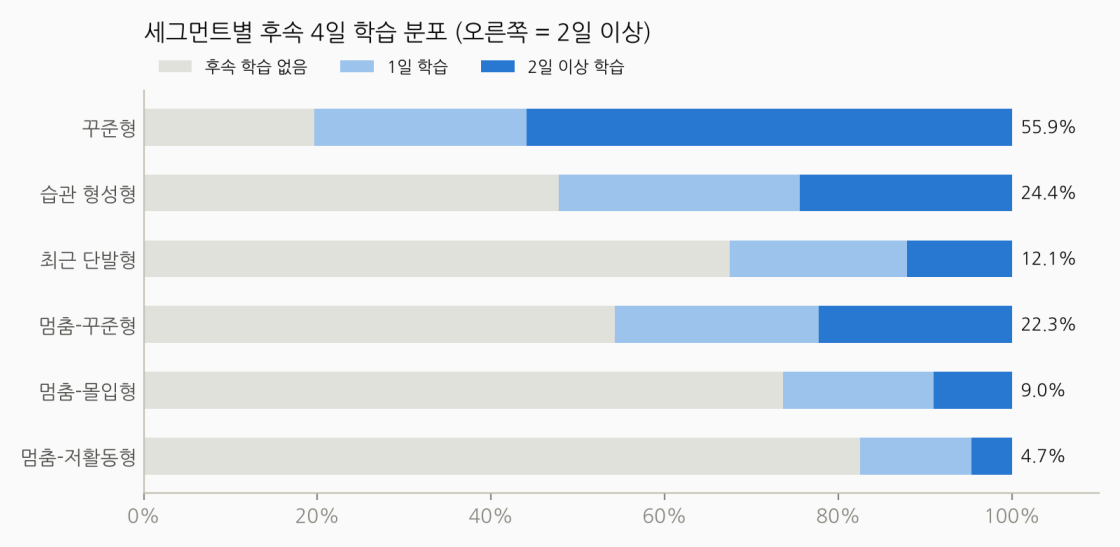
학습 일수	1일	2일	3일	4일	5일	6일	7일
2일 이상	15.4%	24.5%	34.9%	45.8%	58.5%	73.7%	86.3%
인원	8,444	5,063	3,538	2,719	1,920	1,283	831

> **4일은 급변점이 아니라 계단의 한 칸이었다.**
> 1일 이상 재학습 증가폭: 1→2일 +17.1%p, 2→3일 +16.1%p, 3→4일 +14.6%p.
> NSM은 목표선으로 두고, 개입은 바로 아래 단계(2~3일 학습자, 그중 습관 형성형)를 겨냥한다.

🔍 행동 유형별 코호트

> **세그먼트마다 후속 반복학습이 12배 가까이 차이 났다**
> 코호트 = 세그먼트 기본의 6개 세그먼트(3/1-3/7 RFM 규칙) · 분모: 각 세그먼트 전체

- 대시보드 탭 3



세그먼트	고객 비중	학습량 비중	집중도	3/8	3/9	3/10	3/11	1일 이상	2일 이상
꾸준형	10.8%	38.5%	3.58	51.8	42.9	41.2	45.5	80.3%	**55.9%**
습관 형성형	17.7%	22.0%	1.24	28.2	20.2	18.3	21.5	52.2%	**24.4%**
최근 단발형	18.7%	7.5%	0.40	17.1	11.4	9.7	11.4	32.5%	**12.1%**
멈춤-꾸준형	4.4%	8.3%	1.88	20.2	19.8	18.9	19.7	45.7%	**22.3%**
멈춤-몰입형	11.3%	14.9%	1.32	9.9	9.1	9.4	9.9	26.4%	**9.0%**
멈춤-저활동형	37.2%	8.8%	0.24	6.0	5.4	6.1	6.0	17.5%	**4.7%**

- 날짜 칸 = 당일 학습 비율(%). 6개 세그먼트의 2일 이상 반복학습 차이는 유의했다(χ^2=14,581, 자유도 5, p<0.001). '1일 이상'은 세그먼트 기본의 4일 복귀율과 같은 값이다.

마지막 학습일을 맞춰도 순서는 유지됐다

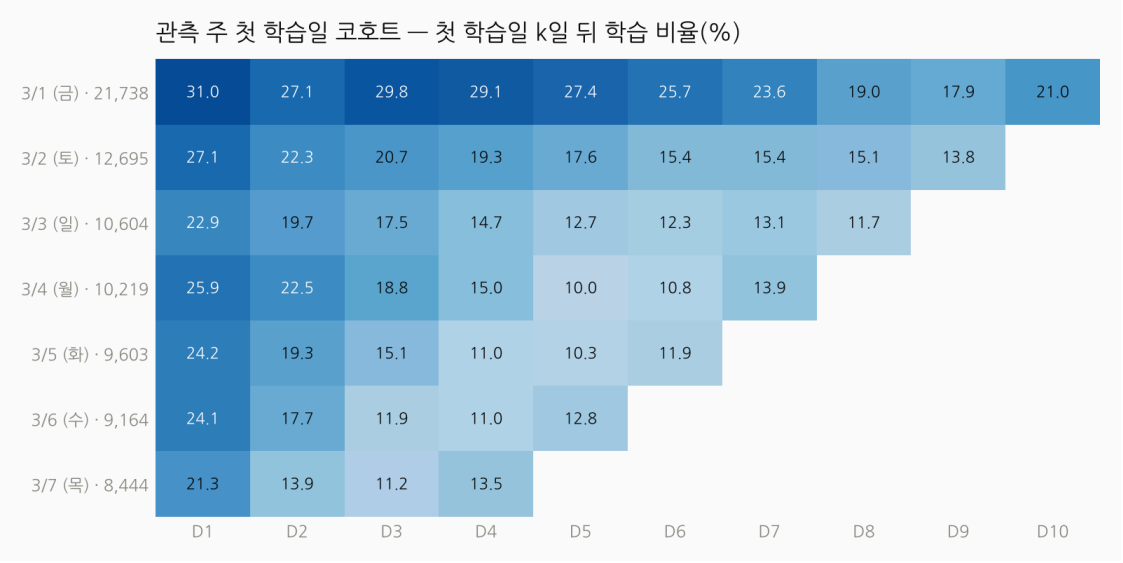
마지막 학습	꾸준형	습관 형성형	최근 단발형
3/7 (어제)	59.7% · n=6,753	28.8% · n=8,601	15.4% · n=8,444
3/6 (이틀 전)	43.8% · n=2,129	18.2% · n=5,982	8.1% · n=6,958

> **대시보드 포인트** 꾸준형은 고객 10.8%로 학습량 38.5%를 만든다. 가장 큰 그룹인 멈춤-저활동형(37.2%)은 학습량 8.8%, 반복 학습 4.7%다. 세그먼트는 기준 주간 행동으로 정의했으므로 이 차이는 분류의 타당성 확인이며 개입 효과가 아니다.

📅 관측 주 첫 학습일 코호트

> **처음 학습한 다음날 다시 학습한 사용자는 4명 중 1명 수준이었다**
> 코호트 = first_active(관측 주 첫 학습일, 세그먼트 기본 변수표의 '코호트 분석' 용도) · 칸 = 첫 학습일 k일 뒤 학습 비율(%)

- 대시보드 탭 4



- 3/1 코호트에는 데이터가 2/28 저녁부터 시작해 이미 학습 중이던 사용자가 많이 섞여 있다. first_active는 가입일이 아니다. 3/8 이후 칸은 후속 관측 기간이다.

읽을 점

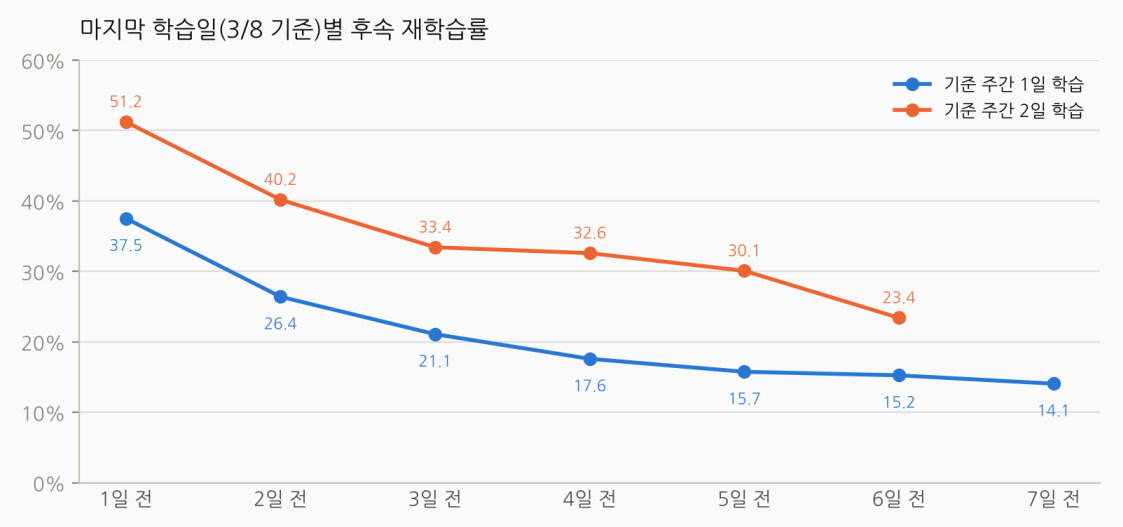
- **첫날 이후 바로 이어진 비율이 낮다.** 3/2-3/7 코호트의 D1은 21.3-27.1%다. Input metric '다음날 재학습률'이 가장 먼저 무너지는 지점이다.
- **가장 큰 하락은 첫날 직후다.** 3/2 코호트는 D1 27.1% 뒤 D9 13.8%까지 하루 평균 1.7%p씩 완만하게 줄었다.
- **요일 영향이 섞인다.** 3/4 코호트는 토·일인 D5·D6이 10.0·10.8%로 월요일 D7 13.9%보다 낮았다.

> 📌 두 원본 파일 모두 이 코호트가 없었다(코호트분석2는 제외를 명시). 세그먼트 기본이 first_active를 코호트용 변수로 만들어 둔 만큼 통합본에 추가했다. 대시보드에서는 세그먼트 필터와 함께 보면 첫날 이후 이탈이 어느 유형에서 큰지 확인할 수 있다.

⏸️ 비활동과 재학습

> **하루를 쉬는 순간 재학습 가능성이 가장 크게 떨어졌다**
> 분석 질문 3(이탈 위험) · 노션 가설 후보 5 · 결과: 3/8-3/11 중 1일 이상 학습 · 학습 일수를 같게 두고 비교

- 대시보드 탭 5



- 1일 학습자는 마지막 학습이 어제→이틀 전이 되면 11.1%p, 이틀→사흘 전이면 5.3%p 떨어졌고 이후 완만했다. 세그먼트 기본이 R≥4(최근 2일)를 '활동 중' 경계로 둔 근거와도 맞는다.

같은 날 돌아온 사용자: 이어서 학습 vs 하루 쉬고 재개

3/8에 학습한 사용자	3/7에도 학습 (이어서)	3/6이 마지막 (하루 쉬고 재개)	차이
꾸준형	71.8% · n=3,759	65.5% · n=843	**6.3%p**
습관 형성형	49.7% · n=2,799	42.0% · n=1,307	**7.7%p**
최근 단발형	40.1% · n=1,795	34.1% · n=841	**5.9%p**

- 결과 = 3/9·3/10 중 추가 학습 비율. 습관 형성형 차이 7.7%p(95% CI ±3.3%p, z=4.62). 다음 두 날이 주말인 같은 날짜끼리의 관측 비교(코호트분석의 재개자 비교를 원본에서 재계산).

> **이탈 위험 신호는 '하루 공백'이다.** 공백이 생기기 전 다음 학습을 약속하게 하거나, 쉬었다 돌아온 순간 다음 학습을 연결하는 개입이 가장 큰 하락 구간을 겨냥한다. 기록 없음은 이 데이터에 학습 기록이 없다는 뜻이며 영구 이탈은 아니다.

🧪 Input metric과 가설

> **다음날 재학습률만 NSM과 같은 방향이었고, 규칙적 학습자 비율은 정의부터 다시 봐야 한다**
> 정의: 세그먼트 기본 Input Metrics 표 · 대상: 세션 3개 이상 사용자(다음날 재학습률 제외)

- 대시보드 탭 6

세그먼트	다음날 재학습률	세션 3개+ 인원	규칙적 학습자 비율	학습 성과 개선율	적정 간격 복습(중앙값)
꾸준형	71.8%	8,882	10.4%	51.7%	20.5%
습관 형성형	35.8%	12,632	8.7%	51.8%	10.3%
최근 단발형	0.0%	4,495	64.8%	52.5%	0.0%
멈춤-꾸준형	52.2%	3,627	15.1%	50.0%	19.4%
멈춤-몰입형	18.0%	9,037	35.9%	53.8%	0.0%
멈춤-저활동형	5.9%	5,822	48.2%	47.9%	0.0%
전체	**35.8%**	44,495	25.9%	51.6%	9.3%

가설별 확인 (후속 2일 이상 반복학습)

가설	집단	전체	습관 형성형
가설 1 규칙성	규칙적(CV<1)	13.8% · n=11,540	24.3% · n=1,102
	불규칙(CV≥1)	28.8% · n=32,955	26.0% · n=11,530
가설 2 성과 변화	후반 정답률 상승	25.2% · n=22,965	26.1% · n=6,545
	상승 없음	24.6% · n=21,530	25.5% · n=6,087
가설 3 복습 타이밍	적정 간격 비율 0%	12.9% · n=16,525	20.2% · n=3,703
	적정 간격 비율 0~10%	28.4% · n=6,338	28.7% · n=2,556
	적정 간격 비율 10~25%	34.7% · n=10,626	27.5% · n=3,300
	적정 간격 비율 25% 초과	31.4% · n=11,006	28.4% · n=3,073

- **가설 1:** 규칙적 학습자의 반복학습이 오히려 낮았다. 1일만 학습한 사용자의 66.7%가 '규칙적'으로 분류되는 반면 2일 이상 학습자는 9.2%뿐이다. 하루 안의 세션 간격과 며칠에 걸친 간격이 한 CV에 섞여, 이 지표는 '하루에 몰아서 학습'을 규칙성으로 잡는다. → 활동일 간 간격 기준으로 정의를 바꾸거나, 대시보드에서는 다음날 재학습률로 대체할 것을 권한다.
- **가설 2:** 성과 개선 여부에 따른 차이가 없었다(0.6%p 이내).
- **가설 3:** 적정 간격 복습 비율이 0%인 집단이 가장 낮고 10~25%까지 오른 뒤 정체했다. 여러 날 학습해야 12~48시간 간격이 생기므로 학습 일수의 영향이 섞인다. 노션 가설 3은 '복습 간격 → 학습 성과', 세그먼트 기본은 '복습 타이밍 → 리텐션'으로 결과 변수가 다르니 팀에서 하나로 정해야 한다.

🎯 누구에게 무엇을

> **세그먼트 기본의 액션 표에 성공 지표의 현재 기준값을 붙였다**
> 대시보드 탭 7은 액션별 '지금 값'을 보여 주고, 실험 후 같은 정의로 비교하는 화면이다

- 대시보드 탭 7

순위	세그먼트	액션안 (세그먼트 기본)	성공 지표	현재 기준값
1	습관 형성형	주간 4일 목표·진행률, 간격 벌어지기 전 알림	4일 이상 학습 전환율	후속 4일 모두 학습 2.3% (2일 이상 24.4%)
2	멈춤-꾸준형	"잊기 전에 복습" 알림	4일 내 복귀율	45.7%
2	멈춤-몰입형	"매일 소량" 목표 제안	재학습일 수	후속 4일 평균 0.38일
3	꾸준형	평소 시간대 알림, 연속 학습 보상	NSM 유지율	측정 불가(다음 7일 필요) · 대체: 2일 이상 55.9%
4	최근 단발형	첫 학습 직후 성취 피드백, 다음 날 안내	다음 날 복귀율	3/7 학습자의 3/8 학습 21.3% (n=8,444)
5	멈춤-저활동형	저비용 일괄 리마인드	알림 반응률	측정 불가(알림 로그 없음) · 대체: 4일 내 복귀율 17.5%

1순위 실험안 (두 코호트 파일의 제안을 합침)

항목	내용
대상	습관 형성형 14,583명 (2~3일 학습 + 최근 학습). 같은 2~3일 학습자라도 멈춤 계열은 반복학습 13.0%로 습관 형성형(24.4%)보다 낮다
시점	학습을 마친 직후(하루 공백 전). 하루 이상 쉬고 돌아온 경우에도 같은 시점에 노출
개입	다음 학습일 정하기 + 주간 4일 목표 표시 (코호트분석2의 4일 목표 + 코호트분석의 다음 학습일 계획)
배정	사용자 단위 1:1 무작위, 안내 미노출자도 배정군 유지
주 지표	다음날 재학습률 (노션·세그먼트 기본 Input metric). 현재 습관 형성형 35.8%
보조 지표	후속 7일 NSM 달성률(코호트분석2), 2일 이상 반복학습률

- **측정 한계: 액션 효과, 7일 NSM 유지, 알림 반응은 이 데이터로 확인할 수 없다(세그먼트 기본도 같은 한계를 명시). 표본 수는 팀이 목표 개선 폭을 정한 뒤 산정한다.**

📌 두 파일을 어떻게 통합했나

> **노션과 세그먼트 기본에 비춰 평가하고 대시보드에 필요한 것만 남겼다**
> 중심 파일: 코호트분석(세그먼트 축·통계 검정·이탈 위험) · 코호트분석2에서 NSM·학습 일수 코호트와 실험 지표를 가져옴

기준	코호트분석	코호트분석2	통합본
세그먼트 기본의 6개 세그먼트를 코호트 축으로	O	X (학습 일수만)	탭 3
NSM(7일 중 4일) 중심 해석	△ (KPI로만)	O	탭 1·2
세그먼트 기본 Input Metrics 4개	X	X	탭 1·6 신규
first_active 코호트	X	X (제외 명시)	탭 4 신규
이탈 위험(분석 질문 3)	O	X	탭 5
통계적 유의성(노션 성공 기준)	O	X	탭 3·5
세그먼트 기본의 전처리 정의	O	△ (학습량 중복 제거 오류)	정정
세그먼트 기본 액션과 연결	X	△ (2~3일군)	탭 7

- O 충족 · △ 부분 · X 미충족
- **뺀 것**: 코호트분석의 A1·완전 관측 같은 자체 용어, 표본 수 8,692명 등 실험 설계 세부, 회귀(OR) 결과는 코호트 범위를 넘어 제외했다. 가설 결과는 노션 '가설 검증' 페이지, 실험 세부는 별도 설계 문서로 옮길 것을 권한다.

- **정정**: 코호트분석2의 학습량 중앙값 27은 user_id·timestamp·session_seen 세 열로 중복을 지울 때 나오는 값(서로 다른 단어 기록 손실)이다. 세그먼트 기본 정의의 중앙값은 75다. 팀원 표의 나머지 37개 값은 원본 재계산과 일치했다.
- **팀 결정이 필요한 것**: ① 규칙적 학습자 비율의 정의 수정 여부(탭 6) ② 가설 3의 결과 변수(학습 성과 vs 리텐션) ③ 실험 주 지표를 다음날 재학습률로 확정할지.

데이터와 재현

- Duolingo Spaced Repetition Dataset(Settles & Meeder, 2016) 원본 12,854,226행 → 12개 열 완전 중복 81행 제거 → 3/1-3/11(109,504명) → 관측 주 3/1-3/7 82,467명.
- 세그먼트 인원·M 경계(24·53·108·239)가 세그먼트 기본과 일치. 세션 = 사용자+timestamp, 학습 문항 수 = session_seen 합.

📁 대시보드 데이터 사전

> **dashboard_data 폴더의 파일과 열**
> 모든 비율은 % 단위 · 날짜는 UTC · 파일은 UTF-8(BOM)로 엑셀에서 바로 열린다

파일	단위(행)	주요 열	쓰는 탭
01_kpi_summary	지표 10개	지표, 정의, 인원_또는_분자, 값, 출처	1
02_cohort_active_days	학습 일수 7	users, ret1_rate, ret2_rate, nsm_group, last3_7_ret2_rate	2
03_cohort_nsm_daily	NSM 군 × 날짜 8	daily_rate, cum_rate	2
04_segment_summary	세그먼트 6	user_share, volume_share, concentration, ret1/ret2(+CI), next_day_rate, regular_rate, improved_rate, review_ok_median	1·3·6
05_segment_daily	세그먼트 × 날짜 24	active_users, daily_rate	3
06_first_active_cohort	첫 학습일 × D1~D10 70	active_users, rate, observed(관측 가능 여부)	4
07_recency_curve	학습 일수 × 경과일	ret1_rate, ret2_rate	5
08_resume_compare	세그먼트 × 집단 6	d1d2_rate	5
09_input_metric_hypothesis	지표 × 집단	metric, scope, group, ret2_rate	6
10_action_baselines	액션 6	success_metric, baseline_definition, baseline_value	7
11_user_level	사용자 82,467	segment, R/F/M, first_active, a8~a11, ret1, ret2, gap_cv, regular, improved, review_ok	필터 전체

- 'observed=False'인 첫 학습일 코호트 칸은 관측 기간 밖이므로 0이 아니라 빈칸으로 그린다. 11_user_level의 Input metric 열은 세션 3개 미만 사용자에서 비어 있다(정의상 대상 아님).

▼ 💻 분석 코드

- 파일: `build_cohort_notion.py` (pandas + numpy + scipy, 차트 matplotlib, PDF는 Chromium 출력)
- 실행 방법: `pip install pandas numpy scipy matplotlib playwright pypdf` → `python build_cohort_notion.py <원본 CSV> <출력 폴더>`
- 데이터 경로: 실행할 때 첫 번째 인자로 원본 CSV(또는 .csv.gz) 경로를 넘김
- 결과 파일 (`<출력 폴더>/`)
  - `dashboard_data/01~11_*.csv` : 대시보드용 집계·사용자 단위 데이터
  - `charts/chart_01~04_*.png` : 학습 일수별 코호트, 세그먼트 분포, 첫 학습일 코호트, 경과일별 재학습 차트
  - `코호트분석_최종통합본.pdf` : 이 문서
- 아래는 분석·집계 부분 코드(차트와 문서 출력 부분 제외)

코드보기

```
"""듀오링고 코호트 분석 최종 통합본 (대시보드 구성용) — 노션 문서 형식 PDF.

기준: 노션 3팀 프로젝트(문제정의·분석 질문·NSM·지표 정의서·가설) + '세그먼트 기본' 문서(세그먼트 분석 최신 코드,
지표 체계: Input Metrics 4개·보류 지표, 세그먼트 요약표, 세그먼트별 액션).
통합 대상: 코호트분석.pdf, 코호트분석2.pdf.
산출: 통합 보고서 PDF(퍼널 분석 문서와 같은 노션 형식) + 대시보드용 집계 CSV 패키지 + 차트 PNG.

실행: pip install pandas numpy scipy matplotlib playwright pypdf && playwright install chromium
      python build_cohort_notion.py <원본 csv 또는 csv.gz> <출력 폴더>
"""
import sys, os, re, json, html
from math import sqrt
import numpy as np, pandas as pd
from scipy.stats import chi2_contingency
from pypdf import PdfReader

SRC, OUTDIR = sys.argv[1], sys.argv[2]
DATA = os.path.join(OUTDIR, "dashboard_data"); os.makedirs(DATA, exist_ok=True)
PDF = os.path.join(OUTDIR, "코호트분석_최종통합본.pdf")
CHART = os.path.join(OUTDIR, "charts"); os.makedirs(CHART, exist_ok=True)
T = pd.Timestamp

# ============================================================ 1. 세그먼트 분석 최신 코드 재현 + 지표 원재료
df = pd.read_csv(SRC, dtype={"user_id": "category", "learning_language": "category", "ui_language": "category",
                             "lexeme_id": "category", "lexeme_string": "category"})
N_RAW = len(df); df = df.drop_duplicates(); N_DUP = N_RAW - len(df)
df = df[["user_id", "timestamp", "delta", "history_seen", "session_seen", "session_correct"]]
df["dt"] = pd.to_datetime(df["timestamp"], unit="s")
df = df[(df["dt"] >= "2013-03-01") & (df["dt"] < "2013-03-12")].copy()
df["date"] = df["dt"].dt.normalize()
df["user_id"] = df["user_id"].astype(str)
N_USERS_311 = df["user_id"].nunique()
ud = df.groupby(["user_id", "date"]).agg(seen=("session_seen", "sum"), correct=("session_correct", "sum"),
                                         sessions=("timestamp", "nunique")).reset_index()
o = df[df.dt < "2013-03-08"]
# 세션 단위(사용자+timestamp)와 복습 행 (세그먼트 기본의 Input Metrics 정의용)
ss = o.groupby(["user_id", "timestamp"]).agg(seen=("session_seen", "sum"), corr=("session_correct", "sum")).rese
t_index().sort_values(["user_id", "timestamp"])
rv = o[o.history_seen >= 1].assign(ok=lambda x: x.delta.between(43200, 172800)).groupby("user_id").ok.mean()
del df, o

obs = ud[ud.date < T("2013-03-08")]; fol = ud[ud.date >= T("2013-03-08")]
u = obs.groupby("user_id").agg(first_active=("date", "min"), last_active=("date", "max"), active_days=("date",
"nunique"),
                               words_seen=("seen", "sum"), words_correct=("correct", "sum"), sessions=("session
s", "sum"))
u["recency"] = (T("2013-03-08") - u.last_active).dt.days
u["F"] = pd.cut(u.active_days, [0, 1, 2, 3, 4, 7], labels=[1, 2, 3, 4, 5]).astype(int)
u["M"], M_EDGES = pd.qcut(u.words_seen, 5, labels=[1, 2, 3, 4, 5], retbins=True); u["M"] = u.M.astype(int)
u["R"] = pd.cut(u.recency, [0, 1, 2, 4, 6, 7], labels=[5, 4, 3, 2, 1]).astype(int)
SEG = ["꾸준형", "습관 형성형", "최근 단발형", "멈춤-꾸준형", "멈춤-몰입형", "멈춤-저활동형"]
cond = [(u.R >= 4) & (u.F >= 4), (u.R >= 4) & u.F.isin([2, 3]), (u.R >= 4) & (u.F == 1), (u.R <= 3) & (u.F >=
3), (u.R <= 3) & (u.M >= 4)]
u["segment"] = np.select(cond, SEG[:5], default=SEG[5])
DATES = list(pd.date_range("2013-03-08", "2013-03-11"))
act = set(zip(fol.user_id, fol.date))
for d in DATES: u[f"a{d.day}"] = [int((i, d) in act) for i in u.index]
u["fdays"] = u[[f"a{d.day}" for d in DATES]].sum(axis=1)
u["ret1"] = (u.fdays >= 1).astype(int); u["ret2"] = (u.fdays >= 2).astype(int)
u["acc"] = u.words_correct / u.words_seen

# ---- 세그먼트 기본의 Input Metrics (관측 주간, 세션 3개 이상 사용자)
ns = ss.groupby("user_id").size(); u["n_sessions_obs"] = ns
ss["gap"] = ss.groupby("user_id").timestamp.diff() / 3600
g = ss.dropna(subset=["gap"]).groupby("user_id").gap.agg(["mean", "std"])
u["gap_cv"] = g["std"] / g["mean"]
def halves(x):
    n = len(x); h = n // 2; a = x.iloc[:h]; b = x.iloc[n - h:]
    return pd.Series({"acc_early": a["corr"].sum() / a.seen.sum(), "acc_late": b["corr"].sum() / b.seen.sum()})
el = ns[ns >= 3].index
hv = ss[ss.user_id.isin(el)].groupby("user_id")[["seen", "corr"]].apply(halves)
```

```
u = u.join(hv); u["review_ok"] = rv
u["eligible3"] = u.n_sessions_obs >= 3
u.loc[~u.eligible3, ["gap_cv", "acc_early", "acc_late", "review_ok"]] = np.nan
u["regular"] = np.where(u.eligible3, (u.gap_cv < 1).astype(float), np.nan)
u["improved"] = np.where(u.eligible3, (u.acc_late > u.acc_early).astype(float), np.nan)

# ---- 대조
assert N_DUP == 81 and N_USERS_311 == 109504 and len(u) == 82467
assert (u.active_days >= 4).sum() == 9834 and u.ret1.sum() == 29240 and u.ret2.sum() == 13466
assert [int(x) for x in M_EDGES] == [1, 24, 53, 108, 239, 11501]
assert u.segment.value_counts().reindex(SEG).tolist() == [8882, 14583, 15402, 3627, 9303, 30670]

def rate(k, n): return k / n * 100 if n else float("nan")
def pct(k, n, d=1): return f"{rate(k, n):.{d}f}%"
def wilson(k, n, z=1.96):
    p = k / n; den = 1 + z * z / n; c0 = (p + z * z / (2 * n)) / den
    h = z * sqrt(p * (1 - p) / n + z * z / (4 * n * n)) / den
    return (c0 - h) * 100, (c0 + h) * 100

# ---- 학습 일수 / NSM (코호트분석2)
days = u.groupby("active_days").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"))
TEAM = {1: (47087, 10278, 3214), 2: (17134, 6675, 2711), 3: (8412, 4633, 2276), 4: (4748, 3310, 1931),
        5: (2723, 2189, 1521), 6: (1532, 1352, 1096), 7: (831, 803, 717)}
for d_, v in TEAM.items(): assert tuple(days.loc[d_]) == v
NSMG = {}
for key, sub in [("hit", u[u.active_days >= 4]), ("miss", u[u.active_days < 4])]:
    NSMG[key] = dict(n=len(sub), k1=int(sub.ret1.sum()), k2=int(sub.ret2.sum()), daily=[int(sub[f"a{d.day}"].sum
()) for d in DATES],
                     cum=[int((sub[[f"a{x.day}" for x in DATES if x <= d]].sum(axis=1) > 0).sum()) for d in DATE
S])
assert NSMG["hit"]["daily"] == [4869, 4067, 3887, 4286] and NSMG["miss"]["cum"] == [9977, 14801, 18301, 21586]
rec1_days = u[u.recency == 1].groupby("active_days").agg(n=("F", "size"), k2=("ret2", "sum"))

# ---- 세그먼트 (코호트분석 + 세그먼트 기본 요약표)
WS = u.words_seen.sum()
seg = u.groupby("segment").agg(n=("F", "size"), k1=("ret1", "sum"), k2=("ret2", "sum"), ws=("words_seen", "su
m"), fd=("fdays", "mean"),
                               **{f"d{d.day}": (f"a{d.day}", "sum") for d in DATES}).reindex(SEG)
seg["cust"] = seg.n / len(u) * 100; seg["vol"] = seg.ws / WS * 100; seg["per"] = seg.ws / seg.n; seg["conc"] = s
eg.vol / seg.cust
CHI2 = chi2_contingency(pd.crosstab(u.segment, u.ret2))
seg_rec = u[u.recency.isin([1, 2])].groupby(["recency", "segment"]).agg(n=("F", "size"), k2=("ret2", "sum"))

# ---- 노션 Input metric: 다음날 재학습률 (사용자-활동일, d=3/1~3/6)
key = set(zip(obs.user_id, obs.date))
ad6 = obs[obs.date <= T("2013-03-06")][["user_id", "date"]].copy()
ad6["nxt"] = [(a, b + pd.Timedelta(days=1)) in key for a, b in zip(ad6.user_id, ad6.date)]
ad6 = ad6.merge(u[["segment"]], left_on="user_id", right_index=True)
NEXT_ALL = (int(ad6.nxt.sum()), len(ad6)); NEXT_SEG = ad6.groupby("segment").nxt.agg(["sum", "size"]).reindex(SE
G)
fa = obs.merge(u[["first_active"]], left_on="user_id", right_index=True)
u["first_vol"] = fa[fa.date == fa.first_active].groupby("user_id").seen.sum()
u["spd"] = u.sessions / u.active_days

# ---- 첫 학습일 코호트
allact = set(zip(ud.user_id, ud.date))
TRI = []
for f in pd.date_range("2013-03-01", "2013-03-07"):
    ids = u.index[u.first_active == f]; row = {"first": f, "n": len(ids), "D": {}}
    for k in range(1, 11):
        d = f + pd.Timedelta(days=k)
        if d > T("2013-03-11"): break
        row["D"][k] = sum((i, d) in allact for i in ids)
    TRI.append(row)

# ---- 비활동 (분석 질문 3)
rec_curve = u[u.active_days <= 2].groupby(["active_days", "recency"]).agg(n=("F", "size"), k1=("ret1", "sum"), k
2=("ret2", "sum"))
rc1 = rec_curve.loc[1]
RESUME = {}
for sg in ["꾸준형", "습관 형성형", "최근 단발형"]:
    s = u[(u.segment == sg) & (u.a8 == 1)]
    for r, lab in [(1, "cont"), (2, "rest")]:
```

```
        t = s[s.recency == r]; RESUME[(sg, lab)] = (len(t), int(((t.a9 + t.a10) > 0).sum()))
assert RESUME[("습관 형성형", "cont")] == (2799, 1392) and RESUME[("습관 형성형", "rest")] == (1307, 549)
(na, ka), (nb, kb) = RESUME[("습관 형성형", "cont")], RESUME[("습관 형성형", "rest")]
pa, pb = ka / na, kb / nb; pp = (ka + kb) / (na + nb)
RES_Z = (pa - pb) / sqrt(pp * (1 - pp) * (1 / na + 1 / nb)); RES_CI = 1.96 * sqrt(pa * (1 - pa) / na + pb * (1 - pb) / nb) * 100

# ---- Input metric × 가설
e = u[u.eligible3].copy()
IM = {"elig": len(e), "regular": e.regular.mean() * 100, "improved": e.improved.mean() * 100, "review_med": e.review_ok.median() * 100,
      "next": rate(*NEXT_ALL)}
im_seg = e.groupby("segment").agg(n=("F", "size"), reg=("regular", "mean"), imp=("improved", "mean"), rev=("review_ok", "median")).reindex(SEG)
reg_tab = e.groupby("regular").agg(n=("F", "size"), k2=("ret2", "sum"))
imp_tab = e.groupby("improved").agg(n=("F", "size"), k2=("ret2", "sum"))
reg_by_days = e.groupby("active_days").regular.agg(["mean", "size"])
reg_habit = e[e.segment == "습관 형성형"].groupby("regular").agg(n=("F", "size"), k2=("ret2", "sum"))
imp_habit = e[e.segment == "습관 형성형"].groupby("improved").agg(n=("F", "size"), k2=("ret2", "sum"))
e["rvq"] = pd.cut(e.review_ok, [-0.001, 0, 0.1, 0.25, 1.0], labels=["0%", "0~10%", "10~25%", "25% 초과"])
rv_tab = e.groupby("rvq", observed=True).agg(n=("F", "size"), k2=("ret2", "sum"))
rv_habit = e[e.segment == "습관 형성형"].groupby("rvq", observed=True).agg(n=("F", "size"), k2=("ret2", "sum"))

# ---- 액션 성공 지표 기준값 (세그먼트 기본 4️⃣)
s1 = u[u.segment == "최근 단발형"]; s1y = s1[s1.recency == 1]
BASE = {"habit_all4": rate((u[u.segment == "습관 형성형"].fdays == 4).sum(), seg.loc["습관 형성형", "n"]),
        "habit_ret2": rate(seg.loc["습관 형성형", "k2"], seg.loc["습관 형성형", "n"]),
        "pk_ret1": rate(seg.loc["멈춤-꾸준형", "k1"], seg.loc["멈춤-꾸준형", "n"]),
        "pm_fd": seg.loc["멈춤-몰입형", "fd"], "steady_ret2": rate(seg.loc["꾸준형", "k2"], seg.loc["꾸준형", "n"]),
        "single_next": rate(s1y.a8.sum(), len(s1y)), "single_next_n": len(s1y), "low_ret1": rate(seg.loc["멈춤-저활동형", "k1"], seg.loc["멈춤-저활동형", "n"])}
two3 = u[u.active_days.isin([2, 3])]; T23H = two3[two3.segment == "습관 형성형"]; T23P = two3[two3.segment != "습관 형성형"]

# ============================================================ 2. 대시보드 데이터 패키지
def save(df_, name): df_.to_csv(os.path.join(DATA, name), index=False, encoding="utf-8-sig")
kpi = pd.DataFrame([
    ("주간 활성 학습자 수", "count(사용자 | 3/1~3/7 활동일 ≥ 1)", len(u), None, "노션 지표 정의서"),
    ("주간 지속 학습 사용자 수(NSM)", "count(사용자 | 3/1~3/7 활동일 ≥ 4)", int((u.active_days >= 4).sum()), rate((u.active_days >= 4).sum(), len(u)), "노션 NSM"),
    ("다음날 재학습률", "활동일 d 중 d+1에도 활동 ÷ 활동일 d (d=3/1~3/6)", NEXT_ALL[0], IM["next"], "노션·세그먼트 기본 Input metric"),
    ("규칙적 학습자 비율", "세션 간 간격 변동계수 < 1 ÷ 세션 3개 이상 사용자", int(e.regular.sum()), IM["regular"], "세그먼트 기본 Input metric(가설 1)"),
    ("학습 성과 개선율", "후반 정답률 > 초반 정답률 ÷ 세션 3개 이상 사용자", int(e.improved.sum()), IM["improved"], "세그먼트 기본 Input metric(가설 2)"),
    ("적정 간격 복습 비율(중앙값)", "사용자별 delta 12~48시간 복습 행 비율의 중앙값, 세션 3개 이상 사용자", None, IM["review_med"], "세그먼트 기본 Input metric(가설 3)"),
    ("활동일당 세션 수(중앙값)", "사용자별 세션 수 ÷ 활동일 수의 중앙값", None, float(u.spd.median()), "세그먼트 기본 보류 지표"),
    ("첫 학습일 학습량(중앙값)", "관측 주 첫 활동일 session_seen 합의 중앙값", None, float(u.first_vol.median()), "세그먼트 기본 보류 지표"),
    ("후속 4일 재학습률", "3/8~3/11 중 1일 이상 학습 ÷ 주간 활성", int(u.ret1.sum()), rate(u.ret1.sum(), len(u)), "두 코호트 파일 공통"),
    ("후속 4일 반복학습률", "3/8~3/11 중 2일 이상 학습 ÷ 주간 활성", int(u.ret2.sum()), rate(u.ret2.sum(), len(u)), "두 코호트 파일 공통")],
    columns=["지표", "정의", "인원_또는_분자", "값(%)_또는_중앙값", "출처"])
save(kpi, "01_kpi_summary.csv")
save(pd.DataFrame({"active_days": days.index, "users": days.n, "ret1_users": days.k1, "ret1_rate": days.k1 / days.n * 100, "ret2_users": days.k2,
                   "ret2_rate": days.k2 / days.n * 100, "nsm_group": np.where(days.index >= 4, "달성", "미달성"),
                   "last3_7_users": rec1_days.n.reindex(days.index).values, "last3_7_ret2_rate": (rec1_days.k2 / rec1_days.n * 100).reindex(days.index).values}), "02_cohort_active_days.csv")
rows = []
for kname, gname in [("hit", "NSM 달성"), ("miss", "NSM 미달성")]:
    gg = NSMG[kname]
    for i, d in enumerate(DATES):
        rows.append([gname, str(d.date()), gg["n"], gg["daily"][i], gg["daily"][i] / gg["n"] * 100, gg["cum"][i], gg["cum"][i] / gg["n"] * 100])
save(pd.DataFrame(rows, columns=["group", "date", "users", "active_users", "daily_rate", "cum_users", "cum_rate"]), "03_cohort_nsm_daily.csv")
sg = seg.copy(); sg["segment"] = sg.index
sg["ret1_rate"] = sg.k1 / sg.n * 100; sg["ret2_rate"] = sg.k2 / sg.n * 100
```

```
sg["ret2_ci_low"], sg["ret2_ci_high"] = zip(*[wilson(k, n) for k, n in zip(sg.k2, sg.n)])
sg["next_day_rate"] = (NEXT_SEG["sum"] / NEXT_SEG["size"] * 100).values
sg["eligible3_users"] = im_seg.n.values; sg["regular_rate"] = im_seg.reg.values * 100; sg["improved_rate"] = im_
seg.imp.values * 100
sg["review_ok_median"] = im_seg.rev.values * 100
sg["sessions_per_day_median"] = u.groupby("segment").spd.median().reindex(SEG).values
sg["first_day_volume_median"] = u.groupby("segment").first_vol.median().reindex(SEG).values
sg["accuracy_mean"] = u.groupby("segment").acc.mean().reindex(SEG).values * 100
save(sg[["segment", "n", "cust", "ws", "vol", "per", "conc", "k1", "ret1_rate", "k2", "ret2_rate", "ret2_ci_lo
w", "ret2_ci_high", "fd",
        "next_day_rate", "eligible3_users", "regular_rate", "improved_rate", "review_ok_median", "sessions_per_
day_median",
        "first_day_volume_median", "accuracy_mean"]].rename(columns={"n": "users", "cust": "user_share", "ws":
"words_seen", "vol": "volume_share",
        "per": "words_per_user", "conc": "concentration", "k1": "ret1_users", "k2": "ret2_users", "fd": "follow
up_days_mean"}), "04_segment_summary.csv")
save(pd.DataFrame([[s, str(d.date()), int(seg.loc[s, "n"]), int(seg.loc[s, f"d{d.day}"]), seg.loc[s, f"d{d.da
y}"] / seg.loc[s, "n"] * 100] for s in SEG for d in DATES],
                 columns=["segment", "date", "users", "active_users", "daily_rate"]), "05_segment_daily.csv")
save(pd.DataFrame([[str(r["first"].date()), r["n"], k, (r["D"].get(k)), (r["D"][k] / r["n"] * 100 if k in r["D"]
else None), k in r["D"]]
                   for r in TRI for k in range(1, 11)], columns=["first_active", "users", "day_k", "active_user
s", "rate", "observed"]), "06_first_active_cohort.csv")
rcv = rec_curve.reset_index(); rcv["ret1_rate"] = rcv.k1 / rcv.n * 100; rcv["ret2_rate"] = rcv.k2 / rcv.n * 100
save(rcv.rename(columns={"n": "users", "k1": "ret1_users", "k2": "ret2_users"}), "07_recency_curve.csv")
save(pd.DataFrame([[sg_, "이어서 학습(3/7 학습)" if lab == "cont" else "하루 쉬고 재개(3/6 마지막)", n_, k_, k_ / n_ * 1
00]
                   for (sg_, lab), (n_, k_) in RESUME.items()], columns=["segment", "group", "users", "d1d2_user
s", "d1d2_rate"]), "08_resume_compare.csv")
hrows = []
for mname, tab, lab in [("규칙적 학습자", reg_tab, {0.0: "불규칙(CV≥1)", 1.0: "규칙(CV<1)"}), ("학습 성과 개선", imp_ta
b, {0.0: "개선 없음", 1.0: "개선"})]:
    for k_, r_ in tab.iterrows(): hrows.append([mname, "전체", lab[k_], int(r_.n), int(r_.k2), r_.k2 / r_.n * 10
0])
for mname, tab, lab in [("규칙적 학습자", reg_habit, {0.0: "불규칙(CV≥1)", 1.0: "규칙(CV<1)"}), ("학습 성과 개선", imp_h
abit, {0.0: "개선 없음", 1.0: "개선"})]:
    for k_, r_ in tab.iterrows(): hrows.append([mname, "습관 형성형", lab[k_], int(r_.n), int(r_.k2), r_.k2 / r_.n
* 100])
for nm, tab in [("전체", rv_tab), ("습관 형성형", rv_habit)]:
    for k_, r_ in tab.iterrows(): hrows.append(["적정 간격 복습 비율", nm, str(k_), int(r_.n), int(r_.k2), r_.k2 / r
_.n * 100])
save(pd.DataFrame(hrows, columns=["metric", "scope", "group", "users", "ret2_users", "ret2_rate"]), "09_input_me
tric_hypothesis.csv")
act_rows = [["1", "습관 형성형", "4일 이상 학습 전환율", "후속 4일 모두 학습", BASE["habit_all4"], "후속 4일 중 2일 이상", BA
SE["habit_ret2"]],
            ["2", "멈춤-꾸준형", "4일 내 복귀율", "후속 4일 중 1일 이상", BASE["pk_ret1"], "", None],
            ["2", "멈춤-몰입형", "재학습일 수", "후속 4일 평균 학습일", BASE["pm_fd"], "", None],
            ["3", "꾸준형", "NSM 유지율", "측정 불가(다음 7일 필요) · 대체: 후속 2일 이상", BASE["steady_ret2"], "", None],
            ["4", "최근 단발형", "다음 날 복귀율", "3/7 학습자의 3/8 학습", BASE["single_next"], "", None],
            ["5", "멈춤-저활동형", "알림 반응률", "측정 불가(알림 로그 없음) · 대체: 4일 내 복귀율", BASE["low_ret1"], "", Non
e]]
save(pd.DataFrame(act_rows, columns=["priority", "segment", "success_metric", "baseline_definition", "baseline_v
alue", "extra_definition", "extra_value"]), "10_action_baselines.csv")
cols = ["segment", "active_days", "recency", "R", "F", "M", "first_active", "last_active", "words_seen", "acc",
"sessions", "first_vol",
        "a8", "a9", "a10", "a11", "fdays", "ret1", "ret2", "n_sessions_obs", "gap_cv", "regular", "acc_early",
"acc_late", "improved", "review_ok"]
uu = u[cols].reset_index().rename(columns={"index": "user_id"})
uu["first_active"] = uu.first_active.dt.date; uu["last_active"] = uu.last_active.dt.date
save(uu, "11_user_level.csv")
```